

République Algérienne Démocratique Et Populaire
Ministère De L'enseignement Supérieur Et De La Recherche Scientifique
Université Echahid Cheikh Larbi Tebessi- Tebessa

Faculté des sciences exactes, sciences de la nature et de la vie

Département d'informatique

Laboratoire de domiciliation : Laboratoire Des Mathématiques, Informatique et Systèmes
(LAMIS)



THÈSE

Présentée et Soutenue Publiquement en Vue de l'Obtention
du Diplôme de Doctorat en Troisième Cycle

Par:

TOURECHE Amina

Domaine : mathématiques et informatique Filière: informatique

Spécialité : Réseaux et multimédia

Intitulée

**L'APPRENTISSAGE MACHINE POUR AMÉLIORER LE
TRAITEMENT AUTOMATIQUE DES IMAGES
MÉDICALES**

Soutenue le : 15/07/2025

Devant le Jury composé de :

Mr. Abdallah Meraoumia	Prof	Univ. deTebessa	Président
Mr. Hakim Bendjenna	Prof	Univ. deTebessa	Encadreur
Mr. Lakhdar Laimeche	Prof	Univ. deTebessa	Co-encadreur
Mr. Akram Bennour	Prof	Univ. deTebessa	Examineur
Mr. Issam Bendib	MCA	Univ. deTebessa	Examineur
Mr. Ledmi Makhlouf	MCA	Univ. deKhenchella	Examineur

Année universitaire : 2024 / 2025

*L'APPRENTISSAGE MACHINE POUR AMÉLIORER LE TRAITEMENT
AUTOMATIQUE DES IMAGES MÉDICALES*

TOURECHE Amina

amina.toureche@univ-tebessa.dz

Laboratoire de Mathématiques, Informatique et Systèmes (LAMIS),
Université Echahid Cheikh Larbi Tebessi- Tébessa,
Algérie.



بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

Remerciements

Le premier remerciement est adressé à Dieu Tout-Puissant qui nous a prodigué ses innombrables bénédictions et nous a permis d'atteindre ce que nous sommes, et tous les remerciements à tous les enseignants et professeurs qui ont eu le mérite d'atteindre cette étape académique de ma vie, ainsi que le généreux Professeur **BENDJENNA Hakim** qui nous a toujours inculqué l'enthousiasme et la persévérance pour achever cette réalisation de notre humble recherche, et tous les remerciements également au Dr. **LAIMECHE Lakhdar** qui a toujours enduré de nombreuses difficultés pour mon orientation académique et m'a aidé à plusieurs moments et stations dans cette recherche.

Je voudrais également remercier le Dr. **MERAOUNIA Abdallah**, qui ne manque jamais de nous fournir des commentaires et des conseils précieux dans notre recherche, et tous ceux qui sont liés à cette thèse de près ou de loin, en particulier mon mari, l'enseignant **Halkoum Noureddine**, mes parents, mes frères et sœurs, et mes enfants.

Enfin, je tiens à remercier mon président de comité et les membres du comité qui ont donné de leur temps pour me guider dans cette soutenance de ma thèse.

Merci

Résumé

Les maladies du foie sont l'une des maladies les plus répandues dans le monde et qui entraînent la mort, notamment en raison de la diversité de leurs causes, de leur diagnostic tardif et de leur difficulté à les diagnostiquer. La meilleure analyse du cancer du foie passe par la recherche clinique qui s'appuie sur la tomodensitométrie, qui joue un rôle clé dans le bon diagnostic du cancer du foie et les étapes de son développement, depuis l'étape du diagnostic jusqu'à celui du traitement. Dans le passé, la détection de cette maladie était extrêmement difficile en termes de détection opportune et d'étapes complexes par lesquelles passent les experts médicaux tels que les radiologues et autres. C'est pourquoi ils ont dû développer des mécanismes spéciaux pour aider à un diagnostic rapide et précis, et ces mécanismes comprennent l'utilisation du diagnostic assisté par ordinateur, qui est devenu essentiel pour la détection précise des tumeurs du foie, en particulier des petites tumeurs.

Dans notre thèse, nous avons proposé plusieurs modèles d'apprentissage automatique et d'apprentissage profond pour aider à la segmentation automatisée des tumeurs cancéreuses du foie et à la classification du foie entre malade et non malade. Tout d'abord, nous avons collecté des images médicales pour obtenir notre base de données. Ces images médicales sont des images médicales transversales. Ensuite, nous avons extrait les images médicales du foie uniquement par la segmentation automatique. À cette étape, nous avons séparé le foie des autres organes afin d'obtenir une base de données contenant uniquement le foie et ses masques. Pour ce faire, nous avons utilisé les méthodes suivantes : Modèle de Rayleigh, modèle de mélange gaussien et flux vectoriel de gradient Il s'agit de l'étape initiale de notre thèse. Nous avons également utilisé ces mêmes méthodes pour segmenter les tumeurs du foie avec leurs masques. Nous avons obtenu un grand ensemble d'images médicales de plusieurs personnes, composé de 784 images médicales du foie avec 370 patients et 414 non-patients avec leurs masques et 235 images médicales de tumeurs du foie, y compris du foie et les tumeurs du foie et leurs masques, puis nous avons créé deux modèles d'apprentissage profond, Ces deux modèles sont de nouvelles versions du modèle ASU_NET, qui est devenu bien connu dans le domaine de la segmentation automatisée et qui joue un rôle important dans l'amélioration du diagnostic assisté par ordinateur.

Le premier modèle, DDA_UNET, a utilisé notre propre base de données pour l'entraînement et les tests, et a comparé ce modèle à trois autres modèles : UNET, UNET++ et ASU_NET. Nous avons obtenu des taux de précision de 99,44 % et 97,39 % pour ACC-BATNA2022 et LITS2017 pour la segmentation du foie, respectivement. Pour la segmentation des tumeurs du foie, nous avons obtenu des résultats remarquables avec des taux de précision de 99,27 % et 99,26 % pour ACC-BATNA2022 (foie et tumeurs du foie), respectivement. Nous avons ici observé l'efficacité de notre modèle par rapport à d'autres modèles. Quant au deuxième modèle ASD_UNET, nous l'avons comparé aux trois modèles précédents, à savoir : UNET, UNET++, ASU_NET, et notre premier modèle, DDA_UNET, avec les bases de données ACC-BATNA 2022 et LITS-17.

Ces dernières sont des images médicales avec une extension '. Nii'. Les meilleurs taux de précision pour notre modèle étaient respectivement de 97,418 % et 99,4492 % pour la segmentation du foie. Pour la segmentation des tumeurs du foie, les taux de précision de notre modèle dans la base de données ACC-BATNA2022 pour la segmentation des tumeurs du foie sont : 99,25 % et 99,2670 %, respectivement. Ce sont les meilleurs par rapport aux autres modèles. Les techniques de segmentation par l'apprentissage profond ont eu un impact significatif en termes d'amélioration du diagnostic du cancer du foie.

Mots clés : cancer du foie, apprentissage machine, apprentissage profond, la segmentation du foie, la segmentation des tumeurs du foie.

Abstract

Liver disease is one of the most common and life-threatening diseases in the world, not least because of the diversity of its causes, its late diagnosis and the difficulty of diagnosing it. The best way to analyze liver cancer is through clinical research based on CT scans, which play a key role in the correct diagnosis of liver cancer and the stages in its development, from diagnosis to treatment. In the past, detection of this disease has been extremely difficult in terms of timely detection and the complex steps that medical experts such as radiologists and others have to go through. For this reason, they have had to develop special mechanisms to aid rapid and accurate diagnosis, and these mechanisms include the use of computer-aided diagnosis, which has become essential for the accurate detection of liver tumors, particularly small tumors.

In our thesis, we proposed several machine learning and deep learning models to aid automated segmentation of liver cancer tumors and classification of the liver between diseased and non-diseased. First, we collected medical images to obtain our database. These medical images are cross-sectional medical images. Then, we extracted the medical images of the liver only by automatic segmentation. At this stage, we separated the liver from the other organs in order to obtain a database containing only the liver and its masks. To do this, we used the following methods: Rayleigh model, Gaussian mixture model and gradient vector flow.... This is the initial stage of our thesis.

We also used these same methods to segment liver tumors with their masks. We obtained a large set of medical images from several people, consisting of 784 medical images of the liver with 370 patients and 414 non-patients with their masks and 235 medical images of liver tumors, including liver and liver tumors and their masks, and then created two deep learning models. These two models are new versions of the ASU_NET model, which has become well known in the field of automated segmentation and plays an important role in improving computer-aided diagnosis.

The first model, DDA_UNET, used our own database for training and testing, and compared this model with three other models: UNET, UNET++ and ASU_NET. We obtained accuracy rates of 99.44% and 97.39% for ACC-BATNA2022 and LITS2017 for liver segmentation, respectively. For liver tumor segmentation, we obtained remarkable results with accuracy rates of 99.27% and 99.26% for ACC-BATNA2022 (liver and liver tumors), respectively. Here we observed the efficiency of our model compared with other models

As for the second model, ASD_UNET, we compared it with the three previous models, namely: UNET, UNET++, ASU_NET, and our first model, DDA_UNET, with the ACC-BATNA2022 and LITS2017 databases. The latter are medical images with a '.Nii' extension. The best accuracy rates for our model were 97.418% and 99.4492% respectively for liver segmentation. For liver tumor segmentation, the accuracy rates of our model in the ACC-BATNA2022 database for liver tumor segmentation are: 99.25% and 99.2670%, respectively. These are the best compared with other models. Deep learning segmentation techniques have had a significant impact in terms of improving liver cancer diagnosis.

Key words: liver cancer, machine learning, deep learning, liver segmentation, liver tumor segmentation.

ملخص

إن أمراض الكبد تعد من الأمراض الشائعة في العالم المسببة للوفاة، خاصة مع تنوع أسبابه وتأخر تشخيصه وصعوبته. وتأتي صعوبة التشخيص من ناحية الوسائل المتاحة للتشخيص والتكلفة الخاصة به، فأحسن تحليل لسرطان الكبد يكون عن طريق الأبحاث السريرية التي تعتمد على التصوير المقطعي المحوسب والذي يلعب دورا رئيسيا في التشخيص الجيد لسرطان الكبد، وتبيان مراحل تطوره من مرحلة التشخيص كبدية الى مرحلة العلاج. ففي السابق كان الكشف عن هذا المرض أمرا في غاية الصعوبة من حيث اكتشافه في الوقت المناسب ومن حيث المراحل المعقدة التي يمر بها الخبراء الطبيون من اخصائي الأشعة وغيرهم. فلهذا كان عليهم تطوير آليات خاصة للمساعدة في التشخيص السريع والدقيق وهذه الآليات تكون باستعمال التشخيص بمساعدة الكمبيوتر الذي أصبح ضروريا للكشف الدقيق للأورام الكبدية خاصة الصغيرة منها.

اقترحنا في رسالتنا عدة نماذج سواء في التعلم الآلي أو التعلم العميق للمساعدة في التجزئة الآلية لأورام سرطان الكبد وتصنيف الكبد بين مريض وغير مريض. أولا، قمنا بجمع الصور الطبية للحصول على قاعدة البيانات الخاصة بنا. هذه الصور الطبية هي صور طبية مقطعية. بعد ذلك، قمنا باستخراج الصور الطبية للكبد فقط عن طريق التجزئة الآلية. في هذه المرحلة قمنا بفصل الكبد عن الأعضاء الأخرى للحصول على قاعدة بيانات خاصة بالكبد فقط وأقنعته. وذلك باستخدام الطرق التالية: نموذج رايلي ونموذج الخليط الغوسي والتدفق المتجه المتدرج.... هذه هي المرحلة الأولية لأطروحتنا.

كما استعملنا هذه الطرق نفسها لتجزئة أورام الكبد مع أقنعته وقد تحصلنا على مجموعة كبيرة من الصور الطبية لعدة أشخاص، تتمثل في 784 صورة طبية للكبد فيها 370 مريضة و414 غير مريضة مع أقنعته و235 صور طبية للأورام الكبدية، فيها تجزئة الكبد وأورام الكبد وأقنعته، ثم قمنا بإنشاء نموذجين خاصين بالتعلم العميق هذين النموذجين هما اصدارين جديدين لنموذج Asu_net، والذي أصبح معروفا في مجال التجزئة الآلية والذي يلعب دورا هاما في تحسين التشخيص بمساعدة الكمبيوتر.

النموذج الأول DDA_UNET، استعملنا فيه قاعدة البيانات الخاصة بنا للتدريب والاختبار وقارنا هذا النموذج مع ثلاثة نماذج أخرى سابقة لها وهي: UNET، UNET++، ASU_NET. فتحصلنا على معدلات دقة 99.44% و97.39% لقاعدة البيانات ACC-BATNA2022 وLITS2017 لتجزئة الكبد، على التوالي. أما في تجزئة أورام الكبد، حققنا نتائج ملحوظة في معدلات الدقة بنسبة 99.27% و99.26% لقاعدة بيانات ACC-BATNA2022 (الكبد وأورام الكبد)، على التوالي. وهنا لاحظنا فاعلية نموذجنا مقارنة بالنماذج الأخرى. أما بالنسبة للنموذج الثاني ASD_UNET فقد قارناه مع النماذج الثلاثة السابقة له، وهي: UNET، UNET++، ASU_NET، وكذلك مع النموذج الأول DDA_UNET الخاص بنا، مع قاعدة البيانات ACC-BATNA2022 وLITS2017. وهذه الأخيرة صورها الطبية بامتداد 'nii'. فكانت هذه هي أفضل النتائج لمعدلات الدقة بالنسبة لنموذجنا 97.418%، 99.4492%، بالنسبة لتجزئة الكبد، على التوالي. أما بالنسبة لتجزئة أورام الكبد، نتائج معدلات الدقة بالنسبة لهذا النموذج في قاعدة البيانات ACC-BATNA2022 الخاصة بتجزئة أورام الكبد هي: 99.25%، 99.2670%، على التوالي. وهي الأفضل مقارنة بالنماذج الأخرى. إن تقنيات التجزئة في التعلم العميق أحدثت أثرا كبيرا من ناحية تحسين تشخيص سرطان الكبد.

الكلمات المفتاحية: سرطان الكبد، التعلم الآلي، التعلم العميق، تجزئة الكبد، تجزئة أورام الكبد

TABLES DES MATIERES

REMERCIEMENTS	6
RESUME.....	7
ABSTRACT	8
ملخص.....	15
TABLES DES MATIERES	16
LISTE D'ABREVIATIONS	19
TABLE DES FIGURES.....	20
LISTE DES TABLEAUX	23
INTRODUCTION GENERALE :.....	17
PARTIE 01 : CONCEPTS DE BASE ET ETAT DE L'ART.....	20
CHAPITRE 1 : CANCER DU FOIE.....	21
1.1 INTRODUCTION.....	22
1.1.1 ÉPIDEMIOLOGIE ET IMPORTANCE CLINIQUE.....	22
1.1.2 FACTEURS DE RISQUE ET CAUSES.....	22
1.1.3 PREVENTION ET DEPISTAGE.....	23
1.2 CANCER DU FOIE ET SES TYPES	23
1.3 TECHNIQUES D'IMAGERIE MEDICALE POUR LE DIAGNOSTIC DU CANCER DU FOIE	27
1.3.1 L'IMAGERIE PAR ULTRASONS	28
1.3.2 LA TOMODENSITOMETRIE (CT)	28
1.3.3 L'IMAGERIE PAR RESONANCE MAGNETIQUE (IRM)	29
1.4 IMAGERIE MEDICALE ET INTELLIGENCE ARTIFICIELLE DANS LE DIAGNOSTIC DU CANCER DU FOIE.....	29
1.5 CONCLUSION	30
CHAPITRE 2 : CONCEPTS FONDAMENTAUX ET METHODES DE SEGMENTATION DES IMAGES MEDICALES	31
2.1 INTRODUCTION.....	32
2.1.1 LA SEGMENTATION BASEE SUR LES REGIONS.....	32
2.1.2 LA SEGMENTATION BASEE SUR LES CONTOURS.....	34
2.1.3 LA SEGMENTATION PAR SEUILLAGE	35

2.1.4	LA SEGMENTATION HYBRIDE ET LES APPROCHES AVANCEES.....	36
2.2	CONCLUSION	38
PARTIE 02 : CONTRIBUTIONS ET VALIDATION		39
CHAPITRE 3 : DIAGNOSTIC ASSISTÉ PAR ORDINATEUR DANS LA SEGMENTATION DES TUMEURS HÉPATIQUES.....		40
3.1.	INTRODUCTION	41
3.2.	ACQUISITION D'IMAGES PAR LE RADIOLOGUE	41
3.3.	ACQUISITION DE BASE DE DONNEES PAR LA SEGMENTATION.....	42
3.4.	METHODOLOGIE CAD DANS LA SEGMENTATION DES TUMEURS HEPATIQUES	42
CHAPITRE 4 : LA SEGMENTATION DES TUMEURS HÉPATIQUES PAR LES MÉTHODES DE MACHINE LEARNING		47
4.1.	INTRODUCTION	48
4.2.	METHODOLOGIE	49
4.2.1.	PRETRAITEMENT DES IMAGES MEDICALES DU FOIE	50
4.2.2.	MODELE DE MELANGE GAUSSIEN	51
4.2.3.	FLUX VECTORIEL DE GRADIENT (GVF : GRADIENT VECTOR FLOW)	55
4.3.	RESULTATS ET ANALYSE	57
4.4.	LA SEGMENTATION DES TUMEURS HEPATIQUES AVEC LE SEUILLAGE	61
4.4.1.	EXTRACTION LES MASQUES AVEC LE SEUILLAGE.....	61
4.5.	CREATION DE LA BASE DE DONNEES	65
4.6.	CONCLUSION ET DISCUSSION.....	69
CHAPITRE 5 : SEGMENTATION AUTOMATIQUE DU CANCER DES TUMEURS HEPATIQUES À L'AIDE DE L'APPRENTISSAGE PROFOND.....		70
5.1.	INTRODUCTION	71
5.2.	BASES DE DONNEES UTILISEES.....	72
5.2.1.	BASE ACC-BATNA2022	73
5.2.2.	BASE LiTS2017	73
5.2.3.	COMPLEMENTARITE DES BASES DE DONNEES.....	73
5.3.	MODELES ET APPROCHES PROPOSEES.....	74
5.3.1.	RAPPEL SUR U-NET++	74
5.3.2.	ARCHITECTURE DDA-UNET	74
5.3.3.	ARCHITECTURE ASD-UNET.....	76

5.3.4.	AMELIORATION DE L'ENCODEUR AVEC DENSENET.....	77
5.3.5.	INTEGRATION DU MODULE ASPP.....	79
5.3.6.	SYNTHESE DES CHOIX METHODOLOGIQUES.....	82
5.4.	MISE EN ŒUVRE EXPERIMENTALE.....	82
5.4.1.	ENVIRONNEMENT MATERIEL ET LOGICIEL	82
5.4.2.	PRETRAITEMENT DES DONNEES.....	82
5.4.3.	PARAMETRES D'ENTRAINEMENT	83
5.4.4.	METRIQUES D'EVALUATION.....	85
5.4.5.	PROTOCOLES DE VALIDATION	86
5.5.	ANALYSE ET DISCUSSION DES RESULTATS.....	86
5.5.1.	RESULTATS DE SEGMENTATION DU FOIE.....	86
5.5.2.	RESULTATS DE SEGMENTATION DES TUMEURS HEPATIQUES	89
5.5.3.	RESULTATS DE LA SEGMENTATION DU FOIE ET DES TUMEURS HEPATIQUES A PARTIR DE LA BASE DE DONNEES LITS2017	95
5.6.	DISCUSSION.....	99
5.7.	CONCLUSION	102
CHAPITRE 6 : CLASSIFICATION DES CANCERS TUMORAUX HEPATIQUES À L'AIDE DE RESEAU NEURONAL CONVOLUTIF (CNN)		104
6.1	INTRODUCTION.....	105
6.2	LA CLASSIFICATION DE LA TUMEUR DE FOIE	105
6.2.1	METHODES DE SEGMENTATION.....	106
6.2.2	CLASSIFICATION DU CNN.....	107
6.3	MÉTHODOLOGIE	108
6.4	ENSEMBLE DE DONNÉES	109
6.5	RÉSULTATS DE LA CLASSIFICATION ET DISCUSSION.....	110
6.6	CONCLUSION	113
CONCLUSION GENERALE& PERSPECTIVE.....		115
CONCLUSION GENERALE & PERSPECTIVE		116
CONTRIBUTIONS SCIENTIFIQUES.....		119
BIBLIOGRAPHIE.....		120

LISTE D'ABREVIATIONS

CT	Tomographie assistée par ordinateur
IRM	Imagerie par résonnance magnétique
US	Echographie
FNH	Hyperplasie nodulaire focale
CHC	Carcinome Hépato Cellulaire
TEP	Tomographie par Emission de Positions
HPC	Calcul Haute Performance
CAD	Diagnostic Assisté par Ordinateur
GVF	Gradient Vector Flow
FCN	FullyConvolutional Networks
CNN	Réseaux de Neurones Convolutifs
GANs	Générative Adversaire Networks
KNN	K-Nearest Neighbors
SVM	Machine à vecteurs de support
SAEs	SparseAuto_Encoders
Dicom	Digital Imaging and Communications in Medicine
Nii	The NIFTI file format (Neuroimaging Informatics Technology Initiative)
GMM	Modèle de mélange gaussien
PNG	Portable Network Graphics
BMP	Basic MetabolicPanel
LITS2017	Liver Tumor Segmentation Challenge 2017
ACC-Batna2022	Anti-Cancer Center of BATNA 2022
ASPP	Atrous Spatial PyramidPooling
DenseNet	Dense Convolutional Network
DDA_UNET	Double DenseNet ASPP
ASD_UNET	ASPPDenseNet
API	Application Programming Interface
GAP	Global Average Pooling
IOU	Intersection Over Union
MSE	Mean Square Error
GPU	Graphics ProcessingPnit
CPU	Central Processing Unit

TABLE DES FIGURES

Figure 1. 1 : Les hémangiomes.....	24
Figure 1. 2: Le carcinome hépatocellulaire	26
Figure 1. 3: Le carcinome hépatocellulaire	26
Figure 1. 4: Diagnostic à l'aide d'un scanner CT	28
Figure 3. 1 : Acquisition de la base de données	42
Figure 3. 2 : Diagramme de flux du système automatisé de création d'une base de données et de segmentation du cancer du foie et tumeurs hépatiques proposé.....	43
Figure 3. 3 : Diagramme de flux du système automatisé de segmentation du cancer du foie et tumeurs hépatiques proposé avec la base de données Lits2017.....	43
Figure 3. 4 : Acquisition des images médicales du foie.....	44
Figure 3. 5 : La segmentation du foie (a) image en niveaux de gris du foie (b) masque du foie	44
Figure 3. 6 : La segmentation des tumeurs hépatiques du foie (a) L'image CT du foie (b) L'image en niveaux de gris du foie (c) Les masques des tumeurs hépatiques ...	45
Figure 3. 7 : La Base de données Lits2017(a) Image du foie (b) Masques des tumeurs hépatiques	46
Figure 4. 1 : les étapes de segmentation des images médicales du foie.....	50
Figure 4.2 : L'estimation de la densité de Rayleigh	51
Figure 4. 3 : L'estimation d'un histogramme par 12 gaussienne	53
Figure 4. 4 : Image Morphologique du CT du foie.....	54
Figure 4. 5 : Image Canny du foie	55
Figure 4. 6 : Illustration sur GVF Méthode.....	57
Figure 4. 7 : L'histogramme des images des personne normales	58
Figure 4. 8 : L'histogramme des images des personnes malades	59
Figure 4. 9 : Résultats de segmentation des tumeurs hépatiques du foie par Seuillage et la méthode GVF (a) Image originale (en niveaux de gris) (b) N° gaussienne (c) Morphologique image (d) Filtrage de Canny (e) Résultat de GVF.....	63
Figure 4. 10 : Résultats de segmentation du foie normale par Seuillage et la méthode GVF (a) Image originale (en niveaux de gris) (b) N° gaussienne (c) Image Morphologique (d) Filtrage de Canny (e) Résultat de GVF.....	65
Figure 4. 11 : Résultats de bases de données du foie (a) Image CT du foie (b) Masques du foie	68
Figure 4. 12 : Résultats de bases de données du Tumeurs hépatiques (a) Image CT du foie (b)	

Images du foie (c) masques des tumeurs hépatiques.....	68
Figure 5. 1 : Architecture DDA_UNet utilisant un double DenseNet et un module ASPP	75
Figure 5. 2 : Architecture ASD_UNet améliorée intégrant un DenseNet et un double module ASPP.....	77
Figure 5. 3 : Structure du DenseNet intégrée dans nos modèles	79
Figure 5. 4 : Convolutions dilatées avec des taux de dilatation (6, 12, 18)	80
Figure 5. 5 : Connexion dense (DDA_UNet).....	81
Figure 5. 6 : Connexion ASPP (ASD_UNet)	81
Figure 5. 7 : Module Atrous Spatial Pyramid Pooling intégré dans nos modèles	81
Figure 5. 8 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les images du foie avec de la base de données ACC-BATNA2022.....	87
Figure 5. 9 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les images de tumeurs hépatiques issues des images CT complètes de la base de données ACC-BATNA2022.....	92
Figure 5. 10 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les tumeurs hépatiques à partir des images de foie segmenté, issues de la base de données ACC-BATNA2022.....	94
Figure 5. 11 : Graphiques de perte et de précision pour les données d'entraînement et de validation relatives à la segmentation des tumeurs hépatiques à partir des images du foie segmenté (a) Précision – (b) Perte.....	95
Figure 5. 12 : Comparaison qualitative entre les modèles, illustrant les résultats de segmentation du foie et des tumeurs hépatiques sur la base de données LiTS2017.....	98
Figure 5. 13 : Courbes de perte et de précision pour la segmentation du foie et des tumeurs hépatiques sur la base de données LiTS2017 : (a) Précision – (b) Perte.....	99
Figure 5. 14 : Exemple de résultats de segmentation obtenus avec le modèle U-Net sur la base LiTS2017 : comparaison entre l'image originale, le masque et la segmentation prédite.	102
Figure 6. 1 : Étapes de la technique CNN basée sur le seuil gaussien.....	109
Figure 6. 2 : Résultats de précision et de validation du foie segmenté.....	112
Figure 6. 3 : Résultats de précision et de validation du foie complet	112
Figure 6. 4 : Résultats de perte de précision et de validation du foie segmenté.....	113
Figure 6. 5 : Résultats de perte de précision et de validation du foie complet.....	113
Figure 6. 6 : Matrice de confusion pour les résultats CNN du foie segmenté.....	114
Figure 6. 7 : Matrice de confusion pour les résultats CNN foie complet.....	114

LISTE DES TABLEAUX

Tableau 4. 1 : L'estimation des valeurs Min et Max dans l'algorithme GMM	59
Tableau 5. 1 : Les spécifications matérielles du cluster de calcul haute performance (HPC-UB2) de l'Université de Batna 2	84
Tableau 5. 2 : Résultats de la segmentation du foie par différentes architectures avec de la base de données ACC-BATNA2022	87
Tableau 5. 3 : Résultats de la segmentation des tumeurs hépatiques sur des images CT complètes à l'aide de différentes architectures, issues de la base de données ACC-BATNA2022.....	90
Tableau 5. 4 : Résultats de la segmentation des tumeurs hépatiques à partir des images du foie segmenté, obtenus par différentes architectures sur la base de données ACC-BATNA2022.....	92
Tableau 5. 5 : Résultats de la segmentation du foie et des tumeurs hépatiques par différentes architectures sur la base de données LiTS2017	96
Tableau 6. 1 : Tableau des résultats CNN.....	110

Introduction générale

Introduction générale :

- **Contexte et cadre de recherche**

Ces dernières années, la propagation du cancer sous toutes ses variantes est devenue une préoccupation majeure de la santé humaine. En particulier, le cancer du foie est abordé dans cette thèse. Le cancer du foie est présent dans tous les groupes d'âge, qu'il s'agisse d'hommes ou de femmes, dans des proportions variables et en constante augmentation, comme le confirment plusieurs recherches scientifiques, médicales et statistiques, qui attestent également de sa détection à des étapes tardives.

En Algérie, l'impact des maladies du foie, en particulier le cancer du foie, est assez important en termes de nombre de patients, qui augmente chaque année, et en termes de coût lourd pour le patient, du diagnostic au traitement, ce qui, dans bien des cas, conduit à la mort, soit en raison d'une détection tardive de la maladie, soit à cause d'erreurs de diagnostic.

Pour prévenir les traitements complexes, diminuer les décès et prévenir les erreurs de diagnostic dans le cancer du foie, nous devons détecter la maladie à un stade précoce afin de trouver de meilleures solutions pour son traitement. Parmi les suggestions existantes, on peut citer un examen général du corps après un certain âge et de manière périodique. Quant aux types d'imagerie médicale les plus appropriés pour le cancer du foie, il s'agit de la tomodensitométrie (CT) et de l'imagerie par résonance magnétique (IRM).

La compréhension des images médicales du foie est une tâche très difficile pour les radiologues, car il s'agit d'un examen répétitif qui exige beaucoup de précision et d'attention. La grande variabilité des tumeurs, notamment en termes de forme et de taille, peut entraîner des biopsies et des traitements inutiles, ou la perte d'échantillons dans le cas de tumeurs malignes.

Par conséquent, ces dernières années, le développement de méthodes semi-automatiques ou automatiques pour traiter les images médicales du foie afin d'augmenter la précision du diagnostic et de fournir des informations plus utiles au radiologue, ainsi que de diminuer le nombre d'erreurs possibles, a donné lieu à la mise au point de systèmes de détection et de diagnostic assistés par ordinateur, sur lesquels porte notre thèse.

Organisation de la thèse :

La thèse a été organisée en six chapitres. Le premier chapitre présente un concept général du cancer du foie, ses types, les moyens techniques utilisés pour le découvrir, et les raisons qui nous ont poussés à faire cette thèse.

Dans le deuxième chapitre, nous avons pris connaissance de toutes les études antérieures

qui ont réalisé la même étude que la nôtre, mais de manière différente, avec une indication de leurs méthodes et une explication brève, afin de clarifier l'importance de notre étude et de prouver qu'elle est toujours d'actualité.

Quant au troisième chapitre, nous expliquons le diagnostic assisté par ordinateur, que nous avons préparé en détail, à partir de la prise des images par le radiologue jusqu'à l'obtention du résultat final, représenté dans la segmentation automatisée du foie et des tumeurs hépatiques au moyen d'apprentissage profond, en utilisant notre propre base de données ACC-BATNA 2022 et la base de données LITS2017, comme nous l'avons déjà mentionné dans ce chapitre.

Dans le quatrième chapitre, nous discutons des différentes méthodes que nous avons utilisées pour obtenir notre base de données, grâce à des méthodes d'apprentissage machine, après avoir effectué le prétraitement des images.

Dans le cinquième chapitre, nous avons montré comment nous pouvons classifier le foie normal et le cancer du foie par la méthode de classification CNN, avec présentation de tous les résultats.

Dans le sixième chapitre, qui est le fruit de tout notre travail, il s'agit d'une explication du travail que nous avons fait, à savoir la création de deux nouveaux modèles de segmentation des tumeurs du foie par l'apprentissage profond, à savoir DDA_UNET et ASD_UNET. Ensuite, nous les comparons avec plusieurs modèles précédents, tels que UNET, UNET++, ASU_NET, avec les résultats expliqués et bien analysés.

- **Contribution**

Bien que la multiplicité des modèles d'apprentissage **profond** vise à aider le radiologue à obtenir une grande précision dans la segmentation et la classification, notamment en ce qui concerne les frontières des tumeurs qui ne sont pas visibles à l'œil nu, et qui seront visibles dans les images CT ultérieures, cela **représente** un problème pour le patient et le radiologue.

Notre thèse vise à identifier des modèles plus précis dans l'extraction des contours du foie et des tumeurs du foie, dans le but de réduire les responsabilités du radiologue, notamment vis-à-vis de l'augmentation de la taille de la tumeur, notamment dans certains cas qui ne peuvent pas être observés par le spécialiste.

Dans un premier temps, nous traitons les images afin que nous puissions remarquer tous les éléments anormaux sur les images CT du foie, aussi petits soient-ils, afin de faciliter leur division, de connaître leur taille et l'étendue de leur dangerosité. Il est même possible de savoir s'il s'agit de tumeurs bénignes ou malignes. Cependant, dans notre thèse, nous avons examiné une partie limitée de ces problèmes, à savoir la classification, la segmentation et l'extraction des

tumeurs du foie, en mettant en évidence leurs limites de manière claire par rapport à des modèles de recherche précédents.

Partie 01 : Concepts de base et état de l'art

Chapitre 1 : CANCER DU FOIE

1.1 Introduction

Le dépistage précoce du cancer du foie constitue un facteur déterminant pour améliorer le pronostic vital des patients et augmenter considérablement leurs chances de survie. Détectée à un stade initial, la maladie peut être traitée plus efficacement grâce aux progrès thérapeutiques récents, tels que la chirurgie, la chimiothérapie ou encore les thérapies ciblées. Parallèlement, la prévention occupe une place essentielle : elle repose sur l'adoption d'un mode de vie sain, la réduction des facteurs de risque connus, ainsi que la réalisation d'exams médicaux réguliers, en particulier pour les personnes présentant une prédisposition ou des antécédents familiaux [1].

Dans ce chapitre, nous nous intéressons spécifiquement au cancer du foie et aux outils permettant d'améliorer sa détection et sa prise en charge. Plus précisément, nous analysons le rôle croissant des techniques d'imagerie médicale combinées aux approches d'apprentissage profond et d'apprentissage automatique, qui offrent des solutions performantes pour assister les radiologues dans la classification et la segmentation des images, notamment celles issues de la tomodensitométrie.

1.1.1 Épidémiologie et importance clinique

Le cancer du foie, et en particulier le carcinome hépatocellulaire (CHC), représente la sixième cause de cancer dans le monde et la troisième cause de mortalité par cancer. Selon les données de l'Organisation mondiale de la santé (OMS), plus de 800 000 nouveaux cas sont diagnostiqués chaque année, avec une incidence particulièrement élevée en Asie et en Afrique subsaharienne [1]. Cette répartition géographique est fortement liée aux taux de prévalence des infections chroniques par les virus de l'hépatite B (VHB) et de l'hépatite C (VHC), qui constituent les principaux facteurs étiologiques.

1.1.2 Facteurs de risque et causes

Le développement du cancer du foie résulte souvent d'une combinaison de facteurs de risque, parmi lesquels :

- ☞ Les infections virales chroniques (VHB, VHC), qui provoquent une inflammation persistante du foie et favorisent la cirrhose.
- ☞ La cirrhose hépatique, quelle qu'en soit la cause (alcool, maladies métaboliques, stéatohépatite non alcoolique).
- ☞ Les toxines alimentaires, notamment les aflatoxines produites par certaines moisissures.

- ☞ Les facteurs génétiques et métaboliques, tels que l'hémochromatose ou la maladie de Wilson.
- ☞ Le mode de vie, incluant la consommation excessive d'alcool, l'obésité et le diabète, qui augmentent le risque de stéatose hépatique sévère et de transformation maligne.

1.1.3 Prévention et dépistage

La prévention du cancer du foie repose sur plusieurs stratégies :

- ☞ La vaccination contre l'hépatite B, qui a prouvé son efficacité dans la réduction de l'incidence du CHC.
- ☞ Le dépistage régulier chez les patients à haut risque (cirrhose, infection chronique par VHB ou VHC) par échographie semestrielle, associée parfois au dosage de l'alpha-foetoprotéine (AFP).
- ☞ La réduction des comportements à risque, notamment la consommation excessive d'alcool et l'exposition aux toxines alimentaires.

Ces mesures visent à identifier la maladie à un stade précoce, moment où les options thérapeutiques curatives (chirurgie, ablation locale, transplantation hépatique) sont les plus efficaces.

1.2 Cancer du foie et ses types

Parmi les pathologies cancéreuses les plus fréquentes figure le cancer du foie, qui représente une menace majeure pour la santé du patient. Cette maladie est particulièrement dangereuse, avec un taux de mortalité élevé, et peut résulter de multiples causes et se présenter sous différentes formes.

Le cancer du foie se divise généralement en deux grandes catégories :

- ☞ Le cancer primaire, qui prend naissance directement dans le tissu hépatique.
- ☞ Le cancer secondaire, qui correspond à des métastases provenant d'autres organes.

On distingue également :

- ☞ Les tumeurs bénignes, telles que le kyste simple ou l'hémangiome hépatique, généralement asymptomatiques et ne nécessitant qu'une surveillance médicale.
- ☞ Les tumeurs malignes, dont la plus courante est le carcinome hépatocellulaire (CHC), souvent associé à une évolution agressive et à un pronostic réservé.

Dans un foie sain, les fonctions physiologiques essentielles, notamment la filtration et la distribution du sang, se déroulent normalement. En revanche, la présence de tissus cancéreux perturbe considérablement ces mécanismes. Heureusement, les avancées, en imagerie médicale,

permettent de détecter et de caractériser ces anomalies. Les principales modalités utilisées sont la tomodensitométrie (CT), l'imagerie par résonance magnétique (IRM) et l'échographie, qui jouent un rôle central dans le diagnostic et le suivi des patients.

Dans cette partie, nous présenterons les tumeurs hépatiques, en distinguant les formes bénignes et malignes, ainsi que les cancers primaires et secondaires.

1. Tumeurs bénignes

A. Les hémangiomes

L'hémangiome hépatique est la tumeur bénigne la plus fréquente du foie. Il se développe à partir des vaisseaux sanguins hépatiques et reste, dans la majorité des cas, de petite taille et asymptomatique. Cependant, dans certaines situations, il peut croître et provoquer des douleurs abdominales, des nausées ou d'autres complications cliniques.

Le traitement dépend de la taille et de la localisation de la tumeur. Dans la plupart des cas, une simple surveillance suffit. Toutefois, en cas de symptômes persistants ou de croissance rapide, une prise en charge plus active peut être envisagée, incluant des traitements médicamenteux ou une intervention chirurgicale. Dans de rares cas, une rupture de l'hémangiome peut entraîner une hémorragie interne grave, parfois fatale, ce qui justifie la nécessité d'un suivi médical régulier.

Globalement, l'hémangiome hépatique est une affection bénigne et contrôlable, voir Figure 1.1. Grâce à un suivi adapté, associé aux examens d'imagerie, les patients peuvent mener une vie normale et limiter les risques de complications. La collaboration étroite avec les professionnels de santé permet d'assurer une gestion efficace de la maladie et d'optimiser le choix thérapeutique en fonction de l'évolution clinique [3].




Figure 1. 1 : Les hémangiomes

B. Les adénomes hépatiques

L'adénome hépatique est une tumeur bénigne du foie, souvent associée à des facteurs hormonaux (comme l'utilisation prolongée de contraceptifs oraux). Son évolution dépend principalement de la taille et des symptômes présentés. Dans les cas asymptomatiques et de petite taille, une simple surveillance régulière est généralement suffisante. En revanche, lorsque la tumeur devient volumineuse ou entraîne des douleurs abdominales, un traitement chirurgical peut être nécessaire afin de prévenir le risque de rupture ou d'hémorragie interne.

L'imagerie médicale, en particulier l'échographie et l'IRM, est couramment utilisée pour suivre l'évolution des adénomes hépatiques et détecter tout changement suspect. Dans certains cas, une biopsie peut être requise afin de confirmer le diagnostic. Globalement, la prise en charge des adénomes repose sur une approche individualisée, adaptée à la taille, aux symptômes et aux risques de complications.

C. L'hyperplasie nodulaire focale (FNH)

L'hyperplasie nodulaire focale (FNH) est une autre lésion bénigne du foie, caractérisée par la présence de nodules d'hépatocytes entourés de tissu fibreux. Ces nodules, bien circonscrits et généralement de petite taille, se distinguent des tumeurs malignes ou des adénomes. La FNH est le plus souvent asymptomatique et découverte fortuitement lors d'examens d'imagerie réalisés pour d'autres raisons.

Dans la majorité des cas, la FNH ne nécessite aucun traitement spécifique. Toutefois, une intervention chirurgicale peut être envisagée si la lésion devient symptomatique ou montre une progression inhabituelle. Compte tenu de son très faible potentiel de transformation maligne, une surveillance prudente constitue généralement l'approche la plus appropriée. Le pronostic des patients atteints de FNH est excellent, la plupart des lésions restant stables, voire régressant spontanément au fil du temps.


2. Tumeurs malignes

A. Le carcinome hépatocellulaire (CHC)


Le carcinome hépatocellulaire (CHC) est le cancer du foie le plus fréquent. Il survient le plus souvent chez les patients atteints de maladies chroniques du foie, notamment la cirrhose ou les hépatites virales B et C. Cliniquement, il peut se manifester par une douleur abdominale, une perte de poids inexpliquée, un ictère (jaunisse) ou encore une ascite (gonflement de l'abdomen).

Le diagnostic repose sur des examens d'imagerie (échographie, CT-scan, IRM) associés

à des analyses sanguines (comme le dosage de l'alpha-foetoprotéine) (voir Figure 1.2). Le traitement du CHC peut inclure la chirurgie, la transplantation hépatique, la chimiothérapie, ainsi que des thérapies ciblées. La détection précoce est essentielle pour améliorer le pronostic et accroître les chances de survie des patients.



Axial C+ Portal Venous Phase CT



Coronal C+ Portal Venous Phase CT

Figure 1. 2 : Le carcinome hépatocellulaire


B. Le carcinome fibrolamellaire

Le carcinome fibrolamellaire est une forme rare de cancer hépatique, touchant principalement les jeunes adultes. Contrairement au CHC, il n'est généralement pas associé à une maladie hépatique sous-jacente comme la cirrhose. Cette tumeur se caractérise par une histologie particulière et par la présence de masses volumineuses.

Les symptômes incluent des douleurs abdominales, une perte de poids et la jaunisse. Le diagnostic repose sur l'imagerie et la biopsie. La chirurgie constitue le traitement de première intention, tandis que la chimiothérapie et la radiothérapie peuvent être utilisées en complément. Un suivi régulier est indispensable pour surveiller les risques de récurrence [3].

C. Le cholangiocarcinome (cancer des voies biliaires)

Le cholangiocarcinome est un cancer rare qui se développe dans les voies biliaires intra ou extra-hépatiques (voir Figure 1.3). Son diagnostic est difficile aux stades précoces, ce qui explique son pronostic souvent défavorable.



Axial C+ Arterial Phase CT



Axial C+Portal Venous Phase CT

Figure 1. 3 : Le carcinome hépatocellulaire

Les principaux facteurs de risque incluent l'inflammation chronique des voies biliaires, certaines infections parasitaires, ainsi que la cholangite sclérosante primitive. Le traitement repose sur la chirurgie, la chimiothérapie ou la radiothérapie, selon le stade et la localisation de la tumeur. Des recherches sont actuellement en cours pour développer de nouvelles thérapies ciblées visant à améliorer la survie des patients atteints de ce cancer agressif [3].

3. Les cancers secondaires (métastatiques)

Les cancers secondaires du foie, ou métastases hépatiques, sont beaucoup plus fréquents que les cancers primitifs. Ils proviennent généralement de cancers situés dans d'autres organes, comme le côlon, le pancréas, l'estomac, les poumons, le sein ou le rein. Ces métastases peuvent se propager par voie sanguine ou via le système lymphatique.

Leur prise en charge est complexe et vise principalement à ralentir l'évolution de la maladie, améliorer la qualité de vie et soulager les symptômes. Les options thérapeutiques incluent la chirurgie, la chimiothérapie, la radiothérapie, les thérapies ciblées ou une combinaison de ces approches.

Un suivi régulier par imagerie (CT, IRM, échographie), analyses sanguines et parfois biopsies est indispensable pour détecter rapidement les récurrences ou l'apparition de nouvelles lésions. Les avancées récentes en recherche médicale et en technologies thérapeutiques contribuent à améliorer la survie et le bien-être des patients atteints de cancers secondaires du foie [3].

1.3 Techniques d'imagerie médicale pour le diagnostic du cancer du foie

Le cancer du foie, également appelé carcinome hépatocellulaire (CHC), est une pathologie grave dont le diagnostic précoce conditionne fortement le succès thérapeutique et l'amélioration du pronostic vital. Les techniques d'imagerie médicale occupent une place centrale dans ce processus, notamment l'échographie, la tomodensitométrie (CT), l'imagerie par résonance magnétique (IRM) et la tomographie par émission de positons (TEP). Ces méthodes permettent de détecter les tumeurs, d'évaluer leur taille, leur localisation et leur extension, et fournissent aux cliniciens des informations précieuses pour orienter les choix thérapeutiques.

La détection précoce par imagerie favorise la mise en œuvre de stratégies de traitement plus efficaces et améliore les chances de survie des patients. L'imagerie joue également un rôle clé dans le suivi de l'évolution de la maladie, l'évaluation de la réponse thérapeutique et l'identification de complications ou de métastases secondaires [4].

1.3.1 L'imagerie par ultrasons

L'échographie est une technique de première intention dans le diagnostic du cancer du foie. Elle repose sur l'utilisation d'ondes sonores à haute fréquence qui génèrent, par réflexion, des images en temps réel des tissus hépatiques. Méthode non invasive, indolore et dépourvue de radiation ionisante, elle permet d'identifier rapidement des masses suspectes et de guider des procédures comme la biopsie.

L'échographie est particulièrement utile pour surveiller la taille et la progression des tumeurs hépatiques. Toutefois, elle présente certaines limites, notamment la difficulté à détecter de très petites lésions ou des tumeurs profondes. De plus, des facteurs tels que l'obésité ou la présence de gaz intestinaux peuvent compromettre la qualité des images. Dans ces cas, des techniques complémentaires comme la CT ou l'IRM sont nécessaires pour une évaluation plus précise.

1.3.2 La tomodensitométrie (CT)

La tomodensitométrie fournit des images en coupe fine et très détaillées du foie, ce qui permet de détecter des lésions de petite taille et de déterminer le stade tumoral (voir Figure 1.4). Cette technique repose sur une série de radiographies prises sous différents angles, ensuite reconstruites par ordinateur en images transversales. L'injection d'un produit de contraste améliore la visualisation des structures vasculaires et des anomalies.



Figure 1. 4 : Diagnostic à l'aide d'un scanner CT

La CT est particulièrement efficace pour évaluer l'extension locale et métastatique du cancer, contribuant ainsi à la planification thérapeutique. Bien qu'indolore et relativement rapide (moins de 30 minutes), elle présente certains inconvénients : exposition aux radiations,

risque d'allergie au produit de contraste, et possibilité de néphrotoxicité chez les patients insuffisants rénaux. Néanmoins, les bénéfices d'un diagnostic précis et d'une détection précoce l'emportent largement sur ces risques [4].

1.3.3 L'imagerie par résonance magnétique (IRM)

L'IRM utilise un champ magnétique puissant et des ondes radio pour générer des images très détaillées du foie et des tissus environnants, sans recours aux radiations ionisantes. Elle se distingue par sa capacité à fournir une excellente caractérisation tissulaire, permettant de différencier une tumeur bénigne d'une tumeur maligne avec une grande précision.

L'IRM est particulièrement utile pour la détection précoce des tumeurs, le suivi de l'évolution de la maladie et l'évaluation de l'efficacité des traitements. Cependant, elle n'est pas recommandée pour certains patients porteurs de dispositifs médicaux implantés (ex. stimulateurs cardiaques) ou souffrant de claustrophobie. L'accès limité aux appareils et le coût élevé peuvent également restreindre son utilisation dans certaines régions.

1.4 Imagerie médicale et intelligence artificielle dans le diagnostic du cancer du foie

L'imagerie médicale occupe une place centrale dans le dépistage, le diagnostic et le suivi thérapeutique du cancer du foie. Parmi les modalités les plus utilisées, la tomodensitométrie (TDM) et l'imagerie par résonance magnétique (IRM) sont considérées comme des outils de référence, offrant une visualisation détaillée de l'anatomie hépatique et permettant de détecter aussi bien les lésions primaires que les métastases. Toutefois, l'interprétation de ces images demeure un processus complexe et fortement dépendant de l'expertise du radiologue, ce qui peut entraîner une variabilité inter- et intra-observateur dans la détection et la classification des anomalies.

Au cours de la dernière décennie, l'émergence des approches d'intelligence artificielle, et plus particulièrement de l'apprentissage profond (Deep Learning) et de l'apprentissage automatique (Machine Learning), a considérablement transformé le domaine de l'imagerie médicale. Ces technologies permettent d'extraire automatiquement des caractéristiques discriminantes à partir des images, souvent invisibles à l'œil humain, afin d'améliorer la précision et la rapidité du diagnostic. Dans le cas du cancer du foie, elles offrent un apport considérable dans la segmentation des organes et des tumeurs, la classification des lésions bénignes et malignes, ainsi que dans la prédiction de la réponse thérapeutique.

Les réseaux de neurones convolutionnels (CNN), en particulier, se sont imposés comme des architectures de pointe pour l'analyse des images médicales. Appliqués aux données issues

de la TDM, ils permettent une segmentation automatique du foie et de ses lésions avec une précision proche, voire supérieure, à celle des experts humains. De plus, les modèles avancés tels que U-Net, DenseNet, ou encore leurs variantes enrichies de modules d'attention ou de mécanismes multi-échelles, se sont révélés particulièrement efficaces pour capturer la complexité morphologique des tumeurs hépatiques.

L'intégration de ces approches dans la pratique clinique vise à assister les radiologues plutôt qu'à les remplacer. Les systèmes basés sur l'intelligence artificielle agissent comme des outils d'aide à la décision, réduisant le temps nécessaire à l'analyse des images tout en minimisant les risques d'erreurs diagnostiques. Cette synergie entre expertise humaine et puissance computationnelle ouvre la voie à une médecine plus personnalisée et plus prédictive, où chaque patient bénéficie d'un suivi adapté à ses caractéristiques cliniques et radiologiques.

En conclusion, l'association de l'imagerie médicale et des techniques d'apprentissage profond et automatique constitue une avancée majeure dans la lutte contre le cancer du foie. Elle favorise un dépistage plus précoce, une classification plus fiable des lésions et une meilleure planification thérapeutique, contribuant ainsi à améliorer le pronostic vital des patients.

1.5 Conclusion

Le cancer du foie constitue une pathologie complexe et multifactorielle, marquée par une forte hétérogénéité clinique et biologique. Son dépistage précoce et sa prise en charge reposent en grande partie sur l'imagerie médicale, qui offre des outils puissants pour détecter, caractériser et suivre l'évolution des lésions hépatiques. Dans la perspective de cette thèse, l'intégration de l'intelligence artificielle et de l'apprentissage profond dans l'analyse des images médicales apparaît comme une approche prometteuse pour améliorer la précision du diagnostic et soutenir les décisions cliniques.

Chapitre 2 : Concepts fondamentaux et méthodes de segmentation des images médicales

2.1 Introduction

La segmentation précise des tumeurs constitue une étape cruciale dans le diagnostic clinique, car elle permet aux médecins d'analyser et d'interpréter plus efficacement les images issues des examens médicaux (IRM, scanner, échographie, etc.). Au cours de la dernière décennie, la segmentation assistée par ordinateur des images médicales a suscité un intérêt croissant en raison de sa rapidité, de son efficacité et de sa capacité à améliorer l'exactitude des décisions médicales.

Historiquement, les méthodes classiques de segmentation reposaient principalement sur la détection de caractéristiques et l'utilisation de classificateurs. Ces approches, bien qu'efficaces dans certaines situations, présentaient des limites face à la complexité des images médicales, souvent bruitées et présentant des structures anatomiques variées.

Dans ce chapitre, nous présentons un panorama des méthodes de segmentation utilisées dans les travaux antérieurs, allant des approches traditionnelles aux techniques modernes basées sur l'apprentissage profond. Nous débutons par l'examen des méthodes classiques, parmi lesquelles :

- Les approches basées sur les régions,
- Les approches basées sur les contours,
- La segmentation par seuillage (Thresholding).

Ensuite, nous analysons les méthodes de segmentation fondées sur l'apprentissage machine, avant de nous concentrer sur les approches d'apprentissage profond, incluant les architectures les plus utilisées dans le domaine biomédical, telles que **U-Net**, **U-Net++**, **ASU-Net**, **FCN** et **CNN**.

2.1.1 La segmentation basée sur les régions

L'approche par régions consiste à regrouper directement les pixels présentant des caractéristiques similaires, puis à fusionner les zones voisines répondant à un critère d'uniformité. Cette méthode exploite des propriétés locales comme l'intensité, la texture ou la couleur, pour créer des régions homogènes.

La technique la plus utilisée est la croissance de régions (Region Growing). Elle débute par la sélection d'un ou plusieurs pixels appelés *germes*, puis ajoute progressivement les pixels voisins dont les caractéristiques sont jugées similaires selon une mesure de distance ou de similarité. Sur le plan mathématique, le critère d'appartenance d'un pixel p à une région R peut être défini par :

$$\mu(R) - \delta \leq g(p) \leq \mu(R) + \delta \quad (1)$$

Où :

- $g(p)$ Représente l'intensité du pixel p ,
- $\mu(R)$ Est la moyenne d'intensité de la région R ,
- δ Est un seuil de tolérance.

Ainsi, un pixel est inclus dans une région si son intensité se situe dans un intervalle acceptable autour de la moyenne de la région en cours de croissance.

A. La croissance de région

La croissance de région (*Region Growing*) est une approche itérative consistant à choisir un ou plusieurs *germes* (pixels de départ), puis à ajouter progressivement les pixels voisins qui satisfont un critère de similarité.

Un pixel p est ajouté à la région R si :

$$|I(p) - \mu_R| \leq \delta \quad (2)$$

Où :

- $I(p)$ Est l'intensité du pixel,
- μ_R Est l'intensité moyenne de la région courante,
- δ Est un seuil de tolérance.

B. La division et la fusion de régions

Une autre famille de méthodes repose sur la stratégie quadtree :

- On divise récursivement l'image en sous-régions jusqu'à ce qu'un critère d'homogénéité soit vérifié.
- Si deux régions voisines satisfont un critère de similarité, elles sont fusionnées.

Cette approche permet une segmentation hiérarchique et adaptative.

C. Les applications en imagerie médicale

Les méthodes basées sur les régions ont été largement utilisées en imagerie médicale :

- Adams et Bischof (1994) ont introduit un algorithme efficace de croissance de région,
- Beucher (1992) a développé des approches de segmentation hiérarchique par régions,
- Vincken et al. (1995) ont appliqué des techniques de fusion de régions en segmentation d'IRM.

Elles sont particulièrement utiles pour la segmentation d'organes présentant une homogénéité relative, comme le foie ou les reins. Toutefois, elles sont sensibles au bruit et au

choix des germes, ce qui peut entraîner une sur-segmentation.

2.1.2 La segmentation basée sur les contours

Les méthodes basées sur les contours exploitent les discontinuités d'intensité pour détecter les limites des objets dans une image. Elles reposent principalement sur le calcul du gradient, qui met en évidence les zones de transition rapide entre des régions homogènes.

Une formulation classique repose sur le calcul du gradient d'une image $I(x,y)$, défini comme :

$$\nabla I = \begin{pmatrix} \frac{\partial I}{\partial x} \\ \frac{\partial I}{\partial y} \end{pmatrix} \quad (3)$$

La magnitude du gradient est alors :

$$|\nabla I| = \sqrt{\left(\frac{\partial I}{\partial x}\right)^2 + \left(\frac{\partial I}{\partial y}\right)^2} \quad (4)$$

Un contour correspond donc à une zone où la magnitude du gradient est élevée.

A. Les contours actifs (*Snakes*)

Parmi les méthodes les plus connues, on retrouve les contours actifs (*Active Contours Models* ou *Snakes*). Ils consistent à faire évoluer une courbe initiale placée autour de l'objet d'intérêt, de manière à ce qu'elle se rapproche progressivement des véritables frontières de l'objet.

L'évolution de cette courbe est guidée par une fonction d'énergie à minimiser :

$$E_{snake} = \int [E_{int}(v(s)) + E_{ext}(v(s))] ds \quad (5)$$

Où :

- $v(s)$ est la représentation paramétrique de la courbe,
- E_{int} correspond à l'énergie interne qui contrôle la continuité et la régularité de la courbe,
- E_{ext} représente l'énergie externe, issue des caractéristiques de l'image (comme les contours détectés par le gradient).

Pour améliorer la capture des bords complexes, Xu et Prince (1997) ont proposé les Gradient Vector Flow (GVF) Snakes, qui étendent le champ d'attraction du contour actif et facilitent la convergence vers les limites réelles de l'objet.

B. Les applications en imagerie médicale

Les contours actifs ont été appliqués avec succès à de nombreux problèmes de segmentation en imagerie médicale, notamment :

- La segmentation des masses mammaires (Jumaat et al., 2010),
- La segmentation du ventricule gauche dans les séquences scintigraphiques (Khalifa et al., 2005),
- La délimitation automatique du foie sur IRM (Daniau-Clavreul et al., 2005).

Ces méthodes présentent cependant des limites, notamment leur sensibilité aux conditions initiales et au bruit de l'image. Malgré cela, elles restent des approches de référence dans le domaine de la segmentation médicale.

2.1.3 La segmentation par seuillage

La segmentation par seuillage est l'une des méthodes les plus simples et largement utilisées pour distinguer les objets d'intérêt du fond dans une image. Elle repose sur l'hypothèse que les régions de l'image présentent des niveaux de gris significativement différents. Ainsi, en fixant une valeur de seuil T , il est possible de séparer automatiquement les pixels en deux classes :

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) \geq T \\ 0 & \text{si } f(x, y) < T \end{cases} \quad (6)$$

Où :

- $f(x, y)$ est l'intensité du pixel de l'image originale,
- $g(x, y)$ est l'image binaire segmentée,
- T est le seuil.

A. Le seuillage global

Dans le cas d'images présentant une répartition bimodale des niveaux de gris, le seuillage global consiste à choisir un seuil unique T qui sépare les deux classes.

La méthode d'Otsu (1979) est l'approche la plus connue : elle choisit le seuil T qui maximise la variance inter-classes tout en minimisant la variance intra-classe.

La fonction objective est donnée par :

$$\sigma_B^2(T) = \omega_1(T) \omega_2(T) [\mu_1(T) - \mu_2(T)]^2 \quad (7)$$

où :

- ω_1, ω_2 Représentent les probabilités de chaque classe,

- μ_1, μ_2 les moyennes de chaque classe.

Le seuil optimal est donc :

$$T T^* = \arg \max(T) \sigma_B^2(T) \quad (8)$$

B. Le seuillage adaptatif

Pour les images médicales hétérogènes ou bruitées, un seuillage local ou adaptatif est préférable. Il consiste à calculer un seuil $T(x, y)$ variable selon une région locale, ce qui permet de mieux gérer les variations d'éclairage et de contraste.

C. Applications en imagerie médicale

Les méthodes de seuillage sont largement utilisées en raison de leur simplicité et de leur rapidité. Par exemple :

- Otsu (1979) a été largement utilisé pour la segmentation des images biomédicales,
- Palumbo et al. (1990) l'ont appliqué pour la segmentation des images de documents médicaux,
- Sahoo et al. (1988) ont réalisé une revue exhaustive des techniques de seuillage en imagerie.

Cependant, ces méthodes montrent des limites face aux images médicales présentant du bruit, des artefacts ou des contrastes faibles, ce qui a motivé le développement d'approches plus avancées (régions, contours, réseaux de neurones).

2.1.4 La segmentation hybride et les approches avancées

Aucune méthode de segmentation ne peut, à elle seule, répondre efficacement à l'ensemble des contraintes liées à l'imagerie médicale : bruit, faible contraste, artefacts ou variabilité anatomique entre patients. Pour cette raison, les chercheurs ont développé des méthodes hybrides, combinant les avantages de plusieurs approches, ainsi que des techniques avancées reposant sur des concepts plus récents comme la théorie des graphes ou l'apprentissage profond.

A. Les Méthodes hybrides

Les méthodes hybrides visent à compenser les limites d'une approche par les atouts d'une autre. Par exemple :

- La combinaison du seuillage et de la croissance de région améliore la robustesse face aux variations d'intensité,
- L'intégration des contours actifs avec le seuillage permet de mieux délimiter les

structures anatomiques complexes,

- L'utilisation des ondes de morphologie mathématique en complément du seuillage améliore la suppression du bruit (Serra, 1982).

Un exemple classique est l'approche dite de Watershed contrôlée, qui combine les contours et les régions. L'image est considérée comme une surface topographique où l'eau remplit les bassins. Le problème de sur-segmentation est résolu en imposant des marqueurs.

A. La segmentation par graphes

Une autre catégorie avancée repose sur la théorie des graphes. L'image est modélisée sous forme de graphe $G = (V, E)$, où :

- V représente les pixels (ou super-pixels),
- E représente les arêtes pondérées selon une mesure de similarité (intensité, distance, texture).

La segmentation consiste alors à trouver une partition optimale du graphe. L'algorithme Normalized Cuts (Shi & Malik, 2000), par exemple, cherche à minimiser la coupe normalisée :

$$N_{cut}(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)} \text{ où :} \quad (9)$$

- $cut(A, B)$ est la somme des poids des arêtes reliant A et B ,
- $assoc(A, V)$ et $assoc(B, V)$ sont les sommes des poids des arêtes reliant A et B à l'ensemble V .

B. L'apprentissage profond et la segmentation moderne

Les réseaux de neurones convolutionnels (CNN) et leurs variantes ont profondément transformé la segmentation médicale.

- U-Net (Ronneberger et al., 2015) constitue l'architecture la plus influente pour la segmentation biomédicale. Elle utilise un schéma en U avec encodeur et décodeur symétriques.
- Des extensions comme U-Net++ (Zhou et al., 2018) ou Attention U-Net (Oktay et al., 2018) intègrent des connexions denses et des mécanismes d'attention pour améliorer la précision.
- L'intégration des modules de type ASPP (Atrous Spatial Pyramid Pooling), comme dans DeepLabV3+ (Chen et al., 2018), permet de capturer des contextes multi-échelles, essentiels pour la segmentation des structures complexes comme les tumeurs.

D. Applications en imagerie médicale

- Les méthodes hybrides comme Watershed avec marqueurs sont utilisées pour la segmentation du cerveau (Beucher & Meyer, 1993).
- Les méthodes par graphes comme Normalized Cuts ont été appliquées en segmentation d'IRM cérébrale.
- Les approches basées sur U-Net et ses variantes sont devenues l'état de l'art dans la segmentation d'organes (foie, poumons, cœur) et de lésions (tumeurs, nodules pulmonaires).

2.2 Conclusion

Dans ce chapitre, nous avons présenté les principales approches de segmentation appliquées à l'imagerie médicale, en particulier dans le cadre du dépistage et du suivi du cancer du foie.

Nous avons d'abord examiné les méthodes classiques :

- Les techniques basées sur les contours, qui exploitent les discontinuités d'intensité et ont donné naissance aux modèles actifs comme les *Snakes* et leurs extensions (GVF).
- Les méthodes de seuillage, simples et rapides, avec en particulier l'approche d'Otsu, bien adaptée aux images présentant des distributions bimodales.
- Les approches basées sur les régions, qui regroupent les pixels homogènes selon des critères de similarité, avec des stratégies comme la croissance de région ou la division-fusion.

Nous avons ensuite abordé les méthodes hybrides et avancées, qui tentent de surmonter les limites des approches classiques :

- Les méthodes hybrides combinant seuillage, régions et contours pour obtenir une segmentation plus robuste.
- Les approches basées sur la théorie des graphes (comme *Normalized Cuts*), capables de modéliser la segmentation comme une optimisation globale.
- Enfin, les méthodes modernes issues de l'apprentissage profond, avec des architectures comme U-Net, U-Net++ et DeepLabV3+, qui ont profondément transformé la segmentation médicale grâce à leur capacité à apprendre automatiquement des représentations complexes et multi-échelles.

Ces évolutions montrent une progression naturelle des techniques, allant des méthodes simples et rapides aux approches sophistiquées et puissantes basées sur l'IA. La segmentation est ainsi devenue un outil essentiel pour assister les radiologues dans la détection, la classification et la caractérisation des lésions hépatiques.

Partie 02 : Contributions et validation

**Chapitre 3 : DIAGNOSTIC ASSISTÉ
PAR ORDINATEUR DANS LA
SEGMENTATION DES TUMEURS
HÉPATIQUES**

3.1. Introduction

Les tumeurs hépatiques, qu'elles soient primaires (carcinome hépatocellulaire) ou secondaires (métastases), constituent l'une des principales causes de mortalité par cancer à l'échelle mondiale. Leur détection repose principalement sur les techniques d'imagerie médicale telles que la tomodensitométrie (CT) et l'imagerie par résonance magnétique (IRM). Ces méthodes se sont considérablement développées et sont devenues incontournables pour la détection précoce et la segmentation des lésions hépatiques, offrant ainsi une aide précieuse aux cliniciens.

L'objectif de ce chapitre est de présenter le rôle des systèmes de diagnostic assisté par ordinateur (CAD – Computer-Aided Diagnosis) appliqués à la segmentation des tumeurs hépatiques. Ces systèmes permettent :

- De réduire les erreurs médicales,
- D'accélérer le processus diagnostique,
- Et d'améliorer la précision dans l'estimation de la taille, de la forme et du type de la tumeur.

Grâce à l'apprentissage automatique et à l'apprentissage profond, il est désormais possible d'effectuer une segmentation automatique des tumeurs et d'extraire diverses caractéristiques à partir d'images médicales en 2D et 3D. Ces informations quantitatives (longueur, largeur, volume, contours) constituent des éléments essentiels pour établir un diagnostic fiable et personnalisé.

3.2. Acquisition d'images par le radiologue

L'objectif ici est de réduire les erreurs médicales liées au diagnostic ainsi que son accélération afin qu'il soit plus précis, nous effectuons ici une segmentation automatique de la lésion ou de la tumeur par l'apprentissage automatique ou l'apprentissage profond afin d'être en mesure d'estimer avec précision la taille, la forme et le type de la tumeur, ce qui aide à un diagnostic correct et précis.

L'obtention des images médicales du centre de cancérologie est l'étape cruciale de cette thèse, et nous avons opté pour le Centre Anti Cancer de Batna, en Algérie. Dans le domaine de la radiologie, nous avons reçu des images médicales de nombreux patients, ce qui nous a permis d'obtenir une base de données préliminaire comprenant ces images médicales avec une extension « .DICOM » pour chaque individu.

Nous avons extrait les images de chaque fichier DICOM et les avons stockées avec une extension PNG, afin de préserver le maximum de caractéristiques et d'informations présentes

dans ces images, et chaque personne a un nombre différent d'images et ces images concernent le corps entier de la tête aux pieds, et nous avons choisi uniquement les images du foie pour les étudier dans le cadre de notre thèse.

3.3. Acquisition de base de données par la segmentation

La tomodensitométrie (CT) est utilisée par le radiologue pour produire des images médicales, qui sont ensuite stockées dans des logiciels spécialisés. Le rôle du radiologue est alors d'interpréter manuellement ces images et de poser un diagnostic. Bien que fiable, cette procédure est chronophage et exige une concentration extrême. Toute erreur d'interprétation ou omission peut entraîner des conséquences graves pour le patient.

Pour automatiser et optimiser ce processus, nous avons extrait les images CT du foie au format PNG, puis appliqué un prétraitement incluant des modèles statistiques tels que :

- Le modèle de Rayleigh,
- Le modèle de mélange gaussien (GMM), avant d'effectuer la segmentation proprement dite.

Ces étapes sont résumées dans la Figure 3.1 : Acquisition de la base de données.




Figure 3. 1 : Acquisition de la base de données

3.4. Méthodologie CAD dans la segmentation des tumeurs hépatiques

Un système CAD repose sur une chaîne de traitement allant de l'acquisition de l'image à la segmentation et, dans certains cas, à la classification. L'objectif est de fournir une aide décisionnelle objective au radiologue.

Dans le cas des tumeurs hépatiques, la segmentation manuelle est rendue complexe par : la diversité des tumeurs, leur morphologie irrégulière, et la présence de petites lésions difficiles à détecter.

Les systèmes CAD permettent donc de : Identifier la région d'intérêt (ROI), ici le foie, Segmenter le foie et isoler les zones suspectes, Extraire des caractéristiques quantitatives, et Classer les lésions selon leur nature.

Les Figures 3.2 et 3.3 illustrent les diagrammes de flux de notre système CAD appliqué au cancer du foie, en utilisant respectivement notre propre base de données et la base de données LiTS2017.




Figure 3. 2 : Diagramme de flux du système automatisé de création d'une base de données et de segmentation du cancer du foie et tumeurs hépatiques proposé.




Figure 3. 3 : Diagramme de flux du système automatisé de segmentation du cancer du foie et tumeurs hépatiques proposé avec la base de données Lits2017.

- **Étapes principales :**

- A. Acquisition d'images**

Des images CT validées par un radiologue ont été collectées, converties du format DICOM vers le format PNG, puis sélectionnées spécifiquement pour le foie (*Figure 3.4*).



Figure 3. 4 : Acquisition des images médicales du foie

- B. Segmentation du foie**

Le foie est segmenté automatiquement en appliquant des algorithmes comme le modèle de Rayleigh, permettant de séparer l'organe du reste du corps et de générer des masques du foie (*Figure 3.5*).




Figure 3. 5 : La segmentation du foie (a) image en niveaux de gris du foie (b) masque du foie

- C. Segmentation des carcinomes hépatique**

La même approche est appliquée aux tumeurs hépatiques afin de générer des masques précis des lésions (*Figure 3.6*).




Figure 3. 6 : La segmentation des tumeurs hépatiques du foie (a) L'image CT du foie (b) L'image en niveaux de gris du foie (c) Les masques des tumeurs hépatiques

D. Création d'une base de données interne

Notre propre base de données a été constituée en combinant les masques du foie et ceux des tumeurs hépatiques. Cette étape constitue un apport original de notre thèse, car elle permet de disposer d'annotations fiables adaptées à nos expérimentations.

E. Segmentation par apprentissage profond

Nous avons ensuite utilisé des modèles de segmentation avancés, notamment : **U-Net**, **U-Net++**, **ASU-Net**, **DDA-U-Net** et **ASD-U-Net**.

- Sur notre base interne, le modèle **DDA-U-Net** a donné les meilleurs résultats.
- Sur la base **LiTS2017**, comprenant 130 patients avec des annotations au format “.nii”, le modèle **ASD-U-Net** s'est montré supérieur, tant en précision qu'en robustesse (Figure 3.7).




Figure 3. 7 : La Base de données Lits2017(a) Image du foie (b) Masques des tumeurs hépatiques

3.5. Conclusion

Ce chapitre a mis en évidence l'importance du diagnostic assisté par ordinateur (CAD) dans la prise en charge du cancer du foie. Nous avons décrit :

- Les étapes d'acquisition et de constitution d'une base de données,
- Les techniques de prétraitement et de segmentation (foie et tumeurs),
- L'intégration des algorithmes d'apprentissage automatique et profond.

Nous avons présenté à la fois notre propre base de données issue du Centre Anti-Cancer de Batna, et la base de référence LiTS2017. Les résultats obtenus ont démontré l'efficacité de nos modèles, en particulier DDA-U-Net et ASD-U-Net, dans la segmentation du foie et des tumeurs hépatiques.

**Chapitre 4 : LA
SEGMENTATION DES
TUMEURS HÉPATIQUES PAR
LES MÉTHODES DE
MACHINE LEARNING**

4.1. Introduction

Le foie joue un rôle essentiel dans l'organisme humain en assurant de nombreuses fonctions vitales, notamment la filtration du sang, le stockage des nutriments et la détoxification. Cependant, divers facteurs pathologiques comme la consommation excessive d'alcool, les infections virales, les hépatites chroniques, la cirrhose ou encore les prédispositions génétiques peuvent altérer ses fonctions et conduire à des affections graves, dont le cancer du foie.

Le carcinome hépatocellulaire (CHC), forme la plus courante du cancer du foie, représente l'un des cancers les plus répandus dans le monde. Sa détection est souvent tardive en raison de symptômes cliniques peu spécifiques, ce qui explique un taux de survie relativement faible, estimé à environ 13 % sur cinq ans. Les facteurs de risque incluent, outre les maladies chroniques du foie, l'âge, l'état de santé général et le cadre de vie.

Face à cette problématique, un diagnostic précoce et précis est primordial. Les patients présentant des signes de pathologies hépatiques sont généralement orientés vers des examens d'imagerie médicale tels que l'échographie, l'imagerie par résonance magnétique (IRM) et surtout la tomodensitométrie (TDM), qui fournit une visualisation détaillée de la structure interne du foie. Dans ce contexte, la segmentation du foie et la détection automatique des tumeurs hépatiques constituent des étapes cruciales pour améliorer l'exactitude du diagnostic et optimiser la prise en charge thérapeutique.

Néanmoins, la segmentation du foie demeure une tâche difficile en raison de la complexité anatomique de l'organe, de la variabilité inter-patients et de la qualité hétérogène des images médicales. Pour pallier ces difficultés, de nombreuses méthodes de segmentation automatique ont été proposées, visant à assister le radiologue dans son interprétation. Ces approches reposent principalement sur deux grandes catégories :

- La segmentation par classification, qui regroupe les pixels ou sous-régions d'images en fonction de leurs similarités (intensité, texture, etc.) ;
- La segmentation par détection de contours, qui se base sur les discontinuités et transitions d'intensité dans l'image.

Plusieurs techniques exploitant l'histogramme des niveaux de gris en TDM permettent de mesurer la structure hépatique et d'en extraire des informations pertinentes. Toutefois, ces méthodes exigent de définir le nombre de classes de niveaux de gris et nécessitent des étapes de prétraitement, telles que la mesure de la densité et l'utilisation de modèles déformables.

Parmi ceux-ci, les contours actifs (ou "snakes") se distinguent comme une méthode largement utilisée, car ils permettent une détection adaptative et robuste des structures grâce à leur capacité à générer un contour fermé.

Dans le cadre de ce chapitre, nous proposons une amélioration des techniques classiques en mettant en œuvre un modèle de contour actif avec initialisation automatique, afin de réduire la dépendance à l'intervention manuelle et d'accroître la fiabilité des résultats. L'approche développée repose sur un flux méthodologique intégrant :

- Un prétraitement des images basé sur le modèle de mélange gaussien (GMM),
- Une détection optimisée des contours,
- Un filtrage morphologique,
- Et enfin, l'utilisation de la carte des contours comme entrée dans le calcul des flux de vecteurs de gradient.

Ainsi, ce chapitre vise à démontrer comment la combinaison de ces techniques permet d'améliorer la segmentation automatique du foie et de ses tumeurs à partir d'images de TDM, ouvrant la voie à un diagnostic assisté plus rapide et plus précis.

4.2. Méthodologie

La méthode proposée pour la segmentation du foie, après une phase de prétraitement, est présentée dans ce chapitre. Elle s'appuie sur plusieurs approches complémentaires, notamment le modèle de Rayleigh, le modèle de mélange gaussien (GMM), les techniques de seuillage, la détection des contours par l'algorithme de Canny, les opérations morphologiques ainsi que le modèle de flux de vecteurs de gradient (GVF). Comme illustré dans la Figure 4. 1, le schéma fonctionnel adopté pour la segmentation du foie se décompose en cinq étapes principales.




Figure 4. 1 : les étapes de segmentation des images médicales du foie

4.2.1. Prétraitement des images médicales du foie

La loi de Rayleigh est une distribution de probabilité largement utilisée en statistique et en traitement du signal. Elle peut être interprétée comme la norme d'un vecteur gaussien bidimensionnel dont les composantes sont indépendantes, centrées et de variance identique. En d'autres termes, la distance d'une particule à son point d'origine, après une marche aléatoire symétrique dans un plan, suit généralement une distribution de Rayleigh paramétrée.

Bien qu'initialement développée dans un cadre probabiliste, cette loi trouve de nombreuses applications pratiques. Par exemple, elle est fréquemment employée pour modéliser l'enveloppe d'un processus gaussien à bande étroite [7]. Dans le domaine du traitement d'images médicales, et en particulier pour la segmentation du foie, le modèle de Rayleigh est utilisé pour représenter la distribution d'intensité des pixels. Cette représentation permet d'améliorer le contraste et de faciliter la séparation entre le foie et les structures anatomiques voisines.

La fonction de densité de probabilité ($f.d.p$) de la loi de Rayleigh est donnée par :

$$f(x, y) = \begin{cases} \frac{x}{\sigma^2} \exp\left(-\frac{x^2}{2\sigma^2}\right), & x \geq 0, \sigma > 0 \\ 0, & x < 0 \end{cases} \quad (10)$$

Où :

- x représente la variable aléatoire (valeur d'intensité des pixels),
- σ est le paramètre d'échelle (lié à la variance).

Cette loi est souvent utilisée pour modéliser des phénomènes physiques, tels que l'amplitude de signaux bruités ou l'enveloppe d'un processus gaussien à bande étroite [7].

Dans le domaine du traitement d'images médicales, et plus particulièrement pour la segmentation du foie, le modèle de Rayleigh permet de caractériser la distribution d'intensité des pixels. Il facilite ainsi la distinction entre les tissus hépatiques et les structures environnantes, ce qui améliore le prétraitement et prépare les images à une segmentation plus précise.

Ce chapitre a pour objectif de supprimer le bruit de fond présent dans les images médicales. Pour ce faire, le premier pic de l'histogramme est estimé à l'aide de la courbe de Rayleigh, laquelle modélise efficacement la distribution du bruit dans l'image (Figure 4.2).

Le seuil ainsi déterminé permet de masquer et d'éliminer l'arrière-plan indésirable, ne conservant que les régions d'intérêt. Cette étape constitue une phase fondamentale de la

méthode proposée, car elle fixe la plage d'intensité approximative qui servira de base aux étapes ultérieures de segmentation.




Figure 4.2 : L'estimation de la densité de Rayleigh

4.2.2. Modèle de mélange gaussien

Le seuillage constitue l'une des méthodes les plus simples de segmentation d'images, puisqu'il permet de transformer une image en une représentation binaire. Toutefois, le choix du seuil est une étape délicate :

- Un intervalle trop large génère des faux positifs, c'est-à-dire que des pixels ne correspondant pas à la région d'intérêt (bruit ou structures voisines d'intensité similaire) sont conservés ;
- Un intervalle trop étroit produit des faux négatifs, entraînant la perte partielle ou totale de certaines régions d'intérêt.

Dans la méthode proposée dans ce chapitre, le choix du seuil optimal dans les images de tomodensitométrie (TDM) est réalisé à l'aide du modèle de mélange gaussien (GMM), en s'appuyant sur la distribution de Rayleigh obtenue lors de l'étape précédente.

Le GMM est un modèle probabiliste qui combine plusieurs distributions gaussiennes pondérées afin de représenter des données complexes ne pouvant pas être modélisées par une gaussienne unique. Chaque composante gaussienne du mélange correspond à un sous-ensemble naturel de données, permettant ainsi une meilleure séparation des structures dans une image. Cette approche est couramment utilisée en traitement d'images et en reconnaissance de formes (images médicales, vidéos, audio, etc.) [7].

La densité de probabilité d'un mélange comportant M composantes est donnée par :

$$p(x | \theta) = \sum_{i=1}^M w_i N(x | \mu_i, \Sigma_i) \quad (11)$$

où :

- x est un vecteur de données à valeurs continues (dans notre cas, les intensités des pixels des images médicales),
- w_i est le poids de mélange associé à la composante i , tel que $\sum_{i=1}^M w_i = 1$,
- μ_i est le vecteur moyen de la composante i ,
- Σ_i est la matrice de covariance de la composante i .

Chaque densité de composante est une gaussienne multidimensionnelle de la forme :

$$N(x | \mu_i, \Sigma_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)\right) \quad (12)$$

Le modèle est estimé à l'aide de l'algorithme Expectation-Maximization (EM), qui maximise la vraisemblance en présence de données incomplètes par un processus itératif. La fonction de vraisemblance est donnée par :

$$L(\theta) = \prod_{i=1}^n p(x_i | \theta) \quad (13)$$

Où $\theta = \{w_i, \mu_i, \Sigma_i\}_{i=1}^M$ représente l'ensemble des paramètres estimés.

Dans notre étude, le GMM a été implémenté avec une contrainte de covariance Full (covariances libres), via la classe GaussianMixture de la bibliothèque Scikit-learn :

- `sklearn.mixture.GaussianMixture (`
- `n_components=12, covariance_type='full',`
- `tol=0.001, max_iter=100, random_state=0)`

L'analyse de l'histogramme des images TDM a montré que celui-ci peut être décomposé en 12 classes de niveaux de gris, après suppression du pic de Rayleigh représentant le bruit de fond. Ces classes ont été modélisées par 12 gaussiennes distinctes. L'histogramme peut donc être représenté comme une somme de gaussiennes, où μ_i et σ_i^2 correspondent respectivement à la moyenne et à la variance de chaque composante.

Pour mettre en évidence les tissus mous (comme le foie), le pic principal de l'histogramme est ajusté par l'une de ces gaussiennes. Les paramètres μ et σ sont estimés à

l'aide de l'algorithme EM, puis un intervalle de seuillage est défini :

- Le minimum correspond à la moyenne μ ,

Le maximum est défini par la valeur la plus élevée observée, après exclusion des pixels saturés (zones très claires associées aux structures osseuses dans l'image TDM).

Ainsi, l'utilisation du GMM permet de déterminer automatiquement un seuil optimal et robuste, garantissant une segmentation plus précise du foie et de ses tumeurs




Figure 4. 3 : L'estimation d'un histogramme par 12 gaussienne

Comme l'illustre la Figure 4.3, l'étape de seuillage repose sur l'exploitation des valeurs essentielles (min et max) pour extraire les régions d'intérêt. Nous appliquons dans un premier temps la méthode **THRESH_BINARY**, qui permet de générer une image binaire séparant les objets de l'avant-plan de l'arrière-plan. Le masque résultant du seuillage est ensuite extrait et inversé afin de faciliter son exploitation.

Le seuillage constitue ainsi une approche élémentaire mais efficace de segmentation d'images, permettant d'isoler les structures pertinentes. Pour affiner le résultat, un flou est appliqué, puis la fonction `cv2.threshold` est utilisée afin d'améliorer la distinction entre les différentes zones de l'image.

Dans cette étape, la valeur Area a été utilisée comme critère de filtrage afin de ne conserver que l'élément de grande taille présent dans l'image. Une fois les composants non pertinents éliminés, la fonction `morphologyEx` avec l'option `MORPH_CLOSE` est appliquée. Cette opération permet de combler les petits trous à l'intérieur des objets d'avant-plan et de supprimer les points noirs isolés apparaissant sur les structures segmentées.

Par la suite, une comparaison est effectuée entre l'image originale et le résultat obtenu après l'opération morphologique, ce qui permet de visualiser clairement l'amélioration apportée

par ce traitement. Enfin, le résultat final du seuillage est restitué (voir Figure 4.4).




Figure 4. 4 : Image Morphologique du CT du foie

Par la suite, différentes méthodes de traitement sont appliquées :

- GaussianBlur et InRange sont utilisées afin de réduire le bruit et les détails superflus de l'image. Cette opération permet d'améliorer la lisibilité des structures à différentes échelles.
- Dans le cadre de la détection des contours, l'algorithme de Canny est mis en œuvre. Ce détecteur a été conçu pour optimiser les performances en respectant trois critères fondamentaux :
 - **Bonne détection** : minimiser les erreurs dans l'identification des contours ;
 - **Localisation optimale** : réduire au maximum la distance entre les contours détectés et les contours réels ;
 - **Réponse unique et claire** : garantir qu'un seul contour est identifié pour chaque bord, en évitant la génération de faux positifs.

L'objectif principal de cette étape est de mettre en évidence les contours pertinents du foie à partir de l'image TDM seuillée, comme illustré dans la Figure 4.5, et plus particulièrement de détecter les bords fins et secondaires présents dans les différentes coupes

de l'image.




Figure 4. 5 : Image Canny du foie

4.2.3. Flux vectoriel de gradient (GVF : Gradient Vector Flow)

L'utilisation de l'algorithme GVF dans notre méthode est motivée par les limites bien connues des Snakes conventionnels, notamment la sensibilité à l'initialisation et la faible capacité de convergence dans les zones concaves.

Un contour déformable, ou *Snake*, peut être représenté par la courbe paramétrique :

$$C(s) = [x(s), y(s)],$$

Où $s \in [0,1]$ est la coordonnée axiale courbée.[7]

Ce contour évolue sous l'action de deux forces principales :

- Les forces internes, qui assurent la régularité et la continuité du contour pendant la déformation ;
- Les forces externes, qui attirent le modèle vers les frontières réelles de l'objet à détecter.

L'évolution du Snake est itérative et contrôlée par un test de convergence. Pour introduire l'algorithme GVF, nous définissons une carte de contours f , obtenue à partir d'un ensemble de points (x_p, y_p) . Ces points de contour, extraits avec la méthode `getcontour()`, sont utilisés pour générer des masques à partir des images CT du foie. L'objectif est de trouver la position optimale de la courbe en minimisant une fonction d'énergie définie comme suit :

$$E = \int_0^1 [E_{int}(C(s)) + E_{ext}(C(s))] ds \quad (14)$$

$$E_{int} = E_{lis}(C(s)) + E_{elas}(C(s)) \quad (15)$$

$$E_{int} = \frac{1}{2} \left[\alpha(s) \left(\frac{dC}{ds} \right)^2 \right] + \frac{1}{2} \left[\beta(s) \left(\frac{d^2C}{ds^2} \right)^2 \right] \quad (16)$$

- E_{int} représente l'énergie interne, qui permet au contour de conserver sa cohérence. Elle est régie par deux paramètres :

- $\alpha(s)$: le coefficient de tension (élasticité),
- $\beta(s)$: le coefficient de rigidité (homogénéisation).

E_{ext} désigne l'énergie externe, dérivée des informations de l'image (gradients, intensités), et agit comme une force d'attraction vers les bords significatifs.

Xu et Prince (1997) [36] ont proposé le Gradient Vector Flow (GVF) afin de pallier les limites des Snakes classiques. Le GVF est calculé à partir de la carte des contours f , et repose sur la résolution d'équations aux dérivées partielles (EDP). Son avantage principal est d'élargir le champ d'attraction des forces externes et de garantir une convergence robuste, y compris dans les zones présentant des concavités.

Ainsi, le modèle déformable enrichi par le GVF est défini par l'optimisation de l'énergie suivante :

$$E = \int_0^1 \frac{1}{2} \left[\alpha(s) \left(\frac{dC}{ds} \right)^2 \right] + \frac{1}{2} \left[\beta(s) \left(\frac{d^2C}{ds^2} \right)^2 \right] - \gamma(s) \frac{\nabla I(x,y)}{|\nabla I(x,y)|} + k(s) V_{GVF} \quad (17)$$

Où :

- $\nabla I(x,y)$ représente le gradient de l'image CT,
- $\gamma(s)$ pondère la force image,
- V_{GVF} est le champ de forces défini par le flux vectoriel de gradient.

Ce formalisme permet une meilleure localisation des contours du foie, tout en offrant une robustesse accrue face au bruit, aux concavités et aux difficultés d'initialisation.

La Figure 4.6 illustre le principe du flux vectoriel de gradient appliqué à la segmentation,

en montrant comment les forces externes générées par le GVF guident le contour actif vers les frontières réelles du foie, même dans les zones présentant des concavités complexes.




Figure 4. 6 : Illustration sur GVF Méthode

4.3. Résultats et analyse

Dans un premier temps, l'arrière-plan a été séparé et supprimé des différentes images médicales du foie. Pour ce faire, un modèle de Rayleigh a été appliqué afin d'identifier la plage approximative correspondant aux organes internes, y compris le foie.

Ensuite, des seuils adaptatifs ont été extraits automatiquement pour chaque image à l'aide de l'algorithme du modèle de mélange gaussien (GMM), tel que décrit dans la méthodologie. En éliminant les valeurs d'arrière-plan (comprises entre 0 et 3 dans le modèle de Rayleigh), nous avons déterminé la valeur minimale (*Min*), correspondant au minimum des moyennes. De plus, après suppression des intensités élevées liées aux structures osseuses (zones blanches), nous avons obtenu la valeur maximale (*Max*), définie comme le maximum des moyennes.

Ces deux bornes (*Min* et *Max*) constituent les paramètres exclusifs et essentiels pour le processus de seuillage, permettant d'isoler avec précision les tissus d'intérêt. Les résultats obtenus sont présentés et illustrés dans le tableau ainsi que dans les figures suivantes.





Figure 4. 7 : L'histogramme des images des personne normales






Figure 4. 8 : L’histogramme des images des personnes malades

Tableau 4. 1 : L’estimation des valeurs Min et Max dans l’algorithme GMM

	Nombre de classe	Négatifs		Positifs	
		Min	Max	Min	Max
Image 01	04	121.37469419363923	133	108.74436450468691	136
	08	121.37469419363923	230	108.74436450468691	195
	12	121.37469419363923	231	108.74436450468691	225
	14	121.37469419363923	231	108.74436450468691	231
	18	121.37469419363923	238	108.74436450468691	231
Image 02	04	126.41538017341719	176	123.10707205253702	157
	08	126.41538017341719	185	123.10707205253702	168
	12	126.41538017341719	216	123.10707205253702	240
	14	126.41538017341719	216	123.10707205253702	242
	18	126.41538017341719	216	123.10707205253702	242
Image 03	04	117.48463741802188	147	135.373057550986	183
	08	117.48463741802188	185	135.373057550986	188
	12	117.48463741802188	219	135.373057550986	218
	14	117.48463741802188	223	135.373057550986	242
	18	117.48463741802188	227	135.373057550986	228

Le tableau 4.1 illustre l'évolution des valeurs Min et Max obtenues pour trois images médicales (Image 01, Image 02 et Image 03) selon un nombre croissant de classes considérées dans l'algorithme du modèle de mélange gaussien (GMM). Ces valeurs sont présentées séparément pour les classes négatives (zones exclues, généralement bruit ou arrière-plan) et pour les classes positives (zones d'intérêt, incluant le foie).

1 Stabilité des valeurs Min

- On remarque que la valeur Min reste relativement stable pour chaque image, indépendamment du nombre de classes.
- Exemple : pour l'Image 01, Min des négatifs est constant (121.37), et pour les positifs il demeure proche de 108.74.
- Cette stabilité montre que l'algorithme identifie de manière fiable les bornes inférieures, ce qui est crucial pour distinguer les faibles intensités (arrière-plan) des zones anatomiques pertinentes.

2 Variation progressive des valeurs Max

- Contrairement aux Min, les valeurs Max augmentent progressivement avec le nombre de classes, traduisant une meilleure finesse de segmentation au fur et à mesure que la granularité du GMM s'affine.
- Exemple : pour l'Image 01, le Max des positifs passe de 136 (4 classes) à 231 (14 classes), stabilisant ensuite.
- Cela reflète la capacité du GMM à capturer des intensités plus élevées correspondant aux structures internes plus denses (comme le foie et les tissus adjacents).

3 Différences entre images

- Les trois images présentent des valeurs légèrement différentes, en particulier pour les Max, ce qui témoigne de la variabilité des intensités selon la coupe CT.
- Exemple : l'Image 02 atteint un Max positif de 242 avec 14–18 classes, alors que l'Image 03 culmine à 228.
- Ces écarts traduisent la nature hétérogène des données médicales et soulignent l'importance de l'adaptation dynamique des seuils.

4 Impact du nombre de classes

- Pour un faible nombre de classes (4 ou 8), les valeurs Max sont limitées, traduisant une segmentation plus grossière.
- À partir de 12 à 14 classes, les Max tendent à se stabiliser, indiquant que le modèle atteint une convergence optimale dans l’estimation des seuils.
- Cela suggère que l’utilisation de 12 à 14 classes est suffisante pour obtenir une bonne balance entre précision et complexité computationnelle.


4.4. La Segmentation des tumeurs hépatiques avec le seuillage















4.4.1. Extraction les masques avec Le seuillage

Après avoir appliqué les algorithmes précédents, nous exploitons désormais les seuils déterminés par le modèle de mélange gaussien (GMM) pour les intégrer dans l’algorithme de seuillage. Cette méthode a été retenue car elle permet de générer des masques des images hépatiques, en utilisant comme entrées des images en niveaux de gris ainsi que les seuils minimum et maximum afin de borner les valeurs de pixels à conserver.

Pour isoler spécifiquement le foie, plusieurs étapes de prétraitement ont été nécessaires. À l’issue du seuillage, nous avons utilisé la fonction `ConnectedComponentsWithStats`, qui segmente les différentes structures anatomiques en composants distincts. Le composant présentant l’aire la plus importante correspond au foie ; il a donc été sélectionné grâce à la fonction `Area`, puis affiné par l’application de l’opérateur morphologique `MorphologyEx` avec l’option `MORPH_Close`, afin de corriger les petites discontinuités internes et homogénéiser la région extraite.

Ensuite, pour délimiter avec précision les contours du foie, nous avons eu recours au filtre de Canny associé à l’opération de dilatation (`Dilate`), ce qui permet de renforcer la visibilité des bords de l’organe. Enfin, afin d’améliorer encore la qualité de la segmentation et d’obtenir une délimitation plus fine, nous avons appliqué la méthode GVF (`Gradient Vector Flow`) en nous appuyant sur les contours précédemment détectés. Les résultats obtenus sont illustrés dans les figures suivantes.



	8			
	12			
	14			
	4			
	8			
	12			
	14			
	4			




Figure 4. 9 : Résultats de segmentation des tumeurs hépatiques du foie par Seuillage et la méthode GVF (a) Image originale (en niveaux de gris) (b) N° gaussienne (c) Morphologique image (d) Filtrage de Canny (e) Résultat de GVF

















Les résultats illustrés dans la Figure 4.9 montrent les différentes étapes du processus de segmentation du foie et de ses tumeurs à partir des images CT. La première colonne représente l'image médicale originale du patient (coupes tomographiques). La deuxième colonne correspond aux résultats du seuillage, où les pixels sont classés en différentes classes en fonction des seuils obtenus par l'algorithme GMM. On observe que, pour un nombre réduit de classes (par exemple 4 ou 8), la segmentation reste bruitée et contient plusieurs zones non pertinentes. En revanche, à partir de 12 classes et au-delà, le foie est mieux isolé, bien que certaines structures parasites persistent.

La troisième colonne illustre les masques obtenus après un premier raffinement morphologique, permettant de mieux distinguer les contours internes. La quatrième colonne montre l'application des algorithmes de détection de contours (Canny) et de dilatation, ce qui permet d'obtenir une délimitation plus nette des bords du foie.

Enfin, la dernière colonne présente le résultat après l'application du modèle déformable GVF (Gradient Vector Flow), qui affine la segmentation en s'adaptant aux contours réels, même dans les zones concaves ou complexes.

De manière générale, on constate que l'approche progressive – combinant seuillage adaptatif, traitement morphologique, détection de contours et raffinement par GVF – permet une amélioration notable de la qualité de la segmentation. Les images finales mettent clairement

en évidence les limites du foie et des régions suspectes (tumeurs), offrant ainsi une base solide pour les étapes ultérieures d'analyse et de classification

	4			
	8			
	12			
	14			
	4			
	8			
	12			
	14			




Figure 4. 10 : Résultats de segmentation du foie normale par Seuillage et la méthode GVF (a) Image originale (en niveaux de gris) (b) N° gaussienne (c) Image Morphologique (d) Filtrage de Canny (e) Résultat de GVF

Nous observons ici une différence notable entre les images morphologiques obtenues en fonction du nombre de gaussiennes générées par l’algorithme GMM. Il apparaît que les résultats deviennent stables et cohérents lorsque le nombre de gaussiennes atteint 12, indépendamment des images considérées. En revanche, pour un nombre inférieur à 12, les images morphologiques présentent des lacunes et ne permettent pas une extraction complète et précise du foie avec toutes ses caractéristiques anatomiques.

Au terme de ce processus, nous avons constitué notre base de données, dont la description détaillée sera présentée dans la section suivante de ce chapitre.

4.5. Création de la base de données

Dans le cadre de ce travail, l’un des objectifs majeurs était de constituer une base de données fiable et exploitable pour l’évaluation des méthodes de segmentation du foie et de ses tumeurs. Pour atteindre ce résultat, nous avons combiné plusieurs algorithmes et approches de traitement d’images, parmi lesquels le modèle de Rayleigh, le modèle de mélange gaussien (GMM), les méthodes de seuillage, les opérations morphologiques, ainsi que l’algorithme GVF

(Gradient Vector Flow).

Le processus de création de la base de données s'est déroulé en plusieurs étapes successives :

1. Prétraitement des images médicales

- Le modèle de Rayleigh a été appliqué afin d'éliminer l'arrière-plan bruité et d'isoler la plage de valeurs correspondant aux organes internes, en particulier le foie.
- Cette étape a permis de préparer les images CT en réduisant les artefacts et les zones non pertinentes pour l'analyse.

2. Segmentation du foie

- Nous avons ensuite appliqué les méthodes de seuillage adaptatif, issues des paramètres fournis par le modèle de mélange gaussien (GMM).
- Les résultats ont été affinés à l'aide d'opérations morphologiques et du filtre de Canny, permettant de mieux délimiter les contours et d'extraire avec précision la région correspondant au foie.

3. Segmentation des tumeurs hépatiques

- À partir des masques segmentés du foie, nous avons isolé et mis en évidence les zones suspectes représentant les tumeurs.
- L'algorithme GVF a été intégré afin d'améliorer la précision des contours dans les régions concaves et complexes, où les méthodes classiques de snakes atteignent leurs limites.





4. Constitution de la base de données ACC-Batna2022

- Les résultats de segmentation (foie et tumeurs) ont été sauvegardés et organisés sous forme de masques annotés.
- Chaque image est accompagnée de son équivalent segmenté, ce qui permet de disposer d'un corpus structuré et homogène pour l'évaluation et l'expérimentation.
- La Figure 4.11 illustre un exemple de ces résultats et met en évidence la qualité des masques générés.

Ainsi, la base de données ACC-Batna2022, élaborée au terme de ce processus, constitue un support expérimental précieux. Elle servira non seulement à évaluer les performances des

algorithmes développés dans ce travail, mais également à enrichir les recherches futures dans le domaine de la segmentation hépatique assistée par ordinateur.

:



(a)

(b)

Figure 4. 11 : Résultats de bases de données du foie (a) Image CT du foie (b) Masques du foie




Figure 4. 12 : Résultats de bases de données du Tumeurs hépatiques (a) Image CT du foie (b) Images du foie (c) masques des tumeurs hépatiques

4.6. Conclusion et discussion

La méthodologie proposée dans ce chapitre s'est révélée être une approche efficace pour répondre aux problématiques de segmentation des images médicales, avec un accent particulier sur l'extraction précise du foie et de ses tumeurs à partir d'images tomодensitométriques (CT). L'intégration des différents algorithmes, notamment le modèle de Rayleigh, l'algorithme GVF (Gradient Vector Flow) et le GMM (Gaussian Mixture Model), a permis de construire un processus de segmentation robuste et adapté aux spécificités des données médicales.

L'objectif principal de cette étude était la création d'une base de données originale et fiable, nommée ACC-Batna2022, afin de combler une lacune importante dans le domaine. En effet, nous avons constaté que la littérature et les ressources disponibles présentent une carence en bases de données spécifiquement dédiées à la segmentation du foie et des tumeurs hépatiques, tant sur le plan de la diversité des pathologies que sur celui de la précision des contours segmentés. Cette contribution vise donc à fournir un outil solide, qui servira de référence pour les recherches à venir, notamment dans les chapitres suivants.

Toutefois, malgré les résultats prometteurs obtenus, plusieurs limites et défis subsistent. Parmi eux, la détection et la délimitation des petites tumeurs restent particulièrement complexes, car elles échappent souvent à la visibilité directe, même pour un radiologue expérimenté. De plus, les contours du foie extraits à partir des images CT présentent parfois des irrégularités ou des imprécisions, ce qui peut influencer sur la fiabilité de l'interprétation clinique.

Ces difficultés mettent en évidence la nécessité d'explorer des approches plus avancées, en particulier celles basées sur l'apprentissage profond (Deep Learning). En effet, l'utilisation de réseaux de neurones convolutifs (CNN) et d'architectures spécialisées pour la segmentation s'avère prometteuse afin de réduire les erreurs de diagnostic, d'améliorer la précision des contours et d'assurer une meilleure visualisation des petites lésions. L'intégration de ces méthodes sera au cœur des perspectives de nos recherches futures.

En somme, cette étude constitue une étape fondamentale dans notre démarche scientifique : elle a permis non seulement de développer une base de données locale et adaptée, mais également de poser les bases d'une amélioration continue de la segmentation médicale grâce à l'intelligence artificielle.

**Chapitre 5 : SEGMENTATION
AUTOMATIQUE DU CANCER DES
TUMEURS HEPATIQUES À
L'AIDE DE L'APPRENTISSAGE
PROFOND**

5.1. Introduction

Avec le développement de l'intelligence artificielle et sa grande dépendance à l'apprentissage profond, de nombreux domaines sont devenus indispensables, en particulier les domaines médicaux et l'imagerie médicale. L'extraction des caractéristiques des images médicales pour aider à diagnostiquer les maladies est une question importante de nos jours, et dans cette recherche, nous parlons spécifiquement des images médicales des tumeurs hépatiques. Les maladies et les tumeurs hépatiques ont un impact significatif sur l'augmentation de la mortalité dans le monde. Le foie se classe au sixième rang pour l'incidence mondiale des tumeurs et est la troisième cause de mortalité liée aux tumeurs. C'est la sixième maladie la plus couramment diagnostiquée dans le monde. En 2020, plus de 900 000 nouveaux cas de tumeurs du foie ont été signalés [38].

Selon les informations de l'OMS, dans la région de l'Afrique du Nord, qui comprend l'Algérie, l'Égypte, le Maroc, la Libye et la Tunisie, le taux d'incidence standardisé par âge pour 100 000 personnes des tumeurs du foie en 2020 a révélé que l'Algérie a enregistré 1 % des nouveaux cas et 1,7 % des décès dus à la maladie, ce qui la place au 21e rang sur la liste des tumeurs les plus courantes. Au cours de la même année, la Tunisie a enregistré une incidence de 3,3 % des cas de la maladie, ce qui la place au 8e rang des tumeurs les plus courantes. Le Maroc a enregistré un taux d'incidence de 2,2 %, ce qui le place également au 11e rang des tumeurs les plus courantes. La Libye a enregistré un taux d'incidence de 3,0 %, se classant au 20e rang en termes de fréquence, tandis que l'Égypte a enregistré un taux d'incidence beaucoup plus élevé de 20,1 %, se classant comme la tumeur la plus fréquente dans la région, occupant la première place [38].

Il est difficile de détecter les tumeurs du foie à un stade précoce, car les signes et symptômes courants ne sont souvent détectés qu'à un stade avancé de la maladie. Le dépistage et la détection précoce permettent d'optimiser le succès du traitement tout en réduisant la mortalité. Une détection précoce efficace des tumeurs hépatiques peut être réalisée par des tests scientifiques standard qui comprennent des tests d'imagerie tels que l'échographie, la tomodensitométrie (CT) ou l'imagerie par résonance magnétique (IRM) en conjonction avec des examens pathologiques.

Cependant, la disponibilité limitée de ces équipements sophistiqués et d'experts spécialisés les rend souvent difficiles et chronophages. Parmi ces techniques, la tomodensitométrie est l'une des méthodes les plus simples pour détecter les tumeurs hépatiques et évaluer la forme, la texture et les lésions focales du foie.

Cependant, la détection des tumeurs hépatiques par la tomodensitométrie s'accompagne de sa propre difficulté : (1) les petites tumeurs hépatiques, en particulier aux étapes précoces, ne sont pas clairement visibles sur les tomodensitogrammes, (2) la densité normale du foie complique encore la distinction entre les tissus sains et malsains, en particulier lorsque les tumeurs présentent une densité similaire à celle du tissu hépatique environnant, (3) les tumeurs sont bien cachées dans le tissu hépatique sain adjacent, ce qui les rend plus difficiles à identifier sur les images tomodensitométriques, et (4) la présence de diverses structures et organes dans la région abdominale peut interférer avec le foie, ce qui peut obscurcir ou compliquer la visualisation des tumeurs hépatiques [39].

L'interprétation médicale impose au radiologue d'interagir avec des images visuellement difficiles. Les radiologues sont influencés par des facteurs tels que les limites inhérentes à l'œil humain, la fatigue, la pression du temps, la qualité de l'image, etc. La sensibilité attendue d'un radiologue lors de l'examen des tumeurs du foie se situe généralement entre 70 et 80 %. Pour améliorer la précision du diagnostic, la pratique des lectures duplex par le radiologue est à l'étude, bien qu'elle entraîne une augmentation des coûts [40]. Ainsi, l'utilisation de méthodes basées sur l'IA pour aider le radiologue peut être bénéfique, y compris l'apprentissage automatique et l'apprentissage profond.

Les modèles d'apprentissage profond présentent certaines limites en termes de défis liés à la qualité des données, aux diverses modalités d'imagerie et aux variations anatomiques complexes, qui sont courantes dans l'imagerie médicale. En outre, il se peut qu'il ne fonctionne pas de manière optimale avec des images à haute résolution ou des scénarios impliquant plusieurs catégories.

Nous avons créé une nouvelle base de données CT de 1019 images acquises au Centre Anti Cancer de Batna (ACC-BATNA2022) en Algérie par des radiologues experts, avec localisation des tumeurs hépatiques. Dans ce chapitre, nous avons pu créer deux nouveaux modèles en remplaçant les couches de codage normales par un réseau de couches de codage de DenseNET et d'ASPP de deux manières différentes dans les deux modèles. Ces deux modèles ont été testés à la fois dans notre propre jeu de données et dans un ensemble de données privé appelé LITS2017. Nous verrons tout cela en détail dans ce chapitre.

5.2. Bases de données utilisées

L'évaluation de tout modèle de segmentation en imagerie médicale repose sur la disponibilité de bases de données représentatives, contenant à la fois des images de qualité et des annotations de référence fiables. Dans le cadre de cette étude, deux bases de données

distinctes ont été exploitées : ACC-BATNA2022, constituée localement, et la base publique internationale LiTS2017. L'utilisation conjointe de ces deux sources vise à garantir une évaluation équilibrée, permettant à la fois de valider les performances dans un contexte local et de comparer les résultats avec ceux issus de la littérature internationale.

5.2.1. Base ACC-BATNA2022

La base ACC-BATNA2022 a été élaborée dans le cadre de cette recherche en collaboration avec le Centre Hospitalo-Universitaire de Batna. Elle est composée de 140 scanners abdominaux, regroupant des images issues de patients présentant diverses pathologies hépatiques. Ces images, collectées selon un protocole rigoureux, ont été anonymisées afin de respecter les principes éthiques et de confidentialité des données médicales.

Chaque volume a été annoté manuellement par des radiologues expérimentés, fournissant ainsi des masques de segmentation de haute qualité, considérés comme référence. Cette base constitue une contribution originale et précieuse de notre travail, en offrant un corpus adapté aux spécificités locales, rarement pris en compte dans les bases de données internationales. Elle servira également de ressource pour des recherches ultérieures dans le domaine de l'imagerie médicale assistée par intelligence artificielle.

5.2.2. Base LiTS2017

La base Liver Tumor Segmentation Challenge 2017 (LiTS2017) est une base de données publique largement utilisée dans la communauté scientifique pour l'évaluation des algorithmes de segmentation hépatique. Elle comprend 131 scanners abdominaux provenant de plusieurs centres hospitaliers et institutions médicales internationales, ce qui lui confère une grande diversité en termes de qualité d'images, de protocoles d'acquisition et de caractéristiques des patients.

Les annotations associées incluent à la fois les contours du foie et ceux des tumeurs, permettant ainsi une évaluation fine de la capacité des modèles à segmenter correctement non seulement l'organe, mais également les lésions de tailles et de formes variées. Cette base, grâce à sa large diffusion et à son adoption par de nombreux travaux, constitue une référence incontournable pour comparer nos résultats avec l'état de l'art.

5.2.3. Complémentarité des bases de données

L'utilisation combinée des bases ACC-BATNA2022 et LiTS2017 présente un double intérêt. D'une part, elle permet de tester les modèles dans un contexte local avec des données représentatives de notre environnement clinique. D'autre part, elle autorise une comparaison objective avec les performances rapportées dans la littérature grâce à une base publique de

référence. Cette approche mixte garantit ainsi une meilleure robustesse et une validité externe accrue des résultats obtenus.

5.3. Modèles et approches proposées

La segmentation des images médicales, en particulier celles du foie et des tumeurs hépatiques, nécessite des architectures profondes capables de combiner une forte capacité de représentation avec une précision spatiale élevée. Dans ce cadre, plusieurs variantes de réseaux de type U-Net ont été explorées et adaptées. Nous présentons dans cette section les modèles de référence utilisés ainsi que les améliorations méthodologiques apportées, notamment l'intégration de DenseNet et du module ASPP (Atrous Spatial Pyramid Pooling).

5.3.1. Rappel sur U-Net++

Le modèle U-Net++ constitue une extension du réseau U-Net initial, largement reconnu pour ses performances en segmentation biomédicale. Cette architecture introduit des connexions denses et imbriquées entre les couches de l'encodeur et celles du décodeur. L'objectif est de réduire l'écart sémantique entre les cartes de caractéristiques issues des différentes profondeurs du réseau, et ainsi d'améliorer la précision des reconstructions spatiales.

U-Net++ se distingue notamment par l'utilisation de blocs intermédiaires de convolution et par une meilleure exploitation des informations multi-échelles, ce qui en fait une base solide pour la segmentation hépatique.

5.3.2. Architecture DDA-UNet

L'architecture DDA-UNet (Deeply Densely Connected Attention U-Net), indiquée dans la Figure 5.1., introduit un mécanisme d'attention et des connexions denses profondes afin de renforcer l'extraction des caractéristiques pertinentes. Grâce à l'attention, le réseau se focalise sur les régions d'intérêt (ROI), en filtrant les informations redondantes ou non discriminantes. Cette approche s'avère particulièrement utile pour la détection de petites tumeurs, souvent difficiles à identifier en raison de leur faible contraste avec les tissus environnants.




Figure 5. 1 : Architecture DDA_UNet utilisant un double DenseNet et un module ASPP

La Figure 5. 1 illustre de manière schématique l'architecture proposée DDA_UNet, qui repose sur l'intégration d'un double DenseNet et d'un module ASPP (Atrous Spatial Pyramid Pooling). Cette architecture vise à améliorer la capacité d'extraction et de fusion des caractéristiques à différentes échelles tout en préservant les détails spatiaux des images segmentées.

Dans cette approche, les couches convolutives classiques sont remplacées par un DenseNet modifié dans les blocs de sous-échantillonnage allant du deuxième au cinquième niveau de l'encodeur. Chaque bloc de sous-échantillonnage intègre une couche ASPP dynamique, chargée de traiter la carte de caractéristiques en entrée et de la fusionner avec la carte de caractéristiques en sortie afin d'enrichir les informations contextuelles multi-échelles.

Le modèle comprend cinq blocs de convolution de sous-échantillonnage, chacun constitué de deux convolutions successives avec des filtres de taille (3×3) . Les cartes de caractéristiques conservent la même dimension au sein d'un même bloc. Entre deux couches consécutives, un dropout de 0,1 est appliqué pour éviter le surapprentissage en supprimant les neurones redondants, suivi d'une opération de MaxPooling destinée à extraire les caractéristiques dominantes et à réduire la taille des cartes.

Les sorties de ces blocs sont ensuite transmises au DenseNet, qui génère deux sorties

distinctes :

- ☞ La première sert d'entrée au module ASPP,
- ☞ La seconde est fusionnée (via l'opération concatenate) avec la sortie de l'ASPP, comme le montre la Figure 5. 5.

Les cartes de caractéristiques conservent des densités similaires le long des chemins de convolution, des connexions de saut (skip connections) et des blocs DenseNet-ASPP du premier au quatrième niveau. Au cinquième niveau, un ASPP dynamique est employé afin de réduire la densité des cartes de caractéristiques et de régulariser le processus d'apprentissage.

Concernant la fonction d'activation, une LeakyReLU est utilisée à la place de la fonction ReLU classique pour éviter le phénomène de “ReLU mourante”, où certains neurones restent bloqués à une sortie nulle suite à la régression du gradient. Cette modification permet de maintenir une propagation de gradient plus stable. De plus, une normalisation par lots (Batch Normalization) est appliquée à chaque bloc afin d'améliorer la stabilité de l'entraînement et d'accélérer la convergence du modèle.

Enfin, conformément aux observations de Gao et Almekkawy [45], les couches du décodeur reproduisent symétriquement le processus inverse de l'encodeur, reliant les blocs de sur-échantillonnage aux cartes de caractéristiques correspondantes des couches de l'encodeur au même niveau, assurant ainsi une reconstruction précise des détails spatiaux de l'image segmentée.

5.3.3. Architecture ASD-UNet

Le modèle ASD-UNet (Attention Supervised Dense U-Net) , indiqué dans la Figure 5.2, constitue une autre variante explorée dans ce travail. Il associe une supervision intermédiaire et des mécanismes d'attention intégrés au sein des couches profondes du réseau. L'idée est de guider l'apprentissage du modèle vers une meilleure différenciation entre les contours du foie, les tumeurs et les tissus voisins. L'ajout de la supervision intermédiaire permet de renforcer la stabilité de l'entraînement et de limiter le phénomène de sur-apprentissage.




Figure 5. 2 : Architecture ASD_UNet améliorée intégrant un DenseNet et un double module ASPP

5.3.4. Amélioration de l'encodeur avec DenseNet

Dans cette phase de notre recherche, nous proposons une amélioration significative de nos modèles en intégrant une variante modifiée du DenseNet-121 dans l'encodeur, en remplacement des couches convolutives conventionnelles. Cette substitution permet d'enrichir considérablement l'expressivité de notre modèle, en produisant des représentations de caractéristiques plus riches et plus informatives.

L'une des principales forces de DenseNet réside dans sa connectivité dense, où chaque couche reçoit en entrée les sorties de toutes les couches précédentes. Cette conception favorise une réutilisation efficace des caractéristiques et facilite la formation de représentations hiérarchiques détaillées et informatives. Sur le plan mathématique, cette connectivité dense peut être exprimée par la relation suivante :

$$X_i = H([X_0, X_1, \dots, X_{i-1}]) \quad (18)$$

où X_i représente la carte de caractéristiques générée par la couche i , et H désigne le bloc convolutif appliquant les activations non linéaires correspondantes.

Pour concrétiser cette stratégie, nous avons adopté le DenseNet-121, initialement conçu pour des tâches de classification d'images, et nous avons adapté ses couches à l'encodeur de l'architecture U-Net++. Cette intégration permet d'exploiter pleinement les capacités d'extraction multi-niveaux du DenseNet tout en préservant la structure en entonnoir propre à U-Net++.

Notre approche tire parti d'une technique permettant la capture de caractéristiques de bas niveau (telles que les bordures et textures) tout en assurant une analyse multi-échelle des images. De plus, nous avons intégré un processus d'optimisation dans la phase d'entraînement afin d'exploiter le plein potentiel de l'encodeur DenseNet-121. L'objectif de cette optimisation est de déterminer les paramètres optimaux θ^* qui minimisent la fonction de perte définie par :

$$\theta^* = \underset{\theta}{\operatorname{argmin}} (L(f_{\theta}(X_i), Y_i)) \quad (19)$$

où $f_{\theta}(X_i)$ représente la sortie du modèle (ici le codeur DenseNet-121) pour une entrée X_i , et Y_i correspond au masque de segmentation de vérité terrain. Ce processus d'optimisation ajuste progressivement les paramètres du modèle afin d'assurer une correspondance optimale entre les prédictions et les masques réels.

DenseNet (voir la Figure 5.3) est un réseau neuronal convolutif profond (CNN) conçu pour améliorer les performances d'apprentissage, notamment dans les architectures où l'augmentation de la profondeur entraîne un risque de dégradation du gradient [] (Huang *et al.*, 2017). La caractéristique essentielle de DenseNet est sa concaténation systématique des sorties de toutes les couches précédentes, assurant ainsi un flux d'informations constant à travers le réseau.

Chaque bloc DenseNet est constitué de la séquence suivante :

Bloc de convolution DenseNet :

- **Batch Normalization** : normalisation des activations d'entrée ;
- **LeakyReLU** ($\alpha = 0,1$) : activation non linéaire atténuant le problème de "ReLU mourante" ;
- **Conv2D** (f, 1×1, same) : convolution de réduction dimensionnelle.

Couche de transition :

- **Batch Normalization** ;
- **LeakyReLU** ($\alpha = 0,1$) ;
- **Conv2D** (f, 1×1, same) ;
- **Average Pooling** (2×2, stride=1, same) pour la réduction de taille spatiale.

Le nombre de couches par bloc H est généralement fixé à 6, 12, 16 ou 24, selon la profondeur souhaitée. Les sorties intermédiaires sont ensuite combinées par concaténation pour former la carte de caractéristiques finale :

$$\text{Concatenate}([x, \text{tensor}])$$




Figure 5. 3 : Structure du DenseNet intégrée dans nos modèles

5.3.5. Intégration du module ASPP

Le module Atrous Spatial Pyramid Pooling (ASPP), reconnu pour sa capacité à capturer des informations contextuelles à plusieurs échelles, a été intégré après l'incorporation du codeur basé sur DenseNet dans nos modèles, comme indiqué dans l'équation (43) :

$$Y_i = G([X_i]) \quad (20)$$

où G représente l'ensemble des fonctions du module ASPP, comprenant notamment les convolutions dilatées, les connexions additionnelles et la fusion des cartes de caractéristiques, tandis que Y_i désigne la sortie du module ASPP.

L'intégration du module ASPP dans notre encodeur DenseNet suit la procédure suivante :

Une entrée supplémentaire est fournie à l'encodeur depuis les modules ASPP, plus précisément au niveau du deuxième jusqu'au cinquième bloc de sous-échantillonnage. Cette configuration permet de conserver et combiner efficacement les caractéristiques issues de différentes opérations convolutives, tout en capturant des informations multi-niveaux.

Dans chaque branche du module ASPP, nous appliquons des convolutions dilatées de taille 3×3 avec des taux de dilatation distincts de 6, 12 et 18.

Ces valeurs permettent d'élargir le champ récepteur des filtres et d'extraire des

informations complémentaires à différentes résolutions spatiales.

Après chaque convolution dilatée, nous appliquons la fonction d'activation LeakyReLU, afin d'améliorer la capacité de représentation non linéaire du modèle, suivie d'une normalisation par lots (Batch Normalization) pour stabiliser l'apprentissage et accélérer la convergence.

Le module ASPP intègre également une couche de mise en commun des moyennes globales (Global Average Pooling), ajoutée afin d'incorporer un contexte global dans les cartes de caractéristiques. Cette couche permet de synthétiser les informations contextuelles issues de l'ensemble de l'image, contribuant ainsi à une meilleure compréhension structurelle des régions cibles.

Les sorties de toutes les branches de l'ASPP, y compris celles issues de la branche GAP, sont ensuite fusionnées par concaténation, puis combinées au moyen d'une convolution 1×1 pour générer une carte de caractéristiques finale plus homogène. Cette fusion multi-niveau permet d'améliorer la segmentation sémantique en capturant simultanément les informations locales et globales pertinentes.

Conformément à la méthodologie de Gao et Almekkawy (2021), notre implémentation du module ASPP comprend trois couches de convolution 3×3 avec des taux de dilatation de 6, 12 et 18, respectivement, comme illustré à la Figure 5.4.




Figure 5. 4 : Convolutions dilatées avec des taux de dilatation (6, 12, 18)

L'utilisation du module ASPP vise à extraire des caractéristiques manquantes que les convolutions standards ne peuvent pas capter, grâce à la variation des taux de dilatation. Après cette étape, une opération de Global Average Pooling est effectuée, suivie d'une concaténation de toutes les cartes de caractéristiques, puis d'une convolution 1×1 pour combiner efficacement les informations issues de plusieurs échelles.

Par ailleurs, nous avons exploré différents types de connexions par saut (skip connections) dans nos modèles, permettant de relier les cartes de caractéristiques de l'encodeur à celles du décodeur, comme illustré dans les figures 5.5, 5.6 et 5.7.




Figure 5. 5 : Connexion dense (DDA_UNet)




Figure 5. 6 : Connexion ASPP (ASD_UNet)




Figure 5. 7 : Module Atrous Spatial Pyramid Pooling intégré dans nos modèles

L'objectif principal de ces nouveaux modèles est d'obtenir une segmentation plus précise

du foie et des tumeurs hépatiques, en exploitant la complémentarité des algorithmes DenseNet et ASPP. L'association de ces deux modules permet d'améliorer à la fois la qualité des contours segmentés et la finesse des détails, surpassant ainsi les performances obtenues avec les modèles précédents.

5.3.6. Synthèse des choix méthodologiques

La combinaison de U-Net++, de l'encodeur DenseNet et du module ASPP aboutit à une architecture hybride optimisée. Celle-ci conjugue :

- La capacité d'U-Net++ à exploiter des informations hiérarchiques et multi-échelles ;
- La richesse descriptive de DenseNet ;
- La vision contextuelle globale apportée par l'ASPP.

Cette synergie vise à surmonter les limites des modèles traditionnels et à fournir des performances de segmentation supérieures, tant pour le foie que pour les tumeurs hépatiques.

5.4. Mise en œuvre expérimentale

La validation de la méthodologie proposée a nécessité une mise en œuvre expérimentale rigoureuse, incluant la préparation de l'environnement de calcul, le choix des hyperparamètres et la configuration des protocoles d'entraînement. Cette étape est cruciale afin d'assurer la reproductibilité et la fiabilité des résultats obtenus.

5.4.1. Environnement matériel et logiciel

Les expériences ont été réalisées sur une station de travail équipée d'un processeur Intel Core i7, de 32 Go de mémoire RAM et d'un processeur graphique NVIDIA RTX 3080 doté de 10 Go de mémoire. Ce choix matériel garantit une puissance de calcul suffisante pour l'entraînement de réseaux profonds de grande taille.

Sur le plan logiciel, nous avons utilisé le framework TensorFlow 2.x couplé à Keras pour l'implémentation des modèles. Le langage de programmation Python (version 3.8) a été retenu, en raison de sa compatibilité avec les bibliothèques spécialisées en apprentissage profond et en traitement d'images médicales, telles que NumPy, OpenCV et SimpleITK.

5.4.2. Prétraitement des données

Avant l'entraînement, les volumes CT ont été soumis à une série d'opérations de prétraitement :

- Normalisation d'intensité afin de réduire les variations liées aux protocoles d'acquisition ;
- Redimensionnement des coupes en une taille standardisée (512×512 pixels) pour

uniformiser les entrées du réseau ;

- Augmentation de données (rotations, translations, zooms et flips horizontaux/verticaux) afin d'accroître la variabilité des échantillons et de limiter le sur-apprentissage.

Ces étapes assurent une meilleure généralisation des modèles et une plus grande robustesse face aux cas cliniques hétérogènes.

5.4.3. Paramètres d'entraînement

Dans le cadre de l'apprentissage de notre modèle de segmentation sémantique amélioré, nous avons configuré avec rigueur un ensemble complet de paramètres d'entraînement afin d'optimiser la performance et la stabilité du modèle. Nous utilisons la fonction d'activation LeakyReLU, avec une pente de 0,1, au sein de chaque bloc convolutionnel. Ce choix introduit une non-linéarité essentielle permettant d'éviter le problème des neurones inactifs, souvent observé avec la fonction ReLU classique.

1 Configuration de l'encodeur DenseNet-121 modifié

L'encodeur de notre architecture repose sur une version modifiée de DenseNet-121, dont la première couche convolutionnelle est initialisée avec 64 filtres. L'encodeur est structuré en cinq blocs denses comportant respectivement 6, 12, 16 et 24 couches convolutionnelles, ce qui permet une extraction progressive et hiérarchisée des caractéristiques.

Le nombre de filtres augmente dynamiquement d'un bloc à l'autre, tandis que les couches de transition réduisent le nombre de filtres d'un facteur deux, assurant un équilibre entre richesse de représentation et efficacité computationnelle. À la sortie de l'encodeur DenseNet-121, les cartes de caractéristiques finales présentent une résolution de 8×8 et comportent 512 canaux, offrant ainsi une représentation compacte mais hautement informative des images d'entrée.

2 Intégration du module ASPP

Les cartes de caractéristiques produites par l'encodeur servent d'entrée au module Atrous Spatial Pyramid Pooling (ASPP), qui vise à capturer les informations contextuelles multi-échelles.

Ce module applique des convolutions dilatées 3×3 avec des taux de dilatation fixés à 6, 12 et 18, opérant en parallèle sur quatre branches, chacune composée de 256 filtres. Les cartes issues de ces branches sont ensuite concaténées pour générer une représentation multi-échelle unifiée de taille $8 \times 8 \times 256$, enrichissant significativement la capacité du modèle à détecter des détails complexes et des structures à différentes échelles spatiales.

3 Structure du décodeur

Le décodeur est conçu de manière symétrique à l'encodeur afin de préserver la cohérence structurelle du modèle. Il intègre des connexions de saut imbriquées (nested skip connections) sur quatre niveaux hiérarchiques. Le nombre de filtres démarre à 1024 dans la première couche du décodeur, puis est divisé par deux à chaque niveau pour permettre une reconstruction progressive des détails fins. La carte de sortie finale du décodeur présente une résolution de 512×512 pixels, correspondant exactement à la taille des images d'entrée, garantissant ainsi une segmentation fine et spatialement cohérente.

4 Paramètres d'entraînement et environnement de calcul

L'entraînement du modèle a été réalisé sur environ 500 époques, bien que le nombre exact puisse varier selon la taille du jeu de données, la complexité du modèle et le profil du taux d'apprentissage adopté.

Les expériences ont été exécutées sur le cluster de calcul haute performance (HPC-UB2) de l'Université de Batna 2, utilisé pour l'apprentissage et le test des modèles sur la base de données ACC-Batna2022. Les spécifications matérielles de ce cluster sont résumées dans le tableau 5.1.

Tableau 5. 1 : Les spécifications matérielles du cluster de calcul haute performance (HPC-UB2) de l'Université de Batna 2

CPU Node Configuration
Chaque CPU node consists of 2 Intel Xeon Gold processors
Each Intel Xeon Gold processor has 14 CPU cores, resulting in a total of 28 CPU cores per node.
Each node is equipped with 128 GB of DDR4 RAM.
It includes a 480 GB SSD for high-speed storage.
GPU Node Configuration
Each GPU node is equipped with an NVIDIA Tesla V100 GPU.
The GPU features 5,120 CUDA cores for parallel processing.
It also has 640 Tensor cores, specialized for deep learning workloads.
The GPU is equipped with 16 GB of High Bandwidth Memory 2 (HBM2) for high-speed data access.
It boasts a memory bandwidth of 900 GB/s, facilitating quick data transfer.
The GPU supports NVLink technology, with up to 6 NVLink connections, enabling high-speed communication between GPUs.

Comme l'indique le tableau ci-dessus, cette configuration correspond à un environnement HPC typique, adapté aux tâches de calcul intensif, telles que les simulations scientifiques, l'apprentissage profond ou encore l'analyse de grandes masses de données.

Concernant la base de données LiTS2017, l'entraînement et le test des modèles proposés

ont été réalisés sur la **plateforme Kaggle**, en exploitant un GPU Tesla P100, au sein d'un environnement interactif dédié à l'expérimentation et à la compétition en apprentissage automatique et profond.

5.4.4. Métriques d'évaluation

Afin d'évaluer objectivement la qualité des segmentations obtenues, plusieurs métriques standards ont été utilisées :

1 Coefficient de Dice :

Le score F1 ou coefficient de Dice est une mesure fréquemment employée pour évaluer la précision des tâches de segmentation, notamment dans les domaines de l'imagerie médicale et de la vision par ordinateur [41]. En général, il évalue la similitude ou les similitudes entre deux ensembles, en particulier la segmentation prédite (Y) et la segmentation de vérité fondamentale (X). On calcule le coefficient de Dice en utilisant la formule suivante :

$$\text{Dice Coefficient } (X, Y) = \frac{2|X \cap Y|}{|X| + |Y|} \quad (21)$$

Où, X est la cardinalité de l'ensemble X, c'est-à-dire la totalité de la plage de pixels à l'intérieur de la segmentation de vérité fondamentale, Y est la cardinalité de l'ensemble Y, c'est-à-dire la grande variété complète de pixels à l'intérieur de la segmentation attendue, et $X \cap Y$ est la cardinalité de l'intersection entre les unités X et Y, c'est-à-dire la grande variété de pixels qui sont bien segmentés à la fois dans la vérité fondamentale et dans les masques prédits.

En pratique, un coefficient de Dice plus élevé suggère une meilleure précision de segmentation, les valeurs plus proches de 1 indiquant des performances globales supérieures.

2 Intersection sur Union

La méthode de l'Intersection sur Union (IoU) est couramment employée afin d'évaluer la précision des tâches de détection et de segmentation d'objets, notamment dans les domaines de la vision par ordinateur et de l'apprentissage automatique [41]. Elle quantifie le chevauchement entre les ensembles, généralement la région prédite (Y) et la zone de vérité fondamentale (X). L'IoU est calculé comme le rapport entre la région d'intersection entre les deux régions et l'emplacement de leur union. La formule de l'IoU est la suivante :

$$\text{IoU } (X, Y) = \frac{|X \cap Y|}{|X \cup Y|} \quad (22)$$

Où X représente la région de la zone de vérité fondamentale, Y représente la zone de la

région prédite, $X \cap Y$ représente la zone d'intersection entre les deux zones, c'est-à-dire la région qui est détectée ou segmentée avec succès dans chacun des masques de vérité fondamentale et attendu, et $X \cup Y$ représente l'emplacement de l'union entre les deux zones, c'est-à-dire toute la région recouverte à la fois par les masques de vérité fondamentale ou prédits.

3 Erreur quadratique moyenne

La mesure de l'erreur quadratique moyenne (MSE) est cruciale pour évaluer la précision des pixels lors de l'évaluation des masques générés par rapport aux masques de vérité fondamentale dans différentes tâches de traitement d'images et de vision par ordinateur [41]. L'MSE quantifie l'erreur entre les pixels correspondants dans ces deux masques, fournissant une mesure de la manière dont ils correspondent étroitement. La définition mathématique de MSE est la suivante :

$$MSE(x, y) = \frac{1}{n} \sum_{i=1}^n (X_i - Y_i)^2 \quad (23)$$

Le nombre total de pixels dans le masque est donné par l'équation n, X_i est la valeur de pixel dans les masques de vérité fondamentale à la position i et Y_i est la valeur de pixel dans le masque généré à la position i. La MSE évalue la variation quadratique moyenne entre les valeurs de pixel à l'intérieur des masques. Les masques générés présentent une similitude évidente avec les masques de vérité fondamentale, ce qui suggère une meilleure précision dans la tâche de segmentation.

5.4.5. Protocoles de validation

Un protocole de validation croisée (5-fold cross-validation) a été adopté pour garantir la robustesse des résultats. Les bases ACC-BATNA2022 et LiTS2017 ont été divisées en ensembles d'entraînement, de validation et de test indépendants. Ce choix méthodologique permet de limiter les biais liés au partitionnement des données et d'obtenir une estimation plus fiable des performances réelles du modèle.

5.5. Analyse et discussion des résultats

5.5.1. Résultats de segmentation du foie

Dans un premier temps, les images médicales utilisées dans la base de données ACC-Batna2022 ont été collectées auprès du Centre Anti-Cancer (CAC) de Batna, après avoir subi plusieurs étapes de prétraitement. Divers algorithmes, tels que le modèle de Rayleigh, le modèle

de mélange gaussien (GMM) et le champ de vecteurs de gradient (GVF), ont été appliqués afin d'isoler le foie des autres organes du corps. Ces mêmes algorithmes ont ensuite été utilisés pour segmenter et extraire les tumeurs hépatiques à partir des images initiales. Sur la base de ces données traitées, nous avons développé deux nouvelles architectures de réseaux de neurones convolutifs : DDA_UNET et ASD_UNET.

La figure 5.8 illustre une comparaison qualitative entre les différentes architectures testées, mettant en évidence les résultats de segmentation obtenus sur des images CT du foie issues de la base de données ACC-BATNA2022. On y observe clairement que les modèles proposés, DDA_UNET et ASD_UNET, produisent des contours de segmentation plus précis et mieux alignés avec la vérité terrain, notamment au niveau des bords du foie et des zones tumorales. Contrairement aux modèles classiques tels que U-Net et U-Net++, qui présentent parfois des détections incomplètes ou des fuites dans les régions adjacentes, nos architectures améliorées par DenseNet et ASPP parviennent à préserver la forme anatomique réelle du foie et à mieux distinguer les structures voisines. Ces résultats visuels confirment la supériorité qualitative de nos approches et valident l'efficacité de la combinaison des connexions denses et des convolutions dilatées dans la segmentation médicale.

Figure 5. 8 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les images du foie avec de la base de données ACC-BATNA2022.


Afin d'évaluer l'efficacité de nos modèles, nous les avons comparés à trois architectures de référence largement reconnues, à savoir U-Net, U-Net++ et ASU-Net++. Le tableau 5. 2.et figures présentées ci-après (figures 5.8, et 5.9) illustrent à la fois les résultats quantitatifs et qualitatifs obtenus sur les images CT du foie issues de la base ACC-Batna2022.

Tableau 5. 2 : Résultats de la segmentation du foie par différentes architectures avec de la base de données ACC-BATNA2022

	IOU	DICE	MSE	Précision
UNET	0.8285	0.9062	0.4348	97.43 %
UNET++	0.1643	0.2823	4.3067	94.68%
ASU_NET	0.8200	0.9011	0.4260	97.423 %
ASD_UNET	0.8254	0.9043	0.5060	97.418 %
DDA_UNET	0.8339	0.9094	0.5001	97.39 %

Le tableau fournit une analyse complète des différentes métriques de performance relatives à la segmentation du foie. Les résultats montrent clairement que nos modèles proposés

*Image CT
du foie*



*Ground
truths*



UNET



UNET++



ASU_NET



rivalisent efficacement avec les architectures existantes, en les surpassant légèrement mais de manière constante sur la majorité des indicateurs. En particulier, lorsque nous comparons DDA_UNET et ASD_UNET à l'architecture de base U-Net (modèle 1), nos modèles affichent une amélioration du coefficient de Dice de 0,32 % et une réduction de l'erreur quadratique moyenne (MSE) respectivement de 6,53 % et 7,12 %, traduisant une meilleure précision de



segmentation. De plus, une hausse significative de 0,54 % de l'intersection sur l'union (IoU) confirme la supériorité de nos approches.

En comparaison avec la structure ASU-Net++ (modèle 2), nos architectures démontrent également des gains notables : une augmentation du Dice de 0,83 % et 0,32 %, une amélioration de l'IoU de 1,39 % et 0,54 %, ainsi qu'une réduction du MSE de 7,47 % et 8,00 %, respectivement.

Enfin, par rapport à U-Net++ (modèle 3), les modèles DDA_UNET et ASD_UNET présentent une hausse spectaculaire du Dice de 62,71 % et 62,20 %, ainsi qu'une amélioration de l'IoU de 66,96 % et 66,11 %, accompagnée d'une diminution significative du MSE.

Ces résultats traduisent une amélioration substantielle de la qualité de la segmentation, en particulier au niveau des contours du foie et des tumeurs hépatiques. Ainsi, les performances de nos modèles confirment leur capacité à extraire des informations plus précises et à fournir une segmentation sémantique plus fine et plus fiable que les architectures classiques.

5.5.2. Résultats de segmentation des tumeurs hépatiques

De la même manière, les résultats quantitatifs et qualitatifs obtenus à partir des segmentations des images CT du foie présentant des tumeurs hépatiques sont présentés dans le Tableau 5.3 et la Figure 6.12.

Les résultats du Tableau 5.3 indiquent que nos modèles DDA_UNET et ASD_UNET présentent des améliorations de performances substantielles par rapport à l'architecture U-Net d'origine. Plus précisément, une réduction notable de 0,99 % et 3,38 % du coefficient de Dice, une diminution de 1,16 % et 3,92 % de l'intersection sur l'union (IoU), ainsi qu'une baisse de 0,51 % et 5,85 % de l'erreur quadratique moyenne (MSE) sont observées, respectivement pour

DDA_UNET et ASD_UNET.

De plus, comparativement à ASU-Net++, nos modèles affichent des performances supérieures, avec une amélioration du coefficient de Dice de 8,57 % et 6,18 %, un gain de 9,43 % et 4,53 % au niveau de l'IoU, et une réduction du MSE de 0,81 % et 5,53 %, respectivement. Par ailleurs, face à U-Net++, nos modèles offrent des augmentations remarquables du coefficient de Dice de 69,36 % et 66,97 %, ainsi que de 53,10 % et 50,34 % pour l'IoU, tout en diminuant significativement le MSE de 38,37 % et 33,03 %, respectivement.

Ces résultats confirment la robustesse et la capacité de généralisation de nos modèles améliorés pour la segmentation de tumeurs hépatiques complexes.

Tableau 5. 3 : Résultats de la segmentation des tumeurs hépatiques sur des images CT complètes à l'aide de différentes architectures, issues de la base de données ACC-BATNA2022

	IOU	DICE	MSE	Précision
UNET	0.5426	0.7035	0.1515	99.2776 %
UNET++	0.0	0.0	0.5403	99.04 %
ASU_NET	0.4367	0.6079	0.1647	99.2774 %
ASD_UNET	0.5034	0.6697	0.2100	99.25 %
DDA_UNET	0.5310	0.6936	0.1566	99.2738 %

De plus, comparativement à ASU-Net++, nos modèles affichent des performances supérieures, avec une amélioration du coefficient de Dice de 8,57 % et 6,18 %, un gain de 9,43 % et 4,53 % au niveau de l'IoU, et une réduction du MSE de 0,81 % et 5,53 %, respectivement. Par ailleurs, face à U-Net++, nos modèles offrent des augmentations remarquables du coefficient de Dice de 69,36 % et 66,97 %, ainsi que de 53,10 % et 50,34 % pour l'IoU, tout en diminuant significativement le MSE de 38,37 % et 33,03 %, respectivement. Ces résultats confirment la robustesse et la capacité de généralisation de nos modèles améliorés pour la segmentation de tumeurs hépatiques complexes.

La Figure 5. 9 illustre la comparaison qualitative entre les modèles testés. Les résultats visuels démontrent que DDA_UNET et ASD_UNET parviennent à mieux délimiter les contours des tumeurs et à préserver la morphologie du foie, contrairement aux modèles classiques (U-Net, U-Net++, ASU-Net++) qui présentent parfois des imprécisions au niveau des bordures. Ces observations visuelles confirment les résultats quantitatifs et mettent en évidence la supériorité visuelle de nos approches.



















IMAGE CT DU FOIE				
GROUND TRUTHS				
UNET				
UNET++				
ASU_NET				



Figure 5. 9 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les images de tumeurs hépatiques issues des images CT complètes de la base de données ACC-BATNA2022.

De façon analogue, la segmentation des tumeurs hépatiques à partir des images de foie préalablement segmentées est évaluée à l'aide du Tableau 5.4 et illustrée par la Figure 5.10.

Les résultats du Tableau 5.4 confirment une amélioration notable des performances de nos modèles. Comparativement à U-Net, les modèles DDA_UNET et ASD_UNET enregistrent une diminution de 0,94 % et 6,77 % du coefficient de Dice, ainsi qu'une réduction de 1,16 % et 7,28 % de l'IoU, et une légère amélioration du MSE de 0,84 % et 3,95 %, respectivement.


Face à ASU-Net++, nos architectures maintiennent leur supériorité avec un coefficient de Dice plus élevé de 0,33 % et 6,16 %, une diminution de l'IoU de 0,36 % et 6,59 %, et une réduction du MSE de 1,96 % et 1,15 %, respectivement. Enfin, comparativement à U-Net++, les modèles DDA_UNET et ASD_UNET affichent des améliorations marquées du coefficient de Dice de 63,75 % et 57,92 %, ainsi qu'un gain de 48,15 % et 31,73 % en IoU, avec une réduction du MSE de 36,31 % et 33,20 %, respectivement. Ces performances démontrent la précision et la stabilité des modèles proposés pour la segmentation fine des tumeurs, tout en assurant une meilleure cohérence spatiale des résultats.

Tableau 5. 4 : Résultats de la segmentation des tumeurs hépatiques à partir des images du foie segmenté, obtenus par différentes architectures sur la base de données ACC-BATNA2022.

	IOU	DICE	MSE	Précision
UNET	0.5031	0.6694	0.1566	99.27 %

UNET++	0.0113	0.0225	0.5281	99.05 %
ASU_NET	0.4962	0.6633	0.1846	99.2640 %
ASD_UNET	0.4303	0.6017	0.1961	99.2670 %
DDA_UNET	0.4926	0.6600	0.1650	99.2692 %

La Figure 5.10 illustre la comparaison qualitative des résultats obtenus pour la segmentation des tumeurs hépatiques. Les contours segmentés par nos modèles se rapprochent davantage de la vérité terrain, attestant leur capacité à distinguer efficacement les régions tumorales, même dans des contextes d'images complexes.









Figure 5. 10 : Comparaison qualitative entre les modèles, affichant les résultats de segmentation pour les tumeurs hépatiques à partir des images de foie segmenté, issues de la base de données ACC-BATNA2022.



Enfin, la Figure 5.11 présente les courbes d'apprentissage et de validation correspondantes. Ces graphiques confirment que DDA_UNET et ASD_UNET atteignent une meilleure stabilité d'apprentissage, avec une perte plus faible et une précision plus élevée, témoignant de la fiabilité et de la convergence rapide de nos approches.





UNET++





ASU_NET



ASD_UNET



DDA_UNET



(a)

(b)

Figure 5. 11 : Graphiques de perte et de précision pour les données d'entraînement et de validation relatives à la segmentation des tumeurs hépatiques à partir des images du foie segmenté (a) Précision – (b) Perte.

5.5.3. Résultats de la segmentation du foie et des tumeurs hépatiques à partir de la base de

données LiTS2017

Les résultats qualitatifs et quantitatifs de la segmentation du foie et des tumeurs hépatiques sur la base de données LiTS2017 sont présentés dans le Tableau 5.5. Ce tableau propose une analyse détaillée des performances des différents modèles selon plusieurs métriques de segmentation.









Tableau 5. 5 : Résultats de la segmentation du foie et des tumeurs hépatiques par différentes architectures sur la base de données LiTS2017

	IOU	DICE	MSE	Précision	Moyenne IOU
UNET	0.6112	0.7587	0,0108	99.4144 %	0,8847
UNET++	0,5260	0,6894	0,0375	97,1883 %	0,5450
ASU_NET	0.6082	0,7563	0.0109	99.5215 %	0,9055
ASD_UNET	0.6170	0.7632	0,0110	99.4492 %	0,8576
DDA_UNET	0.6071	0.7555	0.0109	99,4412 %	0,8882


Il est important de souligner que les modèles proposés, DDA_UNET et ASD_UNET, affichent des performances nettement supérieures à celles des architectures de référence, démontrant ainsi leur efficacité et leur robustesse. En comparaison avec l'architecture de base U-Net, nos modèles montrent une amélioration notable : le coefficient de Dice augmente respectivement de 0,32 % et 0,45 %, tandis que l'intersection sur l'union (IoU) s'améliore de 0,41 % et 0,58 %. Par ailleurs, une légère réduction de l'erreur quadratique moyenne (MSE) de 0,01 % et 0,02 % est observée, traduisant une meilleure précision de reconstruction.

De même, face à la structure ASU-Net++, nos modèles présentent des gains significatifs, avec une hausse du Dice de 0,08 % et 0,69 %, une amélioration de l'IoU de 0,11 % et 0,88 %, et une stabilité remarquable du MSE. Enfin, comparativement à U-Net++, les progrès sont encore plus marqués : les valeurs du Dice augmentent de 6,61 % et 7,38 %, celles de l'IoU de 8,11 % et 9,10 %, tandis que le MSE diminue respectivement de 2,66 % et 2,65 %.

Ces résultats démontrent clairement la supériorité de nos architectures en termes de précision et de cohérence des contours segmentés. Pour une meilleure compréhension des performances visuelles, la Figure 5.12 illustre des échantillons de segmentation issus de différents modèles, mettant en évidence la capacité de DDA_UNET et ASD_UNET à mieux distinguer les frontières du foie et des tumeurs hépatiques.

IMAGE CT DU FOIE				
GROUND TRUTHS				
UNET				
UNET++				
ASU_NET				

ASD_UNET




DDA_UNET





Figure 5. 12 : Comparaison qualitative entre les modèles, illustrant les résultats de segmentation du foie et des tumeurs hépatiques sur la base de données LiTS2017.

La Figure 5.13 présente les courbes de perte et de précision pour les phases d'entraînement et de validation. On observe que les modèles proposés exhibent une courbe de perte plus stable et une convergence plus rapide, témoignant d'une meilleure capacité d'apprentissage et d'une généralisation accrue par rapport aux modèles de référence.



UNET




UNET++





ASU_NET



ASD_UNET



DDA_UNET



(a)

(b)

**Figure 5. 13 : Courbes de perte et de précision pour la segmentation du foie et des tumeurs hépatiques sur la base de données LiTS2017 :
(a) Précision – (b) Perte.**

5.6. Discussion

Dans le domaine du diagnostic médical, l'analyse d'images radiologiques constitue une étape critique, mais souvent sujette à des erreurs d'interprétation. Ces erreurs peuvent provenir de divers facteurs : erreurs de détection, de localisation, de perception ou encore de communication. Parmi elles, la cécité d'inattention est particulièrement problématique — elle survient lorsque l'observateur omet un élément visible mais inattendu, en raison d'une focalisation excessive sur une autre tâche visuelle.

L'apprentissage profond, notamment à travers les réseaux de neurones convolutifs, s'impose aujourd'hui comme un outil essentiel pour réduire ces erreurs, en particulier dans la détection précoce des cancers, y compris des tumeurs hépatiques de petite taille.

Dans cette étude, nous avons utilisé nos modèles DDA_UNET et ASD_UNET pour segmenter le foie et les tumeurs hépatiques sur les bases ACC-BATNA2022 et LiTS2017. Les expériences menées démontrent que nos modèles répondent efficacement aux exigences de la segmentation d'images médicales, en offrant une précision accrue et une meilleure définition des contours.


Afin d'adapter le traitement à nos ressources matérielles, les images ont été redimensionnées à 112×112 pixels pour un entraînement sur GPU Kaggle ($\text{batch_size} = 2$, $\text{epochs} = 100$) pour LiTS2017, et sur le HPC de l'Université de Batna 2 ($\text{batch_size} = 2$, $\text{epochs} = 500$) pour ACC-BATNA2022, avec l'optimiseur Adam. Par la suite, nous avons expérimenté une méthode alternative basée sur la division en patches, permettant de préserver les caractéristiques locales sans réduire la taille des images. Chaque image a été divisée en 16 sous-images avec leurs masques correspondants, augmentant significativement le volume de données d'apprentissage. Cependant, la limitation de la mémoire GPU a restreint le nombre total d'images utilisables.

Malgré ces contraintes, les résultats obtenus avec la méthode des patches sont très prometteurs. Par exemple, le modèle U-Net a atteint une précision de 99,31 %, une moyenne IoU de 0,9272, un score IoU de 0,8979, un score Dice de 0,9462, et un MSE de 0,0063, démontrant ainsi la pertinence de cette approche.

Images originales

Ground truths

UNET






Figure 5. 14 : Exemple de résultats de segmentation obtenus avec le modèle U-Net sur la base LiTS2017 : comparaison entre l'image originale, le masque et la segmentation prédite.

5.7. Conclusion

Dans cette étude, nous avons développé efficacement une méthode particulière pour la segmentation du foie et des tumeurs. Nos nouvelles méthodes intègrent de manière transparente DenseNet, ASPP (Atrous Spatial Pyramid Pooling) et U-Net++, dans le but d'améliorer l'extraction. Nous y sommes parvenus en remplaçant les couches d'encodage conventionnelles par un DenseNet modifié. Ce changement a permis à nos modèles de capturer des informations plus fines et plus nombreuses dans les données d'entrée, un aspect crucial pour les tâches nécessitant la meilleure précision possible en matière de segmentation.

L'intégration de DenseNet a en outre permis au modèle U-net++ d'exceller dans la capture des détails les plus infimes, une fonctionnalité d'une importance capitale pour les tâches de segmentation compliquées ou particulièrement spécifiques, où la délimitation unique des frontières de l'objet et la capture des caractéristiques diffuses sont essentielles pour obtenir des résultats précis.

Nos modèles ont fait l'objet d'une validation approfondie sur des bases de données de référence, telles que la base de données ACC-BATNA2022 collectée auprès du Centre Anti-Cancer de Batna, en Algérie, et la base de données LiTS17. La supériorité des modèles proposés pour la segmentation du foie dans les images de tomodensitométrie est simplement confirmée par les résultats. Les modèles DDA_UNET et ASD_UNET ont obtenu des taux de précision exceptionnels de 97,418 % et 97,39 % respectivement pour la segmentation du foie, et de 99.25 %, 99.273 % et 99.2670 %, 99.2692 % respectivement pour la segmentation des tumeurs du foie de l'image complète et segmentée, respectivement. Nos versions ont également obtenu des résultats remarquables en ce qui concerne la segmentation des tumeurs hépatiques, avec une

précision de nos modèles de 0,8576 et 0,8882% pour la base de données LITS-17. Ces résultats mettent en évidence la solidité et la capacité de nos méthodes, qui se révèlent prometteuses pour améliorer considérablement l'analyse et le diagnostic des images médicales.

Chapitre 6 : CLASSIFICATION DES CANCERS TUMORAUX HEPATIQUES À L'AIDE DE RESEAU NEURONAL CONVOLUTIF (CNN)

6.1 Introduction

Le foie a des fonctions vitales importantes dans le corps humain, puisqu'il est responsable de la digestion et de l'absorption des graisses, en plus de son rôle dans la transformation du sang, ainsi que de sa contribution à plusieurs processus, notamment : le métabolisme et la fabrication de certaines protéines, etc. De nombreuses maladies du foie n'apparaissent que tardivement, d'où l'importance d'un diagnostic précoce, qui joue un rôle important dans le traitement. Le cancer du foie est la maladie la plus répandue dans le monde. Il existe de nombreux moyens de diagnostiquer la présence et le type de la maladie, tels que : l'imagerie par résonance magnétique, l'échographie, la tomodensitométrie...

L'apprentissage profond est vaste, il est utilisé dans plusieurs domaines, et ici il est utilisé dans le domaine médical spécifiquement dans l'imagerie médicale pour détecter et anticiper les maladies, par exemple les maladies du foie. Nous avons utilisé dans cet article une méthode issue de plusieurs méthodes d'apprentissage profond et très efficace dans la détection précoce et le diagnostic du cancer et il s'agit du CNN (Convolutional Neural Networks). Elle a prouvé son efficacité dans plusieurs domaines, dont notre domaine d'étude. Il existe de nombreuses méthodes d'apprentissage profond pour la classification des images médicales en général et du foie en particulier, dont les réseaux de neurones convolutifs (CNN), mais la manière dont elle est utilisée et employée varie en fonction de l'étude demandée.

En outre, ces méthodes aident les radiologues et les spécialistes à détecter les lésions hépatiques et à prendre des décisions sur l'état et l'évolution du patient. L'utilisation de systèmes d'intelligence artificielle, en particulier l'apprentissage profond, nous aide souvent beaucoup à classer et à diagnostiquer les maladies du foie à l'aide d'algorithmes spéciaux assistés par ordinateur avec de très grandes capacités en termes de mémoire, de processeur et de carte graphique....

Tout ce qui précède n'élimine pas l'importance et le rôle du radiologue, qui joue un rôle fondamental dans le processus de diagnostic. Les entrées du CNN sont des images exclusivement du foie, extraites automatiquement des images de tomographie par ordinateur, comme mentionné précédemment. La qualité des images d'entraînement CNN et la durée d'apprentissage et d'entraînement de ce réseau influencent le résultat de la classification ; plus l'apprentissage est important, plus les résultats sont satisfaisants et plus la précision d'apprentissage est élevée. Ces entrées CNN sont plus précises que l'utilisation de l'ensemble des images CT, et c'est ce que nous remarquerons dans nos résultats.

6.2 La Classification de la tumeur de foie

6.2.1 Méthodes de segmentation

1) Rayleigh :

Nous avons utilisé la courbe de Rayleigh pour séparer l'arrière-plan de l'image. Cette courbe de Rayleigh définit le seuil X_s de l'arrière-plan de l'image [7].

$$R(x) = w * \frac{x}{\sigma^2} * \exp\left(\frac{-x^2}{2\sigma^2}\right) \quad (24)$$

2) GMM (modèles de mélange gaussien) :

Nous avons ensuite utilisé la méthode de classification GMM (modèles de mélange gaussien) pour l'apprentissage automatique afin d'obtenir les entrées que nous utilisons dans le seuil, à savoir le seuil inférieur et le seuil supérieur. Les données d'image sont divisées en classes selon cette méthode. La valeur inférieure correspond à la moyenne des valeurs des pixels de l'image, tandis que la valeur supérieure correspond à la valeur la plus élevée des moyennes lorsque les valeurs osseuses sont supprimées. Quant au seuil, il permet d'extraire la zone spécifique (le foie) par le biais des valeurs inférieure et supérieure [7].

Chaque composante a un « poids », w_i : la proportion des données globales qui appartient à cette composante. Par conséquent, la distribution de probabilité combinée, $f(x)$ est de la forme :

$$f(x) = \sum_{k=1}^k \frac{\frac{w_k}{d}}{(2\pi)^2 |\Sigma_k|^{-\frac{1}{2}}} \exp\left\{\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right\} \quad (25)$$

σ_i et μ représentent la variance et la moyenne de chacune des N gaussiennes.

3) GVF (Gradient Vector Flow) :

Pour utiliser l'algorithme GVF, nous appliquons cet algorithme en présentant la carte des bords f qui est représentée par un ensemble de points dont la déformation dépend de la minimisation de la fonction d'énergie (E) comme indiqué dans l'équation suivante[7]:

$$E = \int_0^1 [E_{int}(C(s)) + E_{ext}(C(s))] ds \quad (26)$$

$$E = \int_0^1 \frac{1}{2} \left[\alpha(s) \left(\frac{dc}{ds} \right)^2 \right] + \frac{1}{2} \left[\beta(s) \left(\frac{d^2c}{ds^2} \right)^2 \right] - \gamma(s) \frac{\nabla I(x, y)}{|\nabla I(x, y)|} + k(s) V_{GVF} \quad (27)$$

- $\alpha(s)$: paramètre de lissage,
- $\beta(s)$: constante de force de l'image,

- $\gamma(s)$: poids de la force GVF,
- $k(s)$: paramètre d'élasticité.

La GVF améliore le résultat du seuil pour faciliter l'étude de celui-ci dans les étapes suivantes.

6.2.2 Classification du CNN

Il s'agit d'un groupe de couches qui forment un réseau neuronal convolutif, chaque couche étant différente des autres, nous les mentionnons brièvement :

1. La couche convolutive :

Il s'agit d'appliquer un ensemble de filtres sur les images pour extraire les caractéristiques de ces images. Deux des 32 filtres de $3 * 3$ pixels, ainsi que deux des 64 filtres de $3 * 3$ pixels, sont utilisés ici, ce qui nous donne un ensemble de cartes de caractéristiques. Les filtres utilisés dans la première couche de convolution sont simples : des bords verticaux, horizontaux et diagonaux, ainsi que des petits points ou taches d'une couleur entourés d'une autre [2]. Il y a plusieurs noyaux de convolution dans la couche de convolution ($g_1 \dots g_{k-1}, g_k$), chaque g_k étant une fonction linéaire dans le noyau k -th, comme la fonction suivante [37] :

$$g^k(x, y) = \sum_{u=-m}^m \sum_{v=-n}^n \sum_{w=-d}^d w_k(u, v, w) I(x - u, y - v, z - w) \quad (28)$$

Où (x, y, z) est la position du pixel dans l'entrée, w_k est le poids pour le k -th kernel, m , n et w est la hauteur, la largeur et la profondeur du filtre [31].

2. La couche d'activation :

Les valeurs négatives de l'image de convolution peuvent être supprimées en les remplaçant par la valeur 0. f est une fonction non linéaire au niveau du pixel, c'est-à-dire une unité linéaire rectifiée (ReLU)[31]:

$$f(x) = \max(0, x) \quad (29)$$

Sans cette activation, les résultats de l'apprentissage profond ne seraient pas satisfaisants [31].

3. La couche de mise en commun :

Afin d'extraire les caractéristiques essentielles de la convolution, il cherche la valeur maximale présente dans les cartes de caractéristiques, et chaque couche de convolution est

reliée à une couche de mise en commun [31].

4. La couche entièrement connectée :

Elle prépare les données des images à intégrer dans un réseau neuronal et aplatit ces images en une seule colonne [31].

5. La couche de prédiction :

Il s'agit d'une couche d'apprentissage qui utilise des couches de neurones entièrement connectés pour l'entrée, la couche d'aplatissement précédemment réalisée, et pour la sortie, une prédiction, c'est-à-dire une probabilité par classe (normale et anormale) (0,1).

6. Fonction Softmax :

Nous utilisons la fonction Softmax pour la couche de prédiction, choisir la bonne classe pour chaque probabilité.

7. Normalisation des lots :

Avec toutes ces couches, nous avons utilisé la normalisation par lots pour normaliser le résultat de chaque couche qui est une entrée pour la couche suivante et le grand rôle de la normalisation de Batch est d'éliminer la grande différence entre les valeurs. Après chaque couche entièrement connectée [31].

8. Dropout :

Nous utilisons le Dropout pour éliminer les valeurs qui ne nous intéressent pas et pour diminuer la charge du réseau neuronal.

9. Optimiseur et perte :

Enfin, nous utilisons l'optimiseur Adam pour entraîner nos réseaux convolutifs et la perte binaire_crossentropy pour 2 classifications.

6.3 MÉTHODOLOGIE

Nous avons proposé un modèle CAD appelé technique CNN à seuil gaussien, qui consiste à segmenter le foie en fonction de l'intensité dans les images de tomodensitométrie. Le seuil proposé et le GMM avec la fonction de Rayleigh pour le processus de segmentation ont été utilisés pour séparer le foie des autres organes de l'abdomen. Les caractéristiques statistiques, texturales et géométriques extraites ont été classées à l'aide d'un classificateur CNN afin de différencier les types de foie normaux et anormaux. Dans le diagramme suivant, nous donnons

une explication détaillée de ce que nous avons fait en pratique en utilisant le langage de programmation Python 3.8 avec les sacs TensorFlow 2.4.1, cuda 11.0.3 et cudnn 11.2, keras et OpenCv et d'autres paquets.




Figure 6. 1 : Étapes de la technique CNN basée sur le seuil gaussien

6.4 ENSEMBLE DE DONNÉES

Ces données ont été obtenues auprès de l'institut hospitalier spécialisé, le Centre anticancer (CAC) de Batna, à l'aide de tomodensitogrammes, et nous les avons exploitées pour extraire les images des coupes du foie par tomodensitométrie. Nous avons ensuite extrait automatiquement le foie seul dans toutes les images, puis nous l'avons organisé pour obtenir une base de données en la divisant en trois fichiers, chaque fichier contenant un pourcentage spécifique des images à classer, que nous avons appelé formation, validation et test. Chaque fichier contient deux fichiers pour la classification en foie normal ou anormal. Il en va de même pour les images originales du foie. Toutes les images ont une taille unique de 512 x 512 pixels.

Nous avons utilisé cette base de données comme entrée pour le réseau neuronal convolutionnel CNN, nous avons donc redimensionné les images à 224 x 224 pixels afin de nous entraîner dessus et de les classer à l'aide du fichier test. Cette étude comprenait 706 images différentes de plusieurs personnes, dont 302 images des patients et 404 images des personnes ayant un foie sain. Les données relatives aux patients ont été divisées en 90 % pour l'entraînement et 10 % pour la validation.

L'étude a été exécutée à l'aide de python 3.8 dans un HP Probook équipé d'un processeur Intel (R) Core i7 de 8ème génération, de 8 Go de RAM et d'un GPU NVIDIA GeForce 930MX pour l'entraînement.

6.5 RÉSULTATS DE LA CLASSIFICATION ET DISCUSSION

Nos résultats sur le CNN sont résumés dans le tableau .1. Notre réseau avec segmentation du foie atteint des taux de précision de 99,84%, 0,94% d'erreur d'apprentissage et de précision de test de 98,61%, 4,95% d'erreur de test. Il s'agit de la meilleure performance obtenue lors des tests avec une approche qui consiste à former des modèles CNN de segmentation du foie sur des caractéristiques différentes.

Le test sur un CNN similaire avec une image médicale complète du foie permet d'obtenir des taux de précision de 100%, $3,83 \times 10^{-5}$ % d'erreur lors de l'apprentissage et des taux de précision de 26,19%, $83,99 \times 10^{-2}$ % d'erreur lors du test. Après chaque couche convolutive, il y a la couche de mise en commun, puis après cette couche aplatie, et les trois dernières couches trois couches entièrement connectées.

Nous notons également que la classification des images médicales, malgré la grande précision de la classification, il était difficile de trouver un modèle spécifique du réseau neuronal pour une classification correcte et précise, et après beaucoup d'études et d'entraînement, nous avons atteint ce modèle qui nous a donné cette classification correcte et cette grande précision dans l'entraînement et tout cela en utilisant nos photos médicales du Centre Anti Cancer de Batna.

Tableau 6. 1 : Tableau des résultats CNN

Type de données d'entrée (CNN)	Score F1		Précision		Rappel		Précision globale
	<i>H</i>	<i>L</i>	<i>H</i>	<i>L</i>	<i>H</i>	<i>L</i>	
Image du foie SEG	0.99	0.98	1	0.97	0.98	1	99%
Image du foie COMP	0.42	0.00	0.55	0.00	0.33	0.00	26%

Nos résultats démontrent que le réseau neuronal convolutif proposé est capable d'obtenir de bons résultats dans un ensemble de données d'imagerie médicale en utilisant l'apprentissage profond. Nous notons que le résultat de la classification dans notre réseau se détériore si l'une ou l'autre des couches est supprimée. La profondeur est donc vraiment importante pour obtenir nos résultats. Jusqu'à présent, nos résultats se sont améliorés au fur et à mesure que nous avons développé notre réseau et que nous l'avons entraîné pendant une période plus longue. Nous aimons utiliser des réseaux convolutifs larges et profonds pour les maladies du foie. Un plus grand nombre d'images fournit des informations très utiles.

1) Estimation des performances :

La mesure de validation de la technique CNN basée sur le seuil gaussien se fait dans les termes suivants :

$$Recall = \frac{TP}{TP + FN} \quad (30)$$

$$Precision = \frac{TP}{TP + FP} \quad (31)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (32)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (33)$$

$$F1 = \frac{2}{Recall^{-1} + Precision^{-1}} \quad (34)$$

- TN : True Negative (Vrai négatif) : La valeur réelle était négative et le modèle a prédit une valeur négative. Il a correctement identifié que la personne était normale.
- FP : False Positive (faux positif) : La valeur réelle était négative et le modèle a prédit une valeur positive. Il s'agit également d'une erreur de type I. Le modèle a prédit que la personne était anormale, alors qu'en réalité elle ne l'est pas.
- FN : Faux négatif : La valeur réelle était positive et le modèle a prédit une valeur négative. Il s'agit d'une erreur de type II. Le modèle a prédit que la personne était normale, alors qu'elle l'est en réalité.
- TP : Vrai positif : La valeur réelle était positive et le modèle a prédit une valeur positive. Il a correctement identifié que la personne était anormale.




Figure 6. 2 : Résultats de précision et de validation du foie segmenté




Figure 6. 3 : Résultats de précision et de validation du foie complet




Figure 6. 4 : Résultats de perte de précision et de validation du foie segmenté




Figure 6. 5 : Résultats de perte de précision et de validation du foie complet

6.6 Conclusion

- RÉSUMÉ DE L'ÉTUDE

L'entraînement sur ce CNN nous a donc permis d'obtenir une classification précise et correcte, avec un taux de précision de 100% pour un foie sain et de 97% pour un foie malade, avec une précision d'entraînement très élevée allant jusqu'à 99% dans le foie segmenté, et un taux de précision de 55% pour un foie sain et de 0% pour un foie malade, avec une précision d'entraînement très élevée allant jusqu'à 26% dans le foie complet. Le résultat de la matrice de confusion révèle que les modèles de classification ont été développés afin de prédire si une personne est normale (négative) ou anormale (positive) en se basant sur diverses variables, comme illustré dans la figure ci-dessous :




Figure 6. 6 : Matrice de confusion pour les résultats CNN du foie segmenté




Figure 6. 7 : Matrice de confusion pour les résultats CNN foie complet

Conclusion générale& Perspective

Conclusion générale & Perspective

1. Généralités sur la thèse

La recherche menée dans le cadre de cette thèse vise principalement à présenter quelques méthodes originales permettant de repérer les lésions cancéreuses dans les tomodensitogrammes du foie. Dans notre étude sur la détection et la segmentation des lésions cancéreuses, on a utilisé différentes méthodes pour repérer et segmenter les tumeurs hépatiques, qui peuvent être utilisés pour la diagnostic précoce des maladies. Nous avons développé certaines méthodes automatisées et améliorées pour la détection des tumeurs cancéreuses à l'aide d'images de tomodensitométrie, qui ont été illustrées du chapitre 2 au chapitre 6. L'objectif final de ce travail de recherche est de mettre au point une technique automatique basée sur le diagnostic assisté par ordinateur pour la détection du cancer du foie dans les données de tomodensitométrie.

Des techniques automatiques d'apprentissage profond et l'apprentissage machine ont été développées et testées sur un grand nombre de données et les résultats ont été évalués et analysés. Le travail présenté dans cette thèse a été utilisé de manière significative dans l'analyse d'images médicales pour le diagnostic du cancer du foie à des fins cliniques et de recherche. Dans ce chapitre, les techniques présentées sont passées en revue, leurs limites et les perspectives d'avenir sont proposées.

2. Conclusion

De nos jours, les techniques d'apprentissage automatique sont de plus en plus utilisées dans les diagnostics médicaux. Les images de tomodensitométrie constituent un moyen efficace de détecter les lésions cancéreuses dans le foie. La méthodologie CAD proposée ici se compose de plusieurs étapes : l'acquisition des images médicales, La segmentation du foie et les tumeurs hépatiques par des algorithmes d'apprentissages automatique, la création d'une base de données, la segmentation du foie et tumeurs hépatiques par des méthodes d'apprentissages profond, l'évaluation des résultats avec nos approches. L'objectif principal de cette thèse est de développer des méthodes automatiques basées sur une approche d'apprentissage profond pour la détection précise du cancer du foie afin d'aider les radiologues dans la pratique clinique.

La thèse apporte la contribution principale à la détection automatique et à la classification des lésions cancéreuses du foie pour le diagnostic clinique dans les points suivants.

- Plusieurs méthodes de détection et de segmentation du cancer du foie ont fait l'objet d'une étude approfondie. Ces études suggèrent que le diagnostic du cancer du foie peut être

amélioré en augmentant la précision de la détection à l'aide d'un processus automatisé. Il s'agit donc d'une meilleure méthodologie qui inclut différents algorithmes de segmentation et de classification.

- 112 ensembles de tomodensitogrammes du foie de 512×512 pixels présentant des tumeurs hépatiques a été collecté du centre anti cancer de Batna, en Algérie. Toutes les images ont été confirmées par des radiologues experts. Les images sont stockées au format DICOM (Digital Imaging and Communication in Médecine). Les fichiers DICOM ont été extraits et des programmes Python ont été développés pour convertir les images DICOM en BMP ou JPG.
- Dans un premier temps, une méthode automatisée basée sur l'algorithme GVF est présentée pour segmenter les tumeurs hépatiques à l'aide des autres algorithmes de prétraitements (GMM, Seuillage, courbe de Rayleigh...). Le résultat de cette segmentation est une base de données du foie et les tumeurs hépatiques avec leurs masques. En va classifier cette base de données en des personnes maladies ou normale avec la classifieur CNN dans le chapitre 6.
- Dans d'autres travaux, deux nouvelles approches d'apprentissage profond ont été proposée. Ils utilisent les méthodes ASPP et DenseNET avec UNET++ pour la segmentation des fois et des tumeurs hépatiques. Ils sont basés sur l'extraire des masques du foie et des tumeurs hépatiques comme le résultat de ces approches. Les modèles ont été testé sur 1019 images de cancers du foie normaux, bénins et malins. Les évaluations des résultats dans le chapitre 5.
- La discussion ci-dessus nous a permis de conclure que les approches proposées est la mieux adaptée à la détection et segmentation du cancer du foie dans les images de tomodensitométrie. Ces approches sera utile pour un diagnostic clinique précis et un processus de prise de décision pour un diagnostic précoce des tumeurs.

3. Limites et travaux futurs

Bien que les modèles proposés aient permis de détecter efficacement les tumeurs hépatiques dans les images CT du foie, l'étude présente encore certaines limites qui peuvent être surmontées dans le cadre des travaux futurs.

Nous ne sommes pas en mesure de calculer la taille volumétrique de la lésion, ce qui peut être résolu par une structure de maillage tridimensionnelle. Nous n'avons utilisé que la modalité CT, d'autres modalités comme l'IRM, les US peuvent être étendues pour une meilleure détection des lésions. Ces résultats de nos modèles peuvent être améliorer avec meilleur matérielle

d'apprentissage profond (spécifiquement le GPU).

Les travaux futurs consisteront à explorer d'autres méthodes possibles pour classifier les tumeurs hépatiques avec leurs types. L'accent sera mis sur la détection de très petites lésions et sur l'utilisation de vastes ensembles de données.

Contributions scientifiques

1. T. Amina, B. Hakim, A semantic segmentation framework for liver and livertumour segmentation, 2025 International Journal of Innovative Computing and Applications, pp.118-133, doi: 10.1504/IJICA.2025.145036.
2. T. Amina, L. Lakhdar, B. Hakim and M. Abdallah, "Improved Active Contour Model through Automatic Initialisation: Liver Segmentation," 2021 IEEE 1st International Maghreb Meeting of the Conference on Sciences and Techniques of Automatic Control and Computer Engineering MI-STA, Tripoli, Libya, 2021, pp. 771-775, doi: 10.1109/MI-STA52233.2021.9464516.
3. T. Amina, L. Lakhdar, B. Hakim and M. Abdallah, "Convolutional Neural Networks for Segmented Liver Classification," 2021 International Conference on Recent Advances in Mathematics and Informatics (ICRAMI), Tebessa, Algeria, 2021, pp. 1-5, doi: 10.1109/ICRAMI52622.2021.9585986.

Bibliographie

- [1] D. Aude, F. B, et V. G, Cancerologie Hematologie, 4e édition. en 50 Dossiers Préparation aux Epreuves. Editions Estem, 2008.
- [2] P. Christophe, M. Baptiste, et J. Chantal, Nouveaux dossiers de l'infirmière Processus Tumoraux. MALOINE, 2012. [En ligne]. Disponible sur : <https://www.livres-medicaux.com/semestre-5/6162-nouveaux-dossiers-de-l-infirmiere-processus-tumoraux-ue-2-9.html>
- [3] Das, Amita Rani. s. d. « DOCTOR OF PHILOSOPHY IN ENGINEERING ».
- [4] R. B. Kahla, A. Barkaoui, et T. Merzouki, Finite Element Method and Medical Imaging Techniques in Bone Biomechanics, 1re éd. Wiley, 2019. doi: 10.1002/9781119681625.
- [5] A. K. Jumaat, W. E. Z. W. A. Rahman, A. Ibrahim, et R. Mahmud, « Segmentation of Masses from Breast Ultrasound Images using Parametric Active Contour Algorithm », Procedia - Soc. Behav. Sci., vol. 8, p. 640-647, 2010, doi: 10.1016/j.sbspro.2010.12.089.
- [6] N. Khalifa, A. Malek, et K. Hamrouni, « Segmentation d'images par contours actifs : Application à la détection du ventricule gauche dans les images de scintigraphie cardiaque », 31/03 2005.
- [7] P.-Y. Daniau-Clavreul, V. Roullier, et C. Cavarro-Ménard, « Segmentation automatique du foie sur des IRM abdominales ».
- [8] M. Dhibi, J. Puentes, L. Bressollette, B. Guias, B. Solaiman. Détection des Contours des Thrombus Veineux dans les Images Echographiques. SETIT : Sciences Electroniques, Technologies de l'Information et des Télécommunications, Mar 2005, Sousse, Tunisie.
- [9] M. Menard, V. Courboulay, et C. Cavarro-Ménard, « 196 PUBLICATIONS 2,665 CITATIONS SEE PROFILE ».
- [10] C. Zimmer, E. Labruyere, V. Meas-Yedid, N. Guillen, et J. Olivo-Marin, « Segmentation and tracking of migrating cells in video microscopy with parametric active contours: a tool for cell-based drug testing », IEEE Trans. Med. Imaging, vol. 21, no 10, p. 1212-1221, oct. 2002, doi: 10.1109/TMI.2002.806292.
- [11] Fekir, A., Benamrane, N., & Taleb-Ahmed, A. (2009). Détection et Suivi d'Objets dans une Séquence d'Images par Contours Actifs. In CIIA.
- [12] Li, T., Krupa, A., & Collewet, C. (2011). Un contour actif robuste basé sur les descripteurs de Fourier. In ORASIS-Congrès des jeunes chercheurs en vision par ordinateur.
- [13] D. Smeets, D. Loeckx, B. Stijnen, B. D. Dobbelaer, D. Vandermeulen, et P. Suetens, « Semi-automatic level set segmentation of liver tumors combining a spiral-scanning technique

with supervised fuzzy pixel classification », *Med. Image Anal.*, vol. 14, no 1, p. 13-20, 2010, doi: <https://doi.org/10.1016/j.media.2009.09.002>.

[14] B. N. Li, C. K. Chui, S. Chang, et S. H. Ong, « A new unified level set method for semi-automatic liver tumor segmentation on contrast-enhanced CT images », *Expert Syst. Appl.*, vol. 39, no 10, p. 9661-9668, août 2012, doi: 10.1016/j.eswa.2012.02.095.

[15] O. Ozturk, B. Saritürk, et D. Z. Seker, « Comparison of Fully Convolutional Networks (FCN) and U-Net for Road Segmentation from High Resolution Imageries », *Int. J. Environ. Geoinformatics*, vol. 7, no 3, p. 272-279, sept. 2020, doi: 10.30897/ijegeo.737993.

[16] O. Ronneberger, P. Fischer, et T. Brox, «U-Net: Convolutional Networks for Biomedical Image Segmentation », 18 mai 2015, arXiv: arXiv:1505.04597. Consulté le : 1 novembre 2022. [En ligne]. Disponible sur : <http://arxiv.org/abs/1505.04597>

[17] J. Long, E. Shelhamer, et T. Darrell, « Fully convolutional networks for semantic segmentation », in 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA: IEEE, juin 2015, p. 3431-3440. doi: 10.1109/CVPR.2015.7298965.

[18] Liu, W. (2015). Parsenet: Looking wider to see better. arXiv preprint arXiv:1506.04579.

[19] V. Badrinarayanan, A. Kendall, et R. Cipolla, « SegNet : A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation », *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no 12, p. 2481-2495, déc. 2017, doi: 10.1109/TPAMI.2016.2644615.

[20] G. Wang, W. Li, S. Ourselin, et T. Vercauteren, « Automatic Brain Tumor Segmentation using Cascaded Anisotropic Convolutional Neural Networks », vol. 10670, 2018, p. 178-190. doi: 10.1007/978-3-319-75238-9_16.

[21] A. G. Howard et al., « MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications », 16 avril 2017, arXiv: arXiv :1704.04861. Consulté le : 15 novembre 2022. [En ligne]. Disponible sur: <http://arxiv.org/abs/1704.04861>

[22] D. Cheng, R. Liao, S. Fidler, et R. Urtasun, « DARNet: Deep Active Ray Network for Building Segmentation », in 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA: IEEE, juin 2019, p. 7423-7431. doi: 10.1109/CVPR.2019.00761.

[23] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, et D. Terzopoulos, « Image Segmentation Using Deep Learning: A Survey », 14 novembre 2020, arXiv: arXiv:2001.05566. Consulté le : 15 novembre 2022. [En ligne]. Disponible sur: <http://arxiv.org/abs/2001.05566>

[24] O. Oktay et al., «Attention U-Net: Learning Where to Look for the Pancreas », 20 mai

2018, arXiv: arXiv:1804.03999. Consulté le: 1 novembre 2022. [En ligne]. Disponible sur: <http://arxiv.org/abs/1804.03999>

[25] X. Qin, Z. Zhang, C. Huang, M. Dehghan, O. R. Zaiane, et M. Jagersand, « U²-Net: Going Deeper with Nested U-Structure for Salient Object Detection », *Pattern Recognit.*, vol. 106, p. 107404, oct. 2020, doi: 10.1016/j.patcog.2020.107404.

[26] R. Jean-Jacques, « Les contours actifs, une méthode de segmentation. Application à l'imagerie médicale », Thèse de doctorat, Université de François Rabelais de Tours, 2003.

[27] M. Kass, A. Witkin, et D. Terzopoulos, « Snakes: Active contour models », *Int. J. Comput. Vis.*, vol. 1, no 4, p. 321-331, janv. 1988, doi: 10.1007/BF00133570.

[28] A. A. Amini, T. E. Weymouth, et R. C. Jain, « Using dynamic programming for solving variational problems in vision », *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 12, no 9, p. 855-867, sept. 1990, doi: 10.1109/34.57681.

[29] Williams, D. J., & Shah, M. (1992). A fast algorithm for active contours and curvature estimation. *CVGIP: Image understanding*, 55(1), 14-26.

[30] Lam, K. M., & Yan, H. (1994). Fast greedy algorithm for active contours. *Electronics Letters*, 30(1), 21-23.

[31] A. Vannieuwenhuyze, *Intelligence artificielle vulgarisée - Le Machine Learning et le Deep Learning par la pratique*, Eni Editions. in *Ressources Informatiques*. 2019. [En ligne]. Disponible sur : <https://www.fnac.com/a13707166/Aurelien-Vannieuwenhuyze-Intelligence-artificielle-vulgarisee>

[32] Z. Hu, J. Tang, Z. Wang, K. Zhang, L. Zhang, et Q. Sun, « Deep learning for image-based cancer detection and diagnosis – A survey », *Pattern Recognit.*, vol. 83, p. 134-149, nov. 2018, doi: 10.1016/j.patcog.2018.05.014.

[33] Z. Alom, T. M. Taha, et V. K. Asari, « Recurrent Residual Convolutional Neural Network based on U-Net (R2U-Net) for Medical Image Segmentation », p. 12.

[34] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, et J. Liang, « UNet++: A Nested U-Net Architecture for Medical Image Segmentation », in *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, vol. 11045, D. Stoyanov, Z. Taylor, G. Carneiro, T. Syeda-Mahmood, A. Martel, L. Maier-Hein, J. M. R. S. Tavares, A. Bradley, J. P. Papa, V. Belagiannis, J. C. Nascimento, Z. Lu, S. Conjeti, M. Moradi, H. Greenspan, et A. Madabhushi, Éd., in *Lecture Notes in Computer Science*, vol. 11045. , Cham: Springer International Publishing, 2018, p. 3-11. doi: 10.1007/978-3-030-00889-5_1.

[35] Q. Gao et M. Almekkawy, « ASU-Net++: A nested U-Net with adaptive feature

extractions for liver tumor segmentation », *Comput. Biol. Med.*, vol. 136, p. 104688, sept. 2021, doi: 10.1016/j.compbiomed.2021.104688.

[36] Chenyang Xu et J. L. Prince, « Gradient vector flow: a new external force for snakes », in *Proceedings of IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, San Juan, Puerto Rico: IEEE Comput. Soc, 1997, p. 66-71. doi: 10.1109/CVPR.1997.609299.

[37] Buduma, N., Buduma, N., & Papa, J. (2022). *Fundamentals of deep learning*. " O'Reilly Media, Inc."

[38] Bernard, W. S., & Christopher, P. W. (2020). *World cancer report 2020*. World Health Organization.

[39] M. Moghbel, S. Mashohor, R. Mahmud, et M. I. B. Saripan, « Review of liver segmentation and computer assisted detection/diagnosis methods in computed tomography », *Artif. Intell. Rev.*, vol. 50, no 4, p. 497-537, déc. 2018, doi: 10.1007/s10462-017-9550-x.

[40] H. D. Cheng, X. J. Shi, R. Min, L. M. Hu, X. P. Cai, et H. N. Du, « Approaches for automated detection and classification of masses in mammograms », *Pattern Recognit.*, vol. 39, no 4, p. 646-668, avr. 2006, doi: 10.1016/j.patcog.2005.07.006.

[41] S. L. S. Abdullah, H. Hambali, et N. Jamil, « Segmentation of Natural Images Using an Improved Thresholding-Based Technique », *Procedia Engineering*, vol. 41, p. 938-944, 2012, doi: 10.1016/j.proeng.2012.07.266.

[42] K. Abiko, K. Uruma, M. Sugawara, S. Hangai, et T. Hamamoto, « Image Segmentation Based Graph-Cut Approach to Fast Color Image Coding via Graph Fourier Transform », in *2019 IEEE Visual Communications and Image Processing (VCIP)*, Sydney, Australia: IEEE, déc. 2019, p. 1-4. doi: 10.1109/VCIP47243.2019.8966021.

[43] Md. F. Ahamed et al., « A review on brain tumor segmentation based on deep learning methods with federated learning techniques », *Computerized Medical Imaging and Graphics*, vol. 110, p. 102313, déc. 2023, doi: 10.1016/j.compmedimag.2023.102313.

[44] W. Al-Faqheri, F. Ibrahim, T. Hwai Gilbert Thio, K. Joseph, M. S. Mohktar, et M. Madou, « Liquid density effect on burst frequency in centrifugal microfluidic platforms », in *2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, Milan: IEEE, août 2015, p. 3221-3224. doi: 10.1109/EMBC.2015.7319078.

[45] F. M. Alshagathrh et M. S. Househ, « Artificial Intelligence for Detecting and Quantifying Fatty Liver in Ultrasound Images: A Systematic Review », *Bioengineering*, vol. 9, no 12, p. 748, déc. 2022, doi: 10.3390/bioengineering9120748.

- [46] G. M. H. Amer et A. M. Abushaala, « Edge detection methods », in 2015 2nd World Symposium on Web Applications and Networking (WSWAN), Sousse, Tunisia: IEEE, mars 2015, p. 1-7. doi: 10.1109/WSWAN.2015.7210349.
- [47] T. Amina, L. Lakhdar, B. Hakim, et M. Abdallah, « Improved Active Contour Model through Automatic Initialisation: Liver Segmentation », in 2021 IEEE 1st International Maghreb Meeting of the Conference on Sciences and Techniques of Automatic Control and Computer Engineering MI-STA, Tripoli, Libya: IEEE, mai 2021, p. 771-775. doi: 10.1109/MI-STA52233.2021.9464516.
- [48] T. Amina, L. Lakhdar, B. Hakim, et M. Abdallah, « Convolutional Neural Networks for Segmented Liver Classification », in 2021 International Conference on Recent Advances in Mathematics and Informatics (ICRAMI), Tebessa, Algeria: IEEE, sept. 2021, p. 1-5. doi: 10.1109/ICRAMI52622.2021.9585986.
- [49] B. Ashreetha, M. R. Devi, U. P. Kumar, M. K. Mani, D. N. Sahu, et P. C. S. Reddy, « Soft optimization techniques for automatic liver cancer detection in abdominal liver images », *ijhs*, p. 10820-10831, mai 2022, doi: 10.53730/ijhs.v6nS1.7597.
- [50] Z. Bai, H. Jiang, S. Li, et Y.-D. Yao, « Liver Tumor Segmentation Based on Multi-Scale Candidate Generation and Fractal Residual Network », *IEEE Access*, vol. 7, p. 82122-82133, 2019, doi: 10.1109/ACCESS.2019.2923218.
- [51] D. Bardou, « Investigations on the Use of Deep Learning for the Classification of Lung Sounds and Breast Cancer with Comparison against Classical Machine Learning », p. 117.
- [52] M. T. Bennai, Z. Guessoum, S. Mazouzi, S. Cormier, et M. Mezghiche, « A stochastic multi-agent approach for medical-image segmentation: Application to tumor segmentation in brain MR images », *Artificial Intelligence in Medicine*, vol. 110, p. 101980, nov. 2020, doi: 10.1016/j.artmed.2020.101980.
- [53] L. Bi, J. Kim, A. Kumar, M. Fulham, et D. Feng, « Stacked fully convolutional networks with multi-channel learning: application to medical image segmentation », *Vis Comput*, vol. 33, no 6-8, p. 1061-1071, juin 2017, doi: 10.1007/s00371-017-1379-4.
- [54] P. Bilic et al., « The Liver Tumor Segmentation Benchmark (LiTS) », *Medical Image Analysis*, vol. 84, p. 102680, févr. 2023, doi: 10.1016/j.media.2022.102680.
- [55] Y. Boykov et G. Funka-Lea, « Graph Cuts and Efficient N-D Image Segmentation », *Int J Comput Vision*, vol. 70, no 2, p. 109-131, nov. 2006, doi: 10.1007/s11263-006-7934-5.
- [56] F. Bray, J. Ferlay, I. Soerjomataram, R. L. Siegel, L. A. Torre, et A. Jemal, « Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36

cancers in 185 countries », *CA A Cancer J Clinicians*, vol. 68, no 6, p. 394-424, nov. 2018, doi: 10.3322/caac.21492.

[57] D. Brzakovic, X. M. Luo, et P. Brzakovic, « An approach to automated detection of tumors in mammograms », *IEEE Trans. Med. Imaging*, vol. 9, no 3, p. 233-241, sept. 1990, doi: 10.1109/42.57760.

[58] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, et A. L. Yuille, « DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs », 12 mai 2017, arXiv: arXiv:1606.00915. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1606.00915>

[59] Y. Chen et al., « Channel-Unet: A Spatial Channel-Wise Convolutional Neural Network for Liver and Tumors Segmentation », *Front. Genet.*, vol. 10, p. 1110, nov. 2019, doi: 10.3389/fgene.2019.01110.

[60] G. Chlebus, A. Schenk, J. H. Moltz, B. Van Ginneken, H. K. Hahn, et H. Meine, « Automatic liver tumor segmentation in CT with fully convolutional neural networks and object-based postprocessing », *Sci Rep*, vol. 8, no 1, p. 15497, oct. 2018, doi: 10.1038/s41598-018-33860-7.

[61] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, et O. Ronneberger, « 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation », 21 juin 2016, arXiv: arXiv:1606.06650. Consulté le: 1 novembre 2022. [En ligne]. Disponible sur: <http://arxiv.org/abs/1606.06650>

[62] P. Dempster, N. M. Laird, et D. B. Rubin, « Maximum Likelihood from Incomplete Data Via the EM Algorithm », *Journal of the Royal Statistical Society Series B: Statistical Methodology*, vol. 39, no 1, p. 1-22, sept. 1977, doi: 10.1111/j.2517-6161.1977.tb01600.x.

[63] C. Duan et N. Xiao, « Parallax-Based Spatial and Channel Attention for Stereo Image Super-Resolution », *IEEE Access*, vol. 7, p. 183672-183679, 2019, doi: 10.1109/ACCESS.2019.2960561.

[64] R. O. Duda et P. E. Hart, « Use of the Hough transformation to detect lines and curves in pictures », *Commun. ACM*, vol. 15, no 1, p. 11-15, janv. 1972, doi: 10.1145/361237.361242.

[65] G. Gilanie, U. I. Bajwa, M. M. Waraich, et Z. Habib, « Computer aided diagnosis of brain abnormalities using texture analysis of MRI images », *Int J Imaging Syst Tech*, vol. 29, no 3, p. 260-271, sept. 2019, doi: 10.1002/ima.22312.

[66] J. Goodfellow et al., « Generative Adversarial Networks », 10 juin 2014, arXiv: arXiv:1406.2661. Consulté le: 1 novembre 2022. [En ligne]. Disponible sur:

<http://arxiv.org/abs/1406.2661>

- [67] Goshtasby et M. Satter, « An adaptive window mechanism for image smoothing », *Computer Vision and Image Understanding*, vol. 111, no 2, p. 155-169, août 2008, doi: 10.1016/j.cviu.2007.09.008.
- [68] X. Han, « Automatic Liver Lesion Segmentation Using A Deep Convolutional Neural Network Method », *Med. Phys.*, vol. 44, no 4, p. 1408-1419, avr. 2017, doi: 10.1002/mp.12155.
- [69] K. He, X. Zhang, S. Ren, et J. Sun, « Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification », 6 février 2015, arXiv: arXiv:1502.01852. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1502.01852>
- [70] K. He, X. Zhang, S. Ren, et J. Sun, « Deep Residual Learning for Image Recognition », in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA: IEEE, juin 2016, p. 770-778. doi: 10.1109/CVPR.2016.90.
- [71] K. He, X. Zhang, S. Ren, et J. Sun, « Identity Mappings in Deep Residual Networks », 25 juillet 2016, arXiv: arXiv:1603.05027. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1603.05027>
- [72] C.-Y. Hsiao, P.-D. Chen, et K.-W. Huang, « A Prospective Assessment of the Diagnostic Value of Contrast-Enhanced Ultrasound, Dynamic Computed Tomography and Magnetic Resonance Imaging for Patients with Small Liver Tumors », *JCM*, vol. 8, no 9, p. 1353, sept. 2019, doi: 10.3390/jcm8091353.
- [73] P. Hu, F. Wu, J. Peng, P. Liang, et D. Kong, « Automatic 3D liver segmentation based on deep learning and globally optimized surface evolution », *Phys. Med. Biol.*, vol. 61, no 24, p. 8676-8698, déc. 2016, doi: 10.1088/1361-6560/61/24/8676.
- [74] G. Huang, Z. Liu, L. Van Der Maaten, et K. Q. Weinberger, « Densely Connected Convolutional Networks », in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI: IEEE, juill. 2017, p. 2261-2269. doi: 10.1109/CVPR.2017.243.
- [75] Hyunjin Park, P. H. Bland, et C. R. Meyer, « Construction of an abdominal probabilistic atlas and its application in segmentation », *IEEE Trans. Med. Imaging*, vol. 22, no 4, p. 483-492, avr. 2003, doi: 10.1109/TMI.2003.809139.
- [76] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, et K. H. Maier-Hein, « nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation », *Nat Methods*, vol. 18, no 2, p. 203-211, févr. 2021, doi: 10.1038/s41592-020-01008-z.
- [77] M. Y. Jabarulla et H.-N. Lee, « Computer aided diagnostic system for ultrasound liver

- images: A systematic review », *Optik*, vol. 140, p. 1114-1126, juill. 2017, doi: 10.1016/j.ijleo.2017.05.013.
- [78] S. Jadon, « A survey of loss functions for semantic segmentation », in 2020 IEEE Conference on Computational Intelligence in Bioinformatics and Computational Biology (CIBCB), Via del Mar, Chile: IEEE, oct. 2020, p. 1-7. doi: 10.1109/CIBCB48159.2020.9277638.
- [79] J. Ji, X. Lu, M. Luo, M. Yin, Q. Miao, et X. Liu, « Parallel Fully Convolutional Network for Semantic Segmentation », *IEEE Access*, vol. 9, p. 673-682, 2021, doi: 10.1109/ACCESS.2020.3042254.
- [80] X. Jiang, Z. Hu, S. Wang, et Y. Zhang, « Deep Learning for Medical Image-Based Cancer Diagnosis », *Cancers*, vol. 15, no 14, p. 3608, juill. 2023, doi: 10.3390/cancers15143608.
- [81] D. Kainmuller, T. Lange, et H. Lamecker, « Shape Constrained Automatic Segmentation of the Liver based on a Heuristic Intensity Model ».
- [82] M. Kamel et A. Campilho, Éd., *Image Analysis and Recognition: 8th International Conference, ICIAR 2011, Burnaby, BC, Canada, June 22-24, 2011. Proceedings, Part II*, vol. 6754. in *Lecture Notes in Computer Science*, vol. 6754. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011. doi: 10.1007/978-3-642-21596-4.
- [83] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy, et P. T. P. Tang, « On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima », 9 février 2017, arXiv: arXiv:1609.04836. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1609.04836>
- [84] D. P. Kingma et J. Ba, « Adam: A Method for Stochastic Optimization », 30 janvier 2017, arXiv: arXiv:1412.6980. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1412.6980>
- [85] K. Kirimasthong, A. Rodtook, W. Lohitvisate, et S. S. Makhanov, « Automatic initialization of active contours in ultrasound images of breast cancer », *Pattern Anal Applic*, vol. 21, no 2, p. 491-500, mai 2018, doi: 10.1007/s10044-017-0627-6.
- [86] Krizhevsky, I. Sutskever, et G. E. Hinton, « ImageNet classification with deep convolutional neural networks », *Commun. ACM*, vol. 60, no 6, p. 84-90, mai 2017, doi: 10.1145/3065386.
- [87] C.-Y. Lee, S. Xie, P. Gallagher, Z. Zhang, et Z. Tu, « Deeply-Supervised Nets », 25 septembre 2014, arXiv:arXiv:1409.5185. Consulté le: 5 novembre 2024. [En ligne]. Disponible

sur: <http://arxiv.org/abs/1409.5185>

- [88] H. Li, Z. Xu, G. Taylor, C. Studer, et T. Goldstein, « Visualizing the LossLandscape of Neural Nets », 7 novembre 2018, arXiv:arXiv:1712.09913. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1712.09913>
- [89] Q. Li et al., « Burden of liver cancer: From epidemiology to prevention », *Chinese Journal of Cancer Research*, vol. 34, no 3, p. 554-566, 2022, doi: 10.21147/j.issn.1000-9604.2022.06.02.
- [90] X. Li, H. Chen, X. Qi, Q. Dou, C.-W. Fu, et P. A. Heng, « H-DenseUNet: Hybrid Densely Connected UNet for Liver and Tumor Segmentation from CT Volumes », 3 juillet 2018, arXiv: arXiv:1709.07330. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1709.07330>
- [91] M. G. Linguraru et al., « Tumor Burden Analysis on Computed Tomography by Automated Liver and Tumor Segmentation », *IEEE Trans. Med. Imaging*, vol. 31, no 10, p. 1965-1976, oct. 2012, doi: 10.1109/TMI.2012.2211887.
- [92] G. Litjens et al., « A survey on deep learning in medical image analysis », *Medical Image Analysis*, vol. 42, p. 60-88, déc. 2017, doi: 10.1016/j.media.2017.07.005.
- [93] D. G. Lowe, « Object recognition from local scale-invariant features », in *Proceedings of the Seventh IEEE International Conference on Computer Vision*, Kerkyra, Greece: IEEE, 1999, p. 1150-1157 vol.2. doi: 10.1109/ICCV.1999.790410.
- [94] Y. Luo, L. Liu, Q. Huang, et X. Li, « A Novel Segmentation Approach Combining Region- and Edge-Based Information for Ultrasound Images », *BioMed Research International*, vol. 2017, p. 1-18, 2017, doi: 10.1155/2017/9157341.
- [95] L. Massoptier et S. Casciaro, « A new fully automatic and robust algorithm for fast segmentation of liver tissue and tumors from CT scans », *EurRadiol*, vol. 18, no 8, p. 1658-1665, août 2008, doi: 10.1007/s00330-008-0924-y.
- [96] L. Meng, Y. Tian, et S. Bu, « Liver tumor segmentation based on 3D convolutional neural network with dual scale », *J Applied Clin Med Phys*, vol. 21, no 1, p. 144-157, janv. 2020, doi: 10.1002/acm2.12784.
- [97] L. Meng, Q. Zhang, et S. Bu, « Two-Stage Liver and Tumor Segmentation Algorithm Based on Convolutional Neural Network », *Diagnostics*, vol. 11, no 10, p. 1806, sept. 2021, doi: 10.3390/diagnostics11101806.
- [98] F. Milletari, N. Navab, et S.-A. Ahmadi, « V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation », in *2016 Fourth International Conference on 3D*

- Vision (3DV), Stanford, CA, USA: IEEE, oct. 2016, p. 565-571. doi: 10.1109/3DV.2016.79.
- [99] M. Moghbel, S. Mashohor, R. Mahmud, et M. I. B. Saripan, « Automatic liver tumor segmentation on computed tomography for patient treatment planning and monitoring », EXCLI Journal; 15:Doc406; ISSN 1611-2156, 2016, doi: 10.17179/EXCLI2016-402.
- [100] J. H. Moltz et al., « Advanced Segmentation Techniques for Lung Nodules, Liver Metastases, and Enlarged Lymph Nodes in CT Scans », IEEE J. Sel. Top. Signal Process., vol. 3, no 1, p. 122-134, févr. 2009, doi: 10.1109/JSTSP.2008.2011107.
- [101] K. M. Napte, A. Mahajan, et S. Urooj, « Automatic Liver Cancer Detection Using Deep Convolution Neural Network », IEEE Access, vol. 11, p. 94852-94862, 2023, doi: 10.1109/ACCESS.2023.3307640.
- [102] K. Nawres, M. Amel, et H. Kamel, « Segmentation d'images par contours actifs : Application à la détection du ventricule gauche dans les images de scintigraphie cardiaque ».
- [103] H. Pan, X. Zhu, S. Atici, et A. E. Cetin, « A Hybrid Quantum-Classical Approach based on the Hadamard Transform for the Convolutional Layer », 22 février 2024, arXiv: arXiv:2305.17510. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/2305.17510>
- [104] N. D. Parikh, A. S. Mehta, A. G. Singal, T. Block, J. A. Marrero, et A. S. Lok, « Biomarkers for the Early Detection of Hepatocellular Carcinoma », Cancer Epidemiology, Biomarkers & Prevention, vol. 29, no 12, p. 2495-2503, déc. 2020, doi: 10.1158/1055-9965.EPI-20-0005.
- [105] Qayyum, I. Ahmad, W. Mumtaz, M. O. Alassafi, R. Alghamdi, et M. Mazher, « Automatic Segmentation Using a Hybrid Dense Network Integrated With an 3D-Atrous Spatial Pyramid Pooling Module for Computed Tomography (CT) Imaging », IEEE Access, vol. 8, p. 169794-169803, 2020, doi: 10.1109/ACCESS.2020.3024277.
- [106] S. Qiao, Y. Xia, J. Zhi, X. Xie, et Q. Ye, « Automatic liver segmentation method based on improved region growing algorithm », in 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC), Chongqing, China: IEEE, juin 2020, p. 644-650. doi: 10.1109/ITNEC48623.2020.9085126.
- [107] N. Reamaroon, M. W. Sjoding, J. Gryak, B. D. Athey, K. Najarian, et H. Derksen, « Automated detection of acute respiratory distress syndrome from chest X-Rays using Directionality Measure and deep learning features », Computers in Biology and Medicine, vol. 134, p. 104463, juill. 2021, doi: 10.1016/j.compbiomed.2021.104463.
- [108] J. T. Ruiz, F. C. Gomez, et L. G. P. Meloni, « Analysis of the implementation of hybrid

- functions in the current brazilian digital television system », in 2014 IEEE Fourth International Conference on Consumer Electronics Berlin (ICCE-Berlin), Berlin, Germany: IEEE, sept. 2014, p. 210-214. doi: 10.1109/ICCE-Berlin.2014.7034297.
- [109] Sarti, C. Corsi, E. Mazzini, et C. Lamberti, « Maximum likelihood segmentation of ultrasound images with Rayleigh distribution », IEEE Trans. Ultrason., Ferroelect., Freq. Contr., vol. 52, no 6, p. 947-960, juin 2005, doi: 10.1109/TUFFC.2005.1504017.
- [110] S. Abrahams. T. Mott. D. Hafner. E. Erwitte. A. Scarpinelli, TensorFlow for Machine Intelligence. Place of publication not identified: Bleeding Edge Press, 2016. Consulté le: 19 novembre 2021. [En ligne]. Disponible sur: <https://proquest.safaribooksonline.com/9781939902351>
- [111] P. Schroeter, J.-M. Vesin, T. Langenberger, et R. Meuli, « Robust parameter estimation of intensity distributions for brain magnetic resonance images », IEEE Trans. Med. Imaging, vol. 17, no 2, p. 172-186, avr. 1998, doi: 10.1109/42.700730.
- [112] D. Sengupta, « Deep learning architectures for automated image segmentation », arXiv:1909.10333 [cs, eess, stat], sept. 2019, Consulté le: 6 mars 2022. [En ligne]. Disponible sur: <http://arxiv.org/abs/1909.10333>
- [113] P. Slagmolen, A. Elen, D. Seghers, D. Loeckx, F. Maes, et K. Haustermans, « Atlas based liver segmentation using nonrigid registration with a B-spline transformation model ».
- [114] P. Soille, Morphological Image Analysis. Berlin, Heidelberg: Springer Berlin Heidelberg, 2004. doi: 10.1007/978-3-662-05088-0.
- [115] V. Suárez-Paniagua et I. Segura-Bedmar, « Evaluation of pooling operations in convolutional architectures for drug-drug interaction extraction », BMC Bioinformatics, vol. 19, no S8, p. 209, juin 2018, doi: 10.1186/s12859-018-2195-1.
- [116] S. Tomoshige, E. Oost, A. Shimizu, H. Watanabe, et S. Nawano, « A conditional statistical shape model with integrated error estimation of the conditions; Application to liver segmentation in non-contrast CT images », Medical Image Analysis, vol. 18, no 1, p. 130-143, janv. 2014, doi: 10.1016/j.media.2013.10.003.
- [117] E. Vorontsov, N. Abi-Jaoudeh, et S. Kadoury, « Metastatic Liver Tumor Segmentation Using Texture-Based Omni-Directional Deformable Surface Models », in Abdominal Imaging. Computational and Clinical Applications, vol. 8676, H. Yoshida, J. J. Näppi, et S. Saini, Éd., in Lecture Notes in Computer Science, vol. 8676. , Cham: Springer International Publishing, 2014, p. 74-83. doi: 10.1007/978-3-319-13692-9_7.
- [118] E. Vorontsov, A. Tang, C. Pal, et S. Kadoury, « Liver lesion segmentation informed by

- joint liver segmentation », 11 août 2018, arXiv: arXiv:1707.07734. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1707.07734>
- [119] H. Wan, H. Wang, B. Scotney, et J. Liu, « A Novel Gaussian Mixture Model for Classification », in 2019 IEEE International Conference on Systems, Man and Cybernetics (SMC), Bari, Italy: IEEE, oct. 2019, p. 3298-3303. doi: 10.1109/SMC.2019.8914215.
- [120] G. Wang, Q. Dong, Z. Pan, X. Zhao, J. Yang, et C. Liu, « Active Contour Model for Ultrasound Images with Rayleigh Distribution », Mathematical Problems in Engineering, vol. 2014, p. 1-12, 2014, doi: 10.1155/2014/295320.
- [121] J. Wang, Y. Peng, S. Jing, L. Han, T. Li, et J. Luo, « A deep-learning approach for segmentation of liver tumors in magnetic resonance imaging using UNet++ », BMC Cancer, vol. 23, no 1, p. 1060, nov. 2023, doi: 10.1186/s12885-023-11432-x.
- [122] N. Wang, J. Rauh, et H. Massam, « Approximating faces of marginal polytopes in discrete hierarchical models », Ann. Statist., vol. 47, no 3, juin 2019, doi: 10.1214/18-AOS1710.
- [123] X. Wang, J. Yang, D. Ai, Y. Zheng, S. Tang, et Y. Wang, « Adaptive Mesh Expansion Model (AMEM) for Liver Segmentation from CT Image », PLoS ONE, vol. 10, no 3, p. e0118064, mars 2015, doi: 10.1371/journal.pone.0118064.
- [124] W. Wu, S. Wu, Z. Zhou, R. Zhang, et Y. Zhang, « 3D Liver Tumor Segmentation in CT Images Using Improved Fuzzy C -Means and Graph Cuts », BioMed Research International, vol. 2017, p. 1-11, 2017, doi: 10.1155/2017/5207685.
- [125] S. Xie, R. Girshick, P. Dollar, Z. Tu, et K. He, « Aggregated Residual Transformations for Deep Neural Networks », in 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI: IEEE, juill. 2017, p. 5987-5995. doi: 10.1109/CVPR.2017.634.
- [126] L. Xu, Y. Zhu, Y. Zhang, et H. Yang, « Liver segmentation based on region growing and level set active contour model with new signed pressure force function », Optik, vol. 202, p. 163705, févr. 2020, doi: 10.1016/j.ijleo.2019.163705.
- [127] Z. Xu et al., « Efficient multi-atlas abdominal segmentation on clinically acquired CT with SIMPLE context learning », Medical Image Analysis, vol. 24, no 1, p. 18-27, août 2015, doi: 10.1016/j.media.2015.05.009.
- [128] F. Yu et V. Koltun, « Multi-ScaleContextAggregation by Dilated Convolutions », 30 avril 2016, arXiv:arXiv:1511.07122. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/1511.07122>

- [129] X. Zhang, J. Tian, K. Deng, Y. Wu, et X. Li, « Automatic Liver Segmentation Using a Statistical Shape Model With Optimal Surface Detection », *IEEE Trans. Biomed. Eng.*, vol. 57, no 10, p. 2622-2626, oct. 2010, doi: 10.1109/TBME.2010.2056369.
- [130] Y. Zhang, L. Yang, J. Chen, M. Fredericksen, D. P. Hughes, et D. Z. Chen, « Deep Adversarial Networks for Biomedical Image Segmentation Utilizing Unannotated Images », in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2017*, vol. 10435, M. Descoteaux, L. Maier-Hein, A. Franz, P. Jannin, D. L. Collins, et S. Duchesne, Éd., in *Lecture Notes in Computer Science*, vol. 10435. , Cham: Springer International Publishing, 2017, p. 408-416. doi: 10.1007/978-3-319-66179-7_47.
- [131] R. Zheng et al., « Automatic Liver Tumor Segmentation on Dynamic Contrast Enhanced MRI Using 4D Information: Deep Learning Model Based on 3D Convolution and Convolutional LSTM », *IEEE Trans. Med. Imaging*, vol. 41, no 10, p. 2965-2976, oct. 2022, doi: 10.1109/TMI.2022.3175461.
- [132] B. Zhou, Z. Augenfeld, J. Chapiro, S. K. Zhou, C. Liu, et J. S. Duncan, « Anatomy-guided Multimodal Registration by Learning Segmentation without Ground Truth: Application to Intraprocedural CBCT/MR Liver Segmentation and Registration », 14 avril 2021, arXiv: arXiv:2104.07056. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/2104.07056>
- [133] J. Zhuang et al., « AdaBelief Optimizer: Adapting Stepsizes by the Belief in Observed Gradients », 20 décembre 2020, arXiv: arXiv:2010.07468. Consulté le: 5 novembre 2024. [En ligne]. Disponible sur: <http://arxiv.org/abs/2010.07468>
- [134] « U-Net : le réseau de neurones populaire en Computer Vision ». Consulté le: 16 novembre 2022. [En ligne]. Disponible sur: <https://blent.ai/unet-computer-vision/>